建筑行业技术扫描系列报告（2023）

大数据技术扫描报告

广联达科技股份有限公司

2023 年 9 月

序言

目录

0 主要观点.....1
1 大数据 Top 厂商动态.....6
1.1 全球 Top 大数据厂商技术动态扫描[姜建卫].....6
1.2 友商大数据动态[袁小芬].....12
1.3 垂直行业标杆企业动态[袁小芬].....15
2 大数据技术.....17
2.1 大数据软件架构技术[袁小芬].....17
2.2 数据存储技术[刘松].....23
2.2.1 Serverless 云数仓.....23
2.2.2 数据湖.....24
2.3 数据计算与分析[姜建卫].....26
2.3.1 流计算框架.....26
2.3.2 查询分析框架.....30
2.3.3 图计算框架.....31
2.3.4 ML 计算框架.....36
2.3.5 统一计算引擎.....38
2.3.6 检索分析引擎.....40
2.4 集群资源管理[姜建卫].....43
2.5 大数据中间件[刘松].....44
2.6 数据集成技术[杨思羽].....48
2.6.1 数据集成商业工具/平台.....48
2.6.1 主流开源产品.....50
2.7 大数据开发[袁小芬].....56
2.7.1 开发语言.....56
2.8 数据治理技术[申凯].....59
2.8.1 元数据.....59
2.9 大数据运维[张祺君].....61
2.10 大数据安全技术[高贵增].....62
2.10.1 数据安全标准.....63
2.10.2 DataOps.....64
2.10.3 数据泄露趋势.....66
2.10.4 大数据平台安全.....67
3 大数据与相关技术的结合.....69
3.1 大数据与云计算[姜建卫].....69
3.2 大数据与 AI[张祺君].....73
3.3 大数据与 IOT[刘光剑].....75
4 大数据行业应用.....77
4.1 数据标准[李会涛].....77
4.1.1 行业政策.....77
4.1.2 行业通用数据标准.....79
4.1.3 工程全生命周期数据标准落地应用.....81

4.2 数据中台[刘松] 82
4.3 CDE[刘光剑] 85
4.4 IOT[刘光剑] 87
4.5 BIM[刘光剑] 88
4.6 数据智能[杨思羽] 89
4.7 智慧城市[莫覃华] 91
4.8 数字孪生[杨思羽] 94
5 大数据与广联达 95
5.1 大数据平台建设[刘松] 95
5.2 GDE 平台建设[刘松] 97

0 主要观点

观点 1：Severless

公有云厂商借助云原生能力自然演进大数据存算分离架构，扩展 Serverless 技术组件，增强 Serverless 现有能力，Serverless 技术更趋成熟，实现真正开箱即用，提供方便地接入各类数据、降低存储和运维成本的数据湖方案。对于搜索服务、离线分析计算场景，充分考虑云中立和架构兼容基础上，建议优先选择公有云厂商提供的 Serverless 服务，实现降本增效。

观点 2：数联网

数联网将成为数字化时代的新型信息基础设施，中国移动于 2023 年 4 月正式发布数联网（DSSN），是基础运营商发布的首张面向数据要素服务的专业网，数联网将成为数字化时代的新型信息基础设施。建议广联达密切关注其技术路线发展和落地实践，并着手开展建筑领域行业级数联网基础设施的研究和建设，促进行业客户数据流通，为行业的数字化转型升级和数据要素的市场化发展提供基础保障和关键能力。

观点 3：Data Fabric

在大数据应用需求的驱动下，计算技术体系正在重构，从“以计算为中心”向“以数据为中心”转型：数据与应用进一步分离、数据管理从单域到跨域、大数据管理与处理系统体系结构异构化等日趋明显。Data Fabric 作为一种数据管理设计模式，可实现跨异构数据源的增强数据集成和共享，通过主动元数据技术等，来支持数据系统跨平台的设计、部署和使用，从而实现灵活的数据交付。微软等厂商的相关产品中已经落地，建议广联达持续关注其最佳实践路径，并建议尽快投入预研，破解行业客户数字化转型升级带来的数据汇集融合方面的新挑战。

观点 4：流式数据湖

随着数字化转型浪潮的席卷，各行各业开始采用业界流行的数据湖技术构建自己的数据湖基座，传统数据湖技术由于都是在优化 Batch 数据仓库的背景下诞生的，无法从根本上解决流批一体的问题，流式数据湖技术在此背景下诞生，并被各大行业应用。广联达 GDE 在构建数据湖基座时，选取了流式数据湖 paimon 技术作为基座，为后续广联达 GDE 数据融通、协同奠定了强有力的基础。

观点 5：IOTDB

IoTDB 作为国产自主开源的物联网数据库，它具有体量轻、性能高、易使用的特点，完美对接 Hadoop 与 Spark 生态，适用于工业物联网应用中海量时间序列数据高速写入和复杂分析查询的需求，已被多个大厂平台整合，建议纳入广联达 IoT 平台国产化选型范围。

观点 6：实时计算平台

流式数据处理是当今大数据领域的趋势，当下数字化转型期的企业渴望更及时地洞察自己的数据，而曾经的“批处理”思维正迅速被流式处理所取代。越来越多的企业，无论大小，都在重新思考技术架构时把实时性作为第一考量，并开始用强大的开源引擎构建自己的实时计算平台。广联达正在采用 Flink，Spark，Kafka，Paimon 搭建实时计算平台，建议关注 Pulsar 和 StreamPark 的发展并适时引入，助力建设更强大和更易用的实时计算平台。

观点 7：图计算

图计算已经在大数据处理和分析中展现出其独特的价值和地位。传统 SQL 难以满足高效的数据深度挖掘需求，图几乎成为了不二之选；得益于图抽象的语意表达能力和可解释性，图计算可以很好的解决 LLM 的回答及时性、准确性，以及复杂任务编排的问题，以 ChatGPT 为代表的大语言模型（LLM）迎来爆发式增长。随着未来图数据规模的持续增大，建议广联达采用开源图计算框架或者公有云图计算服务进行图数据的查询和分析，以满足大规模图数据的高性能查询和分析场景需求。

观点 8：AI 框架 Ray

训练和部署 LLM 所需的大量时间和资源非常惊人，分布式计算是降低人工智能项目基础设施复杂性和成本的一种有效方法。OpenAI 开发人员正是使用开源统一计算框架 Ray,深度集成 ML 平台（Aviary）和开发框架（TensorFlow 和 PyTorch），来降低基础设施成本和训练大型语言模型（LLM）的复杂性。建议广联达数据智能相关部门，试用评估 Ray 和 Aviary 能否为广联达带来业务价值或能够提升工作效率。

观点 9：流批计算

流批计算从统一计算到统一存储，实现统一实时分析，流批统一的数据处理概念在越来越多的公司中得到认可，并在越来越多的公司中成功实施。Flink 持续加强批处理方面的能力，成为流批一体的最佳选择。广联达平台和产品线普遍采用 Flink 和 Spark 来作为流或批以及流批一体的计算引擎。

观点 10：Java 版本

Java11 已经成为最主流的 JAVA 长期支持版本（LTS），Java17 的使用率在一年之内增长迅速，目前大数据主流的存储、数据计算与分析等组件等开始支持 Java 17，并且有些大数据主流组件在最新版本里已经不推荐使用 Java 8；目前广联达大数据应用开发仍以 Java 8 为主，建议由数据中台来牵头，确定统一应用开发的 Java 版本选型和升级节奏，Java 版本尽量与大数据技术组件推荐的版本保持一致。

观点 11：数据治理

用软件工程持续集成与交付的理念去治理数据，解决数据开发过程中的效率和质量问题这一概念及实践方法论得到国家部委的认可，并推进 DataOps 能力模型评估工作。广联达作为建筑领域数据治理平台领导者，建议关注相关技术以及相关资质的获得是否对赢得市场有帮助。

观点 12：数据中台与 AI

AI 技术已开始在多行业中得到探索应用，成为一个推动企业创新发展的新引擎，大数据与 AI 相辅相成：数据中台给 AI 提供的数据支撑，AI 又能够提供给数据更便捷的数据分析和预测能力，从而提供更好的数据服务。建议广联达加速考虑数据中台与 AI 中台的融合解决方案。Salesforce 的做法值得我们借鉴，其把组织的所有数据拉通（跟广联达的 GDE 理念类似），然后跟 AI、BI 打通。

观点 13：CDE

国外建筑行业流行的 CDE 模式，更多以文件协同为核心，以 BIM 模型信息交互为关键，基于文档的协同管理，完成多方协同，这里面包含了 ProjectWise、Autodesk Docs、ASite，甚至微软的 OneDrive,这些都是针对 CDE 提供的不同类型的产品方案。

国内建筑行业的所涉及的数字化、智能化，不仅仅是依赖于文件实现，数据是重要核心部分，数据间的协同只是基础能力，数据融合背后的业务协同更符合国内针对 CDE 定位，广联达在建设 GDE 时，需要考虑国内建筑业的“特点”，依据数据+连接+算法思想，构建全栈的数据连接、融合、协同能力。

观点 14：腾讯提出建筑连接器

在数字化时代，单纯的物联网平台已不能满足行业、企业的数字化诉求，将物联网平台、大数据、AI、BIM 等能力整合形成联合解决方案已是趋势。腾讯提出的建筑连接器，多技术融合，连接应用、数据、用户、产业，帮助企业打通产业链上下游环节，提高企业运营效率优化、内外部业务协同、数字营销和敏捷创新的

能力，满足企业数字化转型的需求，这一方式与广联达建筑业务平台的理念异曲同工。

观点 15：超融合数据库

随着智慧城市的建设，城市数据的使用进入融合期，城市异构数据从分散架构向融合架构演进，二三维一体化的空间数据库、时空一体化数据库和超融合数据库成为各厂商探索的方向。广联达 CIM 平台也在基于 PostGIS 构建自己的 BIM+GIS 时空数据库，后续可以考虑纳入 IoT 和业务数据统一管理，形成全融合数据库以支撑复杂分析场景。

观点 16：数据安全

2023 年多份数据安全研究报告指出，数据泄露成本逐年升高，大量数据安全事件为经济驱动、内部人员导致。各 Top 公有云厂商依据《数据安全法》、《个人信息保护法》的相关要求，加快了数据安全相关产品更新迭代频次。建议广联达依据合规要求、社会责任等适当采用数据安全相关产品和技术手段，加强对公司和客户的数据资产的有效保护。

观点 17：数据标准

新时期下，加快行业数字化转型，发展智能建造、推动工程项目全周期数字化应用，均以数据标准化为基础。广联达是数字化、标准化的供给方，建议与多方更深度合作（高校、重点客户、政府等），通过标准建立更加和谐稳固的客户关系，推进示范项目落地应用标准，实现数据和标准的价值，扩大影响力。

观点 18：可视化数据开发

随着数字化转型在各行各业的兴起，在数字化转型的过程中数据开发治理是不可避免的一环，而各行业面临着缺乏专业的数据人才的困境，如何解决低门槛的数据开发治理问题，成为各行业数字化转型过程中的痛点。可视化低门槛的开发治理计算中间件成为大数据领域有力的工具，广联达在数据中台的建设过程中引入 Apache Hop 作为计算中间件，通过可视化拖拉拽的方式实现了数据开发治理，降低了使用门槛，增强了产品的易用性。

观点 19：数据中台

传统大数据时代，数据中台的开发治理工作需要专业的数据治理工程师或团队介入，客户面临治理的门槛和成本较高。目前各大数据产品厂商开始在产品工具、治理方法论，开发治理一体化、流程制度等多方面发力，将治理的全流程环节融入到

产品工具层面，达到通过一体化的工具体系解决复杂的数据治理问题，降低使用门槛和成本，一体化的方案逐渐被客户所接受。广联达数据中台在建设的过程中，前期聚焦在多个零散维度的能力建设方面，没有体系化的设计，后期产品能力完善方面，可重点关注一体化的能力建设。

观点 20：数据智能

在过去几年，数据驱动的智能应用已经逐渐从基于简单的数据分析和统计转型为基于机器学习和深度学习的特征和模型应用。主流厂商的 BI 软件开始集成机器学习能力，用于商业预测和建议；数据库则集成 AI 分析功能，为智能应用提供一体化的数据服务。广联达作为 BI 软件和数据库的深度用户，可以适当投入兵力进行探索，为后期的技术转型做准备。

观点 21：数字孪生

数字孪生领域中大数据技术主要应用于数据底座的建设，包括数据采集、数据存储、数据融合、时空计算等。目前行业内玩家仍然以探索为主，包括京东、腾讯等，都是在做技术积累和调研，bentley 也只是在做物理实体方面的建设。广联达的侧重点在数字孪生的构建，目前的技术水平和主流玩家处于同时代，建议广联达继续投入相关技术，从数字孪生的构建到匹配的机器学习和 AI 算法方面，努力跟上其他玩家的节奏甚至有所领先，力争在未来的数字孪生世代占有一席之地。

1 大数据 Top 厂商动态

Top 厂商大数据动态扫描从 3 个维度选取了行业的领先者产品或技术动态：

（1）**全球 Top 大数据厂商**—阿里云、华为云、腾讯云、Cloudera、亚马逊云、谷歌云、微软云；

（2）**建筑行业内大数据最具领先的代表厂商**—欧特克(Autodesk)、明源云、国泰新点、品茗；

（3）**垂直行业大数据最具领先的代表厂商**—贝壳、Salesforce。

1.1 全球 Top 大数据厂商技术动态扫描[姜建卫]

本节扫描从四个维度选取全球 Top 大数据领先厂商的技术动态：

（1）**国内大数据云厂商 Top**—阿里云、华为云和腾讯云；

（2）**全球开源大数据平台先驱**—Cloudera；

（3）**全球云计算市场份额最大最成熟的厂商**—亚马逊云、微软云；

（4）**大数据时代的奠基者和引领者**—Google。

华为云和阿里云作为广联达大数据公有云应用的基础设施，毫无疑问是本节重点扫描对象。

动态 1：国内开源大数据平台开始提供 Serverless 大数据专业服务，缩小与国外头部云厂商在大数据 Serverless 方面的差距，面向客户提供 Serverless 数据库和数据分析服务，加快用户开发大数据新应用，降低使用大数据技术的总体拥有成本。对于广联达公有云离线分析大数据应用，建议优先选择云厂商提供的 Serverless 大数据技术框架，降本增效。

动态 2：国内开源大数据平台整合发布新的 MPP 数据库，StarRocks 和 Doris 成为国内流行度高的 MPP 数据库。广联达目前选择 StarRocks 作为 OLAP 的数据底座，其稳定性方面挑战较大，建议广联达密切关注 Doris 的大厂应用情况、稳定性及其未来蓝图规划，适时作出技术调整。

动态内容：

阿里云开源大数据平台 E-MapReduce（简称“EMR”）是云原生开源大数据平台，向客户提供简单易集成的 Hadoop、Hive、Spark、Flink、Presto、ClickHouse、StarRocks、Delta、Hudi 等开源大数据计算和存储引擎。EMR 计算资源支持灵活的弹性控制。EMR 支持 on ECS、on ACK 以及 Serverless 多种部署形态。EMR 计算资源可以根据业务的需要调整。EMR 可以部署在阿里云公有云的 ECS 和 ACK 平台。2022 年 9 月新增支持添加弹性伸缩规则、开启自动补偿以及集群克隆功能。2022 年 10 月自定义集群功能上线。2022 年 11 月 OSS-HDFS 支持冷热分层存储以及 DataWorks 支持 EMR 自定义集群。2023 年 2 月访问链接与端口功能升级，支持访问服务原生 UI 地址，另外集群支持数据盘加密。2023 年 3 月支持默认创建存算分离集群。2023 年 5 月发布 Serverless StarRocks 商业版以及支持倚天云服务器。2023 年 6 月新增通过 SQL Editor 操作 StarRocks 实例功能。2023 年 7 月 EMR Workflow 开放公测。

华为云云原生数据湖 MRS(MapReduce Service)为客户提供 Hudi、ClickHouse、Spark、Flink、Kafka、HBase 等 Hadoop 生态的高性能大数据组件，支持数据湖、数据仓库、BI、AI 融合等能力。MRS 同时支持混合云和公有云两种形态。2023 年 3 月 MRS 组件版本升级，支持补丁更新推送和管理，可指定节点退订缩容集群以及可对已有集群新增弹性伸缩策略。2023 年 4 月新增 CDL 和 IoTDB 组件。2023 年 5 月新增 MRS Doris。

腾讯云弹性 MapReduce（简称“EMR”）是基于云原生技术的安全、低成本、高可靠的开源大数据计算框架，提供易于管理的 Hive、Spark、HBase、Flink、Doris、Iceberg、Alluxio 等开源大数据组件，帮助客户构建可弹性扩展的企业级大数据技术架构。2022 年 11 月 EMR 容器版支持 RSS 集群，自动伸缩功能支持托管伸缩。2022 年 12 月 EMR 支持 Java GC 在线分析。2023 年 2 月 EMR 支持查看 HDFS 小文件和大文件分布视图。2023 年 3 月 StarRocks 升级至 2.4 版本，支持 cn 节点和湖相关增强特性。2023 年 5 月优化集群创和和扩容速度。

Amazon EMR 是一个托管集群平台，可简化在上运行大数据框架（如 Apache Hadoop 和 Apache Spark）的过程，AWS 以处理和分析海量数据。使用这些框架和相关的开源项目，可以处理用于分析目的的数据和业务情报工作负载。Amazon EMR 还支持转换大量数据并移出/移入到其它 AWS 数据存储和数据库中。2022 年 9

月至2023年8月，Amazon EMR发布更新共计42次，更新聚焦在Amazon EMR on EKS和Amazon EMR Serverless的能力和地区推广方面。

Google 云 Dataproc 是一项具有高度可伸缩性的全托管式服务，用于运行 Apache Hadoop、Apache Spark、Apache Flink、Presto 等30多个开源工具和框架。使用 Dataproc 可以大规模实现数据湖现代化改造、ETL 和安全数据科学，并且 Dataproc 与 Google Cloud 集成，经济实惠。截止 2023 年 7 月 14 日 Dataproc 已发布 25 个小版本，Dataproc 版本发布非常频繁，基本保持与开源社区的同步。重点增强了Dataproc Serverless for Spark的特性支持。

微软云的Azure HDInsight是面向企业的云中托管、全方位的开源分析服务，包括Apache Hadoop、Spark、Hive和Kafka等。凭借Azure的全球规模，可轻松处理海量数据并享受广泛的开源项目生态系统的所有优势。2023 年 2 月 Azure HDInsight 发布 5.1 版本，主要是对开源组件 Spark、Kafka、Hadoop、Ranger、HBase、Oozie、ZooKeeper等进行了升级，从HDInsight 5.1 版本开始停用 Sqoop和Pig加载项。2023年3月Azure HDInsight推出for Apache HBase 2.4.11公共预览版、for Apache Kafka 3.2.0公共预览版。2023年6月Azure HDInsight for Apache Spark 3.3提供公共预览版、HDInsight 群集中添加了增强的自动缩放功能。2023 年 8 月 Azure HDinsight Spark 2.4停止标准服务支持。

表1-1 头部云厂商开源大数据平台对比

厂家	开源大数据平台	开源组件	部署版本
阿里云	E-MapReduce（EMR）	Celeborn、ClickHouse、Delta Lake、DLF-Auth、Doris、Flink、Flink Table Store、Flume、Hadoop、Hive、Hudi、Hue、Iceberg、Impala、JindoData、Kafka、Kafka Manager、Kyuubi、OSS/OSS-HDFS、Paimon、Presto、Ranger、Spark、、Sqoop、StarRocks、Trino、PyTorch	阿里云公有云
华为云	云原生数据湖MRS	Alluxio、CarbonData、CDL、ClickHouse、DataLake Catelog、Flink、Flume、Hadoop、HetuEngine、Hive、Hudi、Impala、IoTDB、Kafka、KafkaManager、Kudu、OBS、Opentsdb、Presto、Ranger、Spark、Sqoop、Storm	华为云公有云、专有云、混合云

腾讯云	弹性 MapReduce（EMR）	Alluxio、COS、Doris、Flink、flume、Hadoop、HBase、Hive、Hudi、Iceberg、Impala、Kylin、Kyuubi、Kudu、Presto、Spark、StarRocks、Storm、Superset、TensorFlow、Trino、Zeppelin、Zookeeper	腾讯云公有云、专有云
Cloudera	CDP	Flink、Hadoop、HBase、Hive、Hue、Iceberg、Impala、Kafka、Kudu、NIFI、Solr、Spark、Sqoop、Zeppelin	公有云、私有云、混合云
GCP	Dataproc	Flink、Hadoop、HBase、Hive、Kafka、Spark、Sqoop、Cloud Storage、Druid、Hue、Presto、Solr、Zookeeper	公有云
亚马逊云	Amazon EMR	Amazon S3、Amazon DynamoDB、Delta、Druid、Flink、Hadoop、HBase、Hive、Hudi、Iceberg、Trino、Presto、Spark、Sqoop、TensorFlow	公有云
微软云	HDInsight	Spark、Hive、LLAP、Kafka、Hadoop 和 HBase	公有云

动态分析：

从目前全球头部大数据厂商的开源大数据平台能力来看，各厂商支持的开源组件趋同性更强，Flink、Spark、Hadoop、HBase、Hive、Kafka、Presto、Iceberg/Hudi/ Delta Lake 成为开源大数据平台的标配，平台整体能力趋同性也更加明显，能力主要涵盖数据开发、计算引擎、数据存储、中间件、数据集成、平台运维以及数据安全等。除微软云外，其余 6 个厂商的开源大数据平台均可运行在 K8s 集群之上。

各厂商不断从云原生、开源组件扩展升级、丰富生态系统、资源弹性伸缩、Serverless 和高效运维等方面完善开源大数据平台，提高竞争力，抢夺客户，竞争激烈。

Cloudera 和阿里云分别是国外和国内开源大数据平台的技术领域羊，其推出的开源大数据平台无论在支持的组件丰富程度、组件优化深度、开源跟随方面，还是在头部市场占有方面均依旧处于绝对领先地位，他们的动态值得持续关注。

另外，值得关注的一点是全球头部大数据厂商的开源大数据平台现在均不提供 Storm 组件，Storm 技术已处于暮年。

广联达私有化环境部署开源大数据平台：造价大数据平台采用 HDP3.1.5、技术中心的大数据平台采用 HDP3.1.4、流程与数字化部底层经营分析数据仓库采用 HDP3.1.5，HDP3.1.5 是目前可以获得到的最新版本。广联达公有云环境外采公有云开源大数据平台：数据中台阿里云采用 EMR-4.5.1，数据中台华为云采用 MRS

2.1.0，公有云开源大数据平台后续会逐渐过渡到广联达自研的大数据技术平台底座之上。

外部客户私有化部署开源大数据平台：深圳交易集团数字化规划实施一期项目采用 HDP3.1.5，北京建工采用华为云 MRS 2.1.0，广西建工采用 HDP 3.1.4.0。后续寻找合适时机替换为广联达自研的大数据技术平台。

针对十亿级别+和百万级 QPS+的海量数据的 OLAP 处理场景，广联达自研的大数据技术平台尚未经实际验证过，有待实际验证能否满足海量数据的数量场景，再决定是否替换和合适替换 Hadoop 体系。

信息来源：

[1]阿里云 E-MapReduce
https://www.aliyun.com/product/emapreduce?spm=5176.19720258.J_3207526240.33.e9392c4apZDOse
https://help.aliyun.com/document_detail/28070.html
https://help.aliyun.com/zh/emr/emr-on-ecs/product-overview/release-notes-1?spm=a2c4g.11186623.0.0.1f615505iWwhcS
[2]华为云云原生数据湖 MRS
https://www.huaweicloud.com/product/mrs.html
[3]腾讯云 EMR
https://cloud.tencent.com/product/emr
https://cloud.tencent.com/document/product/589/71286
https://cloud.tencent.com/document/product/589/34357
[4]Cloudera 数据平台 (CDP)
https://www.cloudera.com/products/cloudera-data-platform.html?tab=3
https://www.cloudera.com/legal/policies/support-lifecycle-policy.html
https://docs.cloudera.com/cdp-private-cloud/latest/index.html
[5]亚马逊云 EMR
https://aws.amazon.com/cn/emr/?nc=sn&loc=0
[6]谷歌云 dataproc
https://cloud.google.com/dataproc/docs/concepts/versioning/dataproc-release-2.0
https://cloud.google.com/dataproc/docs/release-notes
[7]微软云 HDInsight
https://azure.microsoft.com/zh-cn/products/hdinsight/

动态 2：国内外各头部大数据厂商持续丰富数据湖产品生态和能力，增强数据安全管理能力，满足细粒度的数据权限控制，降低数据湖使用成本，数据湖产品更加成熟，提升数据湖领域的竞争力。

动态内容：

阿里云数据湖构建（Data Lake Formation，简称DLF）作为云原生数据湖架构核心组成部分，帮助用户快速地构建云原生数据湖解决方案。数据湖构建提供湖上元数据统一管理、企业级权限控制，并无缝对接多种计算引擎，打破数据孤岛，数据入湖支持Delta Lake、Hudi、Iceberg。2022年6月发布生命周期管理，能方便地通过多种类型的规则管理数据湖里的数据生命周期，以节约存储成本。2022年7月DLF支持数据目录（Catalog），用于元数据隔离的场景。2022年10月，DLF支持元数据多个统计指标；发布数据湖权限控制，支持配置数据库、数据表、数据列、函数四种维度的权限；发布湖格式自动优化策略。2022年11月，发布Location托管与分析，可将OSS中的存储数据托管到数据湖构建（DLF）中进行管理和分析等；DLF支持数据目录（Calalog）级别设置权限设置开关。2023年3月数据湖构建（DLF）生命周期支持OSS-HDFS。2023年02月15日起数据湖构建（DLF）产品的数据入湖功能停止更新，阿里云建议推荐使用大数据开发治理平台 DataWorks的数据集成能力或 Flink CDC进行数据入湖。

华为云数据湖探索(Data Lake Insight,简称DLI)是完全兼容Apache Spark、Apache Flink、openLooKeng（基于Presto）生态，提供一站式的流处理、批处理、交互式分析的Serverless融合处理分析服务，支持数据入湖、数据仓库、BI、AI融合等能力。2022年10月新增DLI队列与公网打通方案。2022年12月，新增“创建跨源认证”、“创建路由”等跨源相关API；新增“创建作业模板”、“更新SQL模板”等相关API。2023年3月DLI库表支持标签管理。

腾讯云数据湖计算DLC（Data Lake Compute，DLC）提供敏捷高效的数据湖分析与计算服务。DLC服务采用无服务器架构（Serverless），开箱即用。使用标准SQL语法即可完成数据处理、多源数据联合计算等数据工作，有效降低数据分析服务搭建成本及使用成本，提高企业数据敏捷度。2022年07月到2023年7月，增强对Presto、Spark、SparkSQL支撑和性能；支持InLong实时入湖；支持Notebook和Hudi表；产品化Iceberg Upsert布隆过滤和分桶最佳实践；联邦查询分析新增数据源支持；优化数据引擎性能支持联邦PostgreSQL和数据计算过程加密；优化数据权限，支持行级权限；增加数据治理能力等。

AWS Lake Formation是2019年推出的一项服务，可以在几天内轻松建立安全的数据湖。使用Lake Formation创建数据湖很简单，只需定义数据源，制定要应用的访问和安全策略就行。Lake Formation从数据库和对象存储中收集并按目录

分类数据，将数据移动到新的 Amazon S3 数据湖，使用机器学习(ML)算法清理和分类数据，并对列、行和单元格进行精细控制以安全访问敏感数据。2022 年 12 月 Amazon SageMaker Studio 开始支持使用 AWS Lake Formation 和 Amazon EMR 进行精细数据访问控制；2023 年 2 月到 4 月，AWS Lake Formation 面向亚太地区（雅加达）、中东（阿联酋）、欧洲（苏黎世）、欧洲（西班牙）体推出服务。2023 年 6 月，AWS Lake Formation 和 Glue Data Catalog 开始支持跨区域表访问

动态分析：

国内外各头部大数据厂商持续丰富数据湖产品生态和能力，增强数据安全管理能力，满足细粒度的数据权限控制,进一步降低数据湖使用成本，数据湖产品更加成熟，提升数据湖领域的竞争力。国内外厂商继续深度整合自有的大数据产品，集成更多的大数据开源技术组件，紧密拥抱开源数据湖技术 Delta Lake 、Hudi、Iceberg，构建云原生、存算分离、湖仓一体和全托管是当前数据湖发展的主要方向。

亚马逊云和阿里云云原生数据湖产品依旧分别处于国外和国内同类产品的领先地位。

信息来源：

[1]阿里云数据湖构建 DLF
https://www.aliyun.com/product/bigdata/dlf?spm=5176.21211227.J_3207526240.97.5d6f123cm1zIxX
https://help.aliyun.com/document_detail/602499.html?spm=a2c4g.602497.0.0.1ab83afetwaHTh
[2]华为云数据湖探索 DLI
https://www.huaweicloud.com/product/dli.html
[3]腾讯云数据湖
https://cloud.tencent.com/product/dlc
[4]AWS Lake Formation 数据湖架构
https://aws.amazon.com/cn/lake-formation/?whats-new-cards.sort-by=item.additionalFields.postDateTime&whats-new-cards.sort-order=desc

1.2 友商大数据动态[袁小芬]

友商大数据动态扫描选取国内外上市企业且在建筑行业内最具领先的代表厂商—欧特克(Autodesk)、明源云、Procore、Bentley、国泰新点、品茗等，重点关注三个维度的动态：大数据产品发布、最佳实践成果、大数据应用。

动态 1：2022 年，明源云全面推进天际 PaaS 平台商业化，2022 年收入 2.04 亿；天际 PaaS 平台已形成完整的数字化生态体系，其中数芯平台提供数据分析和数据治理两大核心能力；低代码和国产化出现在天际 PaaS 平台的核心技术理念中。

动态内容：

目前明源云已经形成了一套完整的数字化生态体系，包括企业工作台，开发套装，集成套装，流程套装，数据套装和创新实验室。其中数据套装又名数芯平台，提供汇聚和治理企业主数据，打造数据资产，内置行业化指标体系，提供分场景的数据模型和数据应用，同时提供可视的数据自主分析能力。数芯平台主要包括两部分：数据分析平台和数据资产管理平台。数据分析平台以行业的最佳实践辅助企业分析决策。数据资产管理平台提供一站式的高效易用的数据资产构建和管理能力。数芯平台的核心理念是：分区治理，分区入湖；以更快更好的构建数据资产，最大程度的挖掘数据价值。

此外，在天际 PaaS 平台的技术理念中倡导零代码/低代码和国产化的内容，并作为核心理念的两个要点。零代码、低代码的价值在于为企业提供更加本地化的服务和更好的创新应用环境；而国产化则以安全合规，自主可控为主要卖点。

业绩上，2022 年天际 PaaS 平台取得突破，全面推进商业化落地，实现收入 2.04 亿元（2021 年 0.19 亿元），服务客户累计超过 1900 个。目前天际集成套装累计集成系统超过 3200 个，沉淀了 60 个不动产行业技术伙伴连接器。通过“繁星计划”累计覆盖超过 2200 名实施顾问和客户 IT 人员。

动态分析：

天际 PaaS 平台的数据套装包括数据分析平台和数据资产管理平台。跟广联达大数据开发平台+数据分析平台+GDE 模式非常类似，启示我们需要在数据分析平台的产品化和场景沉淀上（按客群沉淀）加快步伐。

安全合规，自主可控，软件国产化已势在必行，在广联达的许多政府项目中已经有了明确的国产化要求。但目前国产软件，包括操作系统、数据库和其他中间件等正处在一个百花争放的阶段，广联达软件对于国产化兼容选型建议保持中立态度，重点关注一些成熟软件，例如：国密算法、中标麒麟操作系统、达梦数据库、人大金仓数据库等。

低代码技术是释放数据价值，支持应用创新的有效手段。在数据分析应用和数据可视化上需要加大低代码能力构建。

信息来源：

[1]《明源云集团控股有限公司 2022 年报》
https://data.eastmoney.com/notices/detail/00909/AN202304241585770961.html
[2]明源云·天际 PaaS 平台
https://open.mingyuanyun.com/
[3]明源云研究报告：不动产生态链 SaaS 龙头，天际 PaaS 平台构建长期竞争优势
https://caifuhao.eastmoney.com/news/20230728135331681683750
[4]明源云天际 PaaS 平台亮相中国信息港论坛 展示助力不动产数字化成果
https://it.sohu.com/a/692500848_121103172

动态 2：Autodesk 的 Autodesk Platform Services（简称 APS，以前为 Forge）越来越成熟，在数据共享方面，丰富了 APS Data 的 API。

动态内容：

Autodesk Converge 2022 峰会，欧特克公司大中华区总经理孙志伟发表了主题为《数字·融合·新可能》的演讲，特地强调了融合理念。孙总在现场分享了中钢集团、瑞云技术、江苏园博园、中建集团等案例，充分展示了欧特克解决方案及服务等产品组合在流程融合、技术融合、数据融合和行业融合这四个层次上的成功运用。

Forge 平台提供 Autodesk 产品中建筑、工程、制造及多媒体等行业服务功能进行数据传递，包含的模块有：查看器(Viewer)、数据管理 API、模型产生 API 和设计自动化 API。

欧特克开发者双享日于 2023 年 4 月 20-21 日在北京举行，Autodesk Developer Day 主题为“加速生态繁荣，欧特克平台技术 APS 推动数字化变革和全球创新应用分享”，介绍了欧特克平台技术 APS、行业数字变革新引擎、APS Data 技术及欧特克施工云服务最新 API 动态等。

动态分析：

欧特克通过 Data Management 数据管理 API 为跨团队跨应用提供统一的数据访问方式，通用云环境 Autodesk Docs 管理共享数据，同时通过 Data Visualization Extension 提供可视化扩展，融入到数字孪生的解决方案里。

数据服务 API 化值得借鉴，应用端无缝衔接，并能直接获得数据服务。我们现在数据中台+GDE 的模式再往前一步，把数据服务化，开放到 API 市场。

信息来源：

[1]Autodesk Converge 2022 峰会：数字化“融合”赋能先进生产力
https://baijiahao.baidu.com/s?id=1750444497660295290&wfr=spider&for=pc
[2]Autodesk Forge 包括哪些模块？有什么功能？
https://www.ruanfujia.com/10678241/
[3]Data Management API
https://aps.autodesk.com/en/docs/data/v2/developers_guide/overview/
[4]Data Visualization Extension
https://aps.autodesk.com/en/docs/dataviz/v1/developers_guide/overview/
[5]Data Exchange
https://aps.autodesk.com/developer/overview/data-exchange
https://aps.autodesk.com/developer/documentation
[6]欧特克开发者双享日于 4 月 20-21 日在北京举行
https://baijiahao.baidu.com/s?id=1764024582028567329&wfr=spider&for=pc

1.3 垂直行业标杆企业动态[袁小芬]

垂直行业标杆企业大数据动态扫描选取国内外数字化转型成功或者大数据最具领 先的代表厂商—贝壳、Salesforce、用友、金蝶、新中大（PM）等，关注其大数据产品动态、最佳实践成果。

动态 1：2022 年 Salesforce 推出超大规模的实时数据平台 Salesforce Genie，能将公司所有不同系统，不同交互终端的客户数据统一起来分析；2023 年 8 月 24 日，Salesforce 发布了 AI 支持的现场服务创新，包含功能“Data Cloud 主动式服务”。

动态 2：用友、金蝶等各行业标杆企业都不约而同的选择与 AI 服务提供商合作，开启企业创新发展的新阶段。

动态内容：

2022 年 9 月 20 日，Salesforce 正式宣布推出 Salesforce Genie。Genie 被称为 Salesforce 公司史上最伟大的创新，为实时交付的高度个性化客户体验铺平了道路。Genie 是一个超大规模的实时数据平台，能将公司所有不同系统，不同交互终端的客户数据统一起来分析，让组织能实时了解客户需求，为客户提供更好的体验。Genie 跨越整个 Salesforce 平台（Customer 360），数据从组织拥有的所有数据源进行整理，可用于推动销售、服务、营销、商务、MuleSoft、Tableau 等

领域的任何行动或洞察。Genie 可大规模接收和存储实时数据流，并将其与 Salesforce 数据相结合。Genie 使用 Salesforce 元数据模型，它可以利用 Einstein 进行实时预测。Einstein 引擎每天大概会进行 175 次账单预测。

2023 年 8 月 24 日，Salesforce 发布了 AI 支持的现场服务创新，其中包含功能“Data Cloud 主动式服务”，Data Cloud 主动式服务结合了客户及其资产的统一视图，包括客户购买详情、服务历史记录和关于机器健康状况的物联网信号，所有这些都是实时和大规模的。有了这些统一的数据，Einstein 可以自动安排服务预约和工作持续时间、所需的必要零件或工具以及合适的技术人员。

用友 BIP 接入百度文心一言能力后，结合用友长期深耕企业数智化服务的技术沉淀和领先实践，共同推动企业与公共组织在企业知识管理、低代码开发、流程智能化等子领域的数智商业创新。目前，用友 BIP 已建立了 2300 多个企业服务应用模型、开发超过 70 个 AI 算法、提供数百个场景化机器人模板，在财务、人力、采购、制造、营销等众多领域提供了超过 300 个数智应用服务，帮助企业建立展现级、分析级、控制级、决策级、创新级的全面数智能力。

2023 年 5 月，由金蝶自研的企业级可组装 PaaS 平台——金蝶云·苍穹，官宣成为百度文心一言（生成式对话 AI）先行体验官，以期优势互补，共同为企业用户打造更可靠敏捷、智能开放的服务。接入文心一言后，借助业内领先的智能对话技术，金蝶云·苍穹能进一步提升信息获取和整合、数据洞察、决策分析能力，让企业用户享受更加智能便捷、精确高效的人财税管理、业务分析、决策支持等服务，加速转型发展。

动态分析：

在垂直标杆领域，各行业标杆企业都不约而同的选择与 AI 服务提供商合作，开启企业创新发展的新阶段。借助 AI 能力为用户打造更可靠，更智能，更开放的服务能力。大数据技术是 AI 技术落地的关键支撑，AI 中台是数据中台的未来发展趋势。随着业务技术的发展，企业软件需围绕智能化服务为核心，这就依赖于数据中台提供的数据服务能力，而智能化的技术能力，又能够提供给数据更便捷的数据分析和预测能力，从而提供更好的数据服务。数据中台与 AI 是相互依存，共同提升的关系；建议广联达数据中台建设充分考虑对 AI 技术的支撑场景，助力 AI 技术能力在建筑领域创新落地。

信息来源：

[1].Salesforce 宣布推出 Einstein GPT
https://www.salesforce.com/news/press-releases/2023/03/07/einstein-generative-ai/
[2].用友 BIP 接入百度文心一言 持续使能企业数智商业创新
https://www.yonyoufintech.com/news/detail/id/783.html
[3].金蝶云·苍穹成为文心一言先行体验官
https://www.kingdee.com/article/1656573582995746818.html
[4].金蝶云苍穹 AI 服务云
https://www.kingdee.com/products/cosmic_ai_services.html
[5] 必看，最新最全版 Salesforce 产品指南
https://baijiahao.baidu.com/s?id=1757891567631332920&wfr=spider&for=pc
[6] 必看，Salesforce Field Service 新功能上线啦！
https://baijiahao.baidu.com/s?id=1776909700214519438
[7] Salesforce 在 2023 年 Gartner 数字商务魔力象限中被评为“领导者”
https://baijiahao.baidu.com/s?id=1776180240883627753

2 大数据技术

本章动态扫描大数据 10 大技术维度的产品或技术的重要动态，考虑到广联达的大数据应用产品或解决方案既要满足公有云部署要求，同时也需具备私有化部署能力，因此本次动态扫描的重点是开源的大数据技术，特别是广联达目前正在使用或高度相关的大数据技术，商业化的大数据产品和技术不作为扫描重点。大数据技术的 10 个维度依次是大数据的软件架构、数据存储、数据计算与分析、集群资源管理、大数据中间件、数据集成、大数据开发、数据治理、数据运维和数据安全。

2.1 大数据软件架构技术[袁小芬]

大数据软件架构技术从两个维度进行扫描和关注动态：

（1）新的架构思想-关注动态及架构落地的最佳实践和产品；

（2）成熟架构思想（Lambda、Kappa、Unifield、IOTA）—关注架构能力（功能）的变化、架构组件的变化。

动态 1：Data Fabric 作为一种数据管理设计模式，继续受到行业关注，微软、Talend、Denodo 等企业持续发布或更新其产品，探索最佳实践。

动态内容：

数据编织(Data Fabric)是一种全面的数据管理和集成方法，它使用一组技术组件来管理、集成和处理来自不同数据源的数据，以便组织可以更好地理解和利用这些数据。

Gartner 在 2023 年 5 月公布了 2023 年十大数据和分析（D&A）趋势，其中提

到趋势之一：Practical Data Fabric。Data Fabric 是一种数据管理设计模式，利用所有类型的元数据来观察、分析和推荐数据管理解决方案。Data Fabric 通过组装和丰富底层数据的语义，对元数据应用持续分析，以生成警报和建议，让人类和系统可以用于采取行动。Data Fabric 让业务用户能够自信地使用数据，并促进技能较低的全民开发人员在集成和建模过程中变得更加灵活。

微软在 2023 年 5 月召开的 Build 2023 开发者大会上，宣布推出数据分析平台 Microsoft Fabric，加速从微软的 OneLake 数据湖（data lake）、亚马逊 S3 和 Google Cloud 中提取数据。该平台汇集了所有构建 AI 所需的数据和分析工具：据微软称，Microsoft Fabric 将用一个更简单、更易于管理且具有成本效益的集成平台,取代分散的系统，供希望构建 AI 并将其集成到技术堆栈中的企业所使用。Microsoft Fabric 平台把数据专业人员所需的所有工具捆绑在一个地方，包括数据集成、数据工程、数据仓库、数据科学、实时分析、应用可观察性和商业智能。

数据集成和管理提供商 Talend 更新了 Talend Data Fabric（这是用于数据发现、转换、治理和共享的端到端平台）。在 Winter ’23 版本中，Talend 引入了先进的功能和增强功能，以简化和自动化云迁移和数据管理，扩展数据连接，并提高数据可见性、质量、控制和访问。

Denodo 平台具备构建逻辑数据编织所需的全部功能，是业界唯一可同时进行数据集成和管理的平台。得益于数据虚拟化，Denodo 平台具备以下功能：

●通用语义层，可以更快地向业务部门公开数据；

●动态数据目录，可用于语义搜索和企业级的数据治理；

●行业领先的查询加速，由机器学习提供支持；

●通自动化基础架构管理，可用于多云和混合云场景；

●嵌入式数据准备功能，可用于自助服务分析、更快地获取洞察、改善隐私和合规性、提高数据管理流程的自动化程度以及避免供应商锁定。

Aloudata 发布了白皮书《Data Fabric 面向未来的数据管理架构》。阐述为什么 Data Fabric 是企业数据管理的未来，并介绍如何通过 Aloudata NoETL 湖仓平台快速落地 Data Fabric 数据架构，加快释放企业数据价值。

动态分析：

随着数据的不断增多和使用场景的日益丰富，特别是 AI 场景的结合，组织在不同的环境和数据源之间管理、集成、处理和访问数据的需求越来越强烈，多领域数据技术的整合使用是大势所趋。需要持续关注 Data Fabric 理念的发展和落地

实践，新的技术理论层出不穷，Data Fabric 的概念也会面临更新与调整。

微软的 Fabric 实践之路值得关注和借鉴。产品层面，微软通过单一体验和专项 SaaS 产品（非 PaaS）模式，为用户提供单一的窗口来查看和管理数据（安全、治理、集成、发现），大大提高了数据的一致性和可信度。技术层面，微软通过一个名为 OneLake 的数据湖简化和统一其数据架构的方式：OneLake 以 Apache Parquet 的通用格式存储来自微软公司各种服务的所有数据的单一副本；同时，OneLake 的简洁性和统一性也延伸到了微软生态系统之外的数据，OneLake 以 Delta Lake 的开源格式存储其数据表，该格式创建了一层元数据，可将来自各种来源(例如 CSV 或 JSON 文件)的原始数据转换为可被业内任何计算引擎分析的通用格式。

信息来源：

[1] Gartner 发布 2023 年十大数据和分析趋势
https://baijiahao.baidu.com/s?id=1765702099921616083&wfr=spider&for=pc
https://new.qq.com/rain/a/20230518A09SE000
[2] 微软推出 Fabric 数据分析平台，帮企业在 AI 时代洞察数据
https://baijiahao.baidu.com/s?id=1767325600417529359&wfr=spider&for=pc
[3] 帮专家洞察数据，微软推出端到端统一分析平台 Fabric
https://roll.sohu.com/a/678306956_114760
[4] 微软推出 Microsoft Fabric，计划在云计算市场击败亚马逊和谷歌
https://baijiahao.baidu.com/s?id=1768206341154000793&wfr=spider&for=pc
[5]Talend’s Winter’23 Data Fabric Release Powers Modern Data Management
https://www.dbta.com/Editorial/News-Flashes/Talends-Winter-23-Data-Fabric-Release-Powers-Modern-Data-Management-157377.aspx
[6] Denodo 企业版 借助 Denodo 平台，加速逻辑数据编织之旅的进程
https://www.dkmeco.com/products/denodo/standard
[7] 数据编织(Data Fabric)的核心组成技术
https://zhuanlan.zhihu.com/p/620355356
[8] 一文看懂数据编织（Data Fabric）
https://it.sohu.com/a/690426881_121124377
[9] 《超越技术：利用 Data Mesh 创造业务价值》
https://www.thoughtworks.com/content/dam/thoughtworks/documents/whitepaper/tw_whitepaper_hbr_beyond_technology_cn.pdf
[10] 数据架构最新趋势：Data Fabric 和 Data Mesh
https://blog.csdn.net/weixin_39971741/article/details/126281681

动态 2： Lakehouse（数据湖仓一体）架构:数据湖技术日趋成熟，湖仓一体技术成熟期缩短，期望值升高，各云厂商集成开源数据数据湖组件，强化湖仓一体能力。

动态内容：

ThoughtWorks：在 2023 年 4 月发布的技术雷达中，将 Lakehouse 架构归入到技术象限的试验环里（ThoughtWorks 对“试验”阶段的技术的建议是：“值得一试，了解为何要构建这一能力是很重要的。企业应当在风险可控的前提下在项目中尝试应用此项技术。”）。Lakehouse（数据湖仓一体）架构是一种数据湖的可扩展性与数据仓库可靠性和性能相结合的架构风格，它使得组织能在一个平台上使用类似于 SQL 的工具和技术，储存分析大量不同的数据，而不是将他们放在单独的在数据湖和数据仓库层中。

大数据技术标准推进委员会：于 2023 年 6 月发布《湖仓一体技术与产业研究报告(2023 年)》。阐述湖仓一体是指融合数据湖与数据仓库的优势，形成一体化、开放式数据处理平台的技术。通过湖仓一体技术，可使得数据处理平台底层支持多数据类型统一存储，实现数据在数据湖、数据仓库之间无缝调度和管理，并使得上层通过统一接口进行访问查询和分析。

阿里云：推出基于云原生技术的企业级数据湖体系，该体系由数据湖对象存储 OSS、云原生数据湖分析 DLA、数据湖构建 DLF、E-MapReduce、DataWorks 等产品强强组合，在存储与计算分离架构下，提供“湖存储”、“湖加速”、“湖管理”、“湖计算”的企业级数据湖解决方案。其中数据湖构建 Data Lake Formation 近一年内重大更新 6 次；DataWorks 基于阿里云 ODPS/EMR/CDP 等大数据引擎，为数据仓库/数据湖/湖仓一体等解决方案提供统一的全链路大数据开发治理平台；实时数仓 Hologres 近一年更新频繁：数据湖加速支持 OSS-HDFS、共享集群支持数据湖加速、Hologres 基于 Delta Lake 实现湖仓一体。

华为云：数据湖探索 DLI 是完全兼容 Apache Spark、Apache Flink、openLooKeng（基于 Presto）生态，提供一站式的流处理、批处理、交互式分析的 Serverless 融合处理分析服务，支持数据入湖、数据仓库、BI、AI 融合等能力。DLI 近一年重大更新 12 次；MapReduce 服务 MRS 于 2022 年 12 月支持 Hudi 数据湖组件。

腾讯云数据湖分析依托于腾讯云原生技术，提供云端数据湖构建与分析服务，覆盖数据入湖构建、元数据管理、湖数据敏捷分析等全链路能力。包含：数据湖计算 DLC（Data Lake Compute，DLC）提供了敏捷高效的数据湖分析与计算服务。服务采用无服务器架构（Serverless），开箱即用。

ThoughtWorks 在 2023 年 4 月发布的技术雷达中，将 Apache Hudi 归入到技术象限的试验环里。Apache Hudi 是一款开源数据湖平台，它将 ACID 事务保障引入

了数据湖中。Hudi 在大数据量高吞吐量场景下使用进行实时写入和更新数据有非常理想的效果；Hudi 对定制压缩算法的支持很灵活，这有助于解决“小文件”读写的问题。

ThoughtWorks 在 2022 年 10 月发布的技术雷达中，将 Delta Lake 归入到技术象限的采纳环里（ThoughtWorks 对“采纳”阶段的技术的建议是：强烈建议业界采用这些技术）。Delta Lake 是由 Databricks 实现的开源存储层，旨在将 ACID 事务处理引入到大数据处理中。

ThoughtWorks 在 2022 年 3 月发布的技术雷达中，将 Apache Iceberg 归入到技术象限的评估环里（ThoughtWorks 对“评估”阶段的技术的建议是：在了解它将对你的企业产生什么影响的前提下值得探索）。Apache Iceberg 是一个面向超大的分析数据集的开放表格格式。Iceberg 支持现代数据分析操作，如条目级的插入、更新、删除、时间旅行查询、ACID 事务、隐藏式分区和完整模式演化。它支持多种底层文件存储格式，如 Apache Parquet、Apache ORC 和 Apache Avro。已有许多数据处理引擎支持 Apache Iceberg，包括一些 SQL 引擎，如 Dremio 和 Trino，以及（结构化）流处理引擎，如 Apache Spark 和 Apache Flink。

动态分析：

Lakehouse（数据湖仓一体）架构是一种数据湖的可扩展性与数据仓库可靠性和性能相结合的架构风格，它使得组织能在一个平台上使用类似于 SQL 的工具和技术，储存分析大量不同的数据。通过湖仓一体技术，可使得数据处理平台底层支持多数据类型统一存储，实现数据在数据湖、数据仓库之间无缝调度和管理，并使得上层通过统一接口进行访问查询和分析。像 Delta Lake，Apache Iceberg 和 Apache Hudi 之类的开源数据湖框架趋于成熟，各云厂商结合开源方案积极构建自己的湖仓一体化平台，并且 Lakehouse 架构可以补充数据网格的实现。

信息来源：

[1] Thoughtworks 的技术雷达第 27 期
https://www.thoughtworks.com/content/dam/thoughtworks/documents/radar/2022/10/tr_technology_radar_vol_27_cn.pdf
[2] Thoughtworks 的技术雷达第 28 期
https://www.thoughtworks.com/content/dam/thoughtworks/documents/radar/2023/04/tr_technology_radar_vol_28_cn.pdf
[3]《湖仓一体技术与产业研究报告(2023 年)》
https://www.doc88.com/p-59599232279671.html
[4] 数据湖构建 Data Lake Formation
https://www.aliyun.com/product/bigdata/dlf?spm=5176.55536.J_3207526240.34.36b96bf681h62k

[5] 数据湖探索 DLI
https://www.huaweicloud.com/product/dli.html
[6] 数据湖计算 DLC
https://cloud.tencent.com/product/dlc

动态 3：数联网成为互联网之上实现可信可管可控的数据互联互通和大数据应用的核心技术,数字对象架构（DOA）是当前最有影响力的数联网技术路线。

动态内容：

在大数据开放流通方面，数联网成为互联网之上实现可信可管可控的数据互联互通和大数据应用的核心技术。数联网是基于软件定义的，将各种异构数据平台和系统连接起来，在“物理/机器”互联网之上形成的“虚拟/数据”网络，它正在世界范围内发展成为大数据时代的一种新型信息基础设施。

2022 年 11 月 9 日，2022 年世界互联网大会“世界互联网领先科技成果发布活动”上，北京大学计算机学院黄罡教授团队主持研发的“基于数字对象架构的数联网及大数据互操作技术”入选世界互联网领先科技成果。

中国科学院院士梅宏 2023 年 7 月 5 日在全球数字经济大会主论坛上表示，数联网将成为数字化时代的新型信息基础设施。他认为，大数据技术未来的发展趋势是，数据与应用进一步分离，以促进数据要素化。数据将不再依赖具体的业务场景，而是以独立形态存在于数据库中，通过数据服务向不同的业务场景提供服务。

2023 年 4 月 14 日，中国移动正式发布数联网（DSSN），受到业界广泛关注。这是国家宣布组建国家数据局以来，基础运营商发布的首张面向数据要素服务的专业网，也是中国移动继物联网、车联网之后，另一张全新网络。数联网基于按需接入、算网筑底、安全共享、开放合作、可管可控的原则，打造可信的数算一体化服务网络，实现五大目标——数据就近接入、广覆盖流通网络、可信数据交付、安全可管可控、全程合规可证。

信息来源：

[1] 信通院-大数据技术前瞻
http://www.infocomm-journal.com/bdr/article/2023/2096-0271/2096-0271-9-1-00001.shtml
[2] 梅宏院士“五问”大数据
https://baijiahao.baidu.com/s?id=1770575250504121531&wfr=spider&for=pc
[3] 中国科学院院士梅宏：数联网将成为数字化时代的新型信息基础设施
https://baijiahao.baidu.com/s?id=1770568812414496789&wfr=spider&for=pc
[4] 行业观察 | 盘点 2023 全球数字经济大会嘉宾精彩建言
http://t.10jqka.com.cn/pid_297071362.shtml
[5] 重磅：“数联网”来了（附白皮书）
https://baijiahao.baidu.com/s?id=1763562961652869700&wfr=spider&for=pc

[6] 数据空间基础设施的技术挑战及数联网解决方案
https://baijiahao.baidu.com/s?id=1768491113854144221&wfr=spider&for=pc
[7] 北大这项研究，入选世界互联网领先科技成果！
https://m.thepaper.cn/baijiahao_21285073

2.2 数据存储技术[刘松]

2.2.1 Serverless 云数仓

动态 1：数据仓库上云成为大数据领域发展的新趋势，逐步向云原生化、平台化、一体化、智能化方向发展；存算分离、数据湖、Serverless 特性的新范式数据仓库百花齐放

动态内容：

2022 年以来，数据库迁移上云态势显著提速，相较传统部署的数据库而言，云原生数据库通过存储计算分离，实现资源池化和弹性，具备高扩展性、高可用性、低成本等优势。近年来，云原生数据库在存算分离架构基础上，引入 Serverless 技术，具备智能弹性扩容能力，能够随着用户业务的请求数的增加和减少，自动“膨胀”和“缩小”，实现资源的智能“吞吐”。智能弹性技术的引入，为用户带来更经济的计费模式和更无感的扩容体验，成为云原生数据库技术新趋势。资源池化方面，随着 RDMA 高速网络和新型内存技术普及，在同一数据中心内，计算、内存和存储资源的三层解耦逐渐从理论走向实际，成为云原生数据库资源管理的新趋势。

Databend 是一款使用 Rust 研发，完全面向云架构，基于对象存储构建的云原生数仓。Databend Cloud 是基于 Databend 实现上的云原生数仓 SAAS 产品，提供的一站式 SaaS 云数据平台，免安装、免运维，注册账号即可使用，按 SQL 查询按需按量付费，真正做到使用才付费，不查询不使用不付费的特点。

Databend Cloud 已上架阿里云和腾讯云市场。

2023 年 4 月，StarRocks 3.0 版本正式发布，正式开启了 StarRocks 极速统一的新篇章。从 OLAP 到 Lakehouse，从存算一体到存算分离，从 ETL 到 ELT，经过两个大版本后 StarRocks 为用户创造极速统一的数据分析新范式。StarRocks 3.0 版本主要升级了存算分离架构，BE 节点升级为无状态的 Compute Node（CN）节点，数据存储从本地存储升级为共享存储，例如采用 S3 或者 HDFS 来存储数据，以提高系统的可扩展性和降低成本。此外，该版本还引入了湖仓融合的概念，旨在为用户提供一站式的 Lakehouse 产品能力。

2023 年 7 月 Apache Doris2.0-beta 版本正式发布，带来全新的查询优化器、

自适应的 pipeline 引擎、多租户资源的逻辑隔离和物理隔离、Schema 演进、极致弹性与存算分离、更全面、更高性能的数据湖分析、CCR 跨集群数据同步、K8S 容器化部署等能力。

动态分析：

Serverless 云数仓必备的条件是存算分离，存算分离让计算和存储资源更容易弹性伸缩，同时也对计算效率产生影响。两个动态，代表着两种做法：

1. 阿里云借助自己深厚的技术积累，通过软硬件结合的方式，把计算、内存和存储资源三层解耦，实现存算分离的同时，计算效率也有所保证。计算效率的优化，使得一个数据库覆盖所有的工作负载成为可能，数据将不再需要耗费资源实时集成至数仓，而是基于同一个数据库计算分析。但该方案会让用户有云锁定担忧。

2. DatabendCloud 基于开源的 Databend 实现，底层存储使用云存储，资源管理使用 Kubenetes，该实现方案计算效率上肯定没有阿里云软硬结合的方案好，但是它更开放，能借助社区的力量发展更快。

目前广联达数据中台使用的存算分离方案为：对象存储+开源的计算引擎（Spark 和 Flink），该方案的特点是可支持更复杂的分析场景（SQL 解决不了的场景），但多个开源组件的组合会提升整个数仓的复杂性。后续可持续关注 Databend 在稳定性、效率和复杂分析场景的发展。

信息来源：

[1] 中国信通院云大所联合阿里云发布《Serverless 数据库技术研究报告》
[2] 面向未来，阿里云数据库将整体向“四化”方向发展
[3] 云上数据变革：Databend Cloud 正式发布 - 知乎
[4] Databend Cloud 平台的 Serverless 架构实践 - 知乎
[5] 祝贺！Databend Cloud 和腾讯云达成合作 - 知乎

2.2.2 数据湖

动态 1：随着数据湖技术在各行业的应用逐步加深，目前主流的数据湖技术 Iceberg、Hudi、Delta 都是面向 Batch 模式设计的，无法满足实时场景的诉求，流式数据湖存储逐渐兴起。

动态内容：

2023 年 3 月 Flink Table Store 项目顺利通过投票，正式进入 Apache 软件基金会(ASF)的孵化器，改名为 Apache Paimon(incubating)。随着 Apache Flink 技术社区的不断成熟和发展，越来越多企业开始利用 Flink 进行流式数据处理，从而提升数据时效性价值，获取业务实时化效果。与此同时，在大数据领域湖仓一体

架构也日益成为新的技术趋势，越来越多企业开始采用 Lakehouse 架构，基于 DataLake 构建新一代 Data Warehouse。因此，Flink 社区希望能够将 Flink 的 Streaming 实时计算能力和 Lakehouse 新架构优势进一步结合，推出新一代的 Streaming Lakehouse 技术，促进数据在数据湖上真正实时流动起来，并为用户提供实时离线一体化的开发体验。

目前业界主流数据湖存储格式项目都是面向 Batch 场景设计的，在数据更新处理时效性上无法满足 Streaming Lakehouse 的需求，因此 Flink 社区在一年多前内部孵化了 Flink Table Store（简称 FTS）子项目，一个真正面向 Streaming 以及 Realtime 的数据湖存储项目，截止目前已经发布了 3 个版本，并得到了大量用户的积极反馈和多家公司的积极贡献。为了让 Flink Table Store 能够有更大的发展空间和生态体系，Flink PMC 经过讨论决定将其捐赠 ASF 进行独立孵化。

截止目前，包括阿里云，字节跳动、Confluent、同程旅行、Bilibili 等多家公司参与到 Apache Paimon 的贡献，未来希望能够有更多对新一代流式数据湖存储感兴趣的开发者加入 Paimon 社区，一起打造新一代的流式湖仓新架构。

动态分析：

目前广联达数据中台数据湖的基础设施选型，是基于 paimon 构建，本质原因是 Iceberg、Hudi、Delta 都是为了解决传统离线数仓在查询性能、流式 scan 数据、元数据的性能问题，实质还是在基于原有的批处理模式在优化。从技术本质上来讲，无法真正做到流批统一的数据湖新范式，从业务的角度上来讲，业务满足秒级数据协同的诉求。当下，广联达数据中台基于 paimon 构建的数据湖，已经支持了 GDE 整库实时入湖，原始层到标准层的实时计算，实时数据变更等多种场景，随着 GDE 场景持续深入，持续打磨数据湖能力，能力成熟之后，集团对外交付会全面推广。

信息来源：

[1] 阿里云
https://developer.aliyun.com/article/1284020
[2] 知乎
https://zhuanlan.zhihu.com/p/646325692
[3] 阿里云
https://developer.aliyun.com/article/1180963

2.3 数据计算与分析[姜建卫]

本节扫描范围涵盖大数据计算与分析的流计算框架、批计算框架、查询分析框架、图计算框架、空间数据计算框架、机器学习计算框架、统一计算引擎、检索分析引擎、作业调度与资源管理等 9 个类别，其中主流的批计算框架和空间数据计算框架截止 2022 年 7 月底无重要动态，本报告中不予表述。

2.3.1流计算框架

动态 1：Flink 目前已经成为流处理领域的主角和事实标准，是大数据流处理领域毫无争议的王者。广联达业务平台、技术中心和各个产品线均采用 Flink 作为流处理

动态内容：

ApacheCon 2023 亚洲流处理分会场的主角是 Aapche Flink，占据 7/11 的演讲案例。

2022 年 11 月 Flink Forward Asia 上，首次提出了以云原生、流批融合、自适应为核心的 Flink Shuffle 3.0 架构。新的 Shuffle 架构具有以下优势：更加适应云原生环境的资源编排与隔离特点；兼具传统流式与批式 Shuffle 技术的优势；能够根据运行时的资源与负载情况做出自适应调节，更加易用。上面的内容同时来自于阿里云在 ApacheCon 2023 上的案例“APACHE FLINK 流批自适应 SHUFFLE”。

2023 年 8 月，ApacheCon 2023 亚洲流处理分会场上，案例 1：来自杭州数澜科技的“FLINKSQL 的字段血缘及数据权限解决方案”、案例 2：来自易趣的“流式 APACHE KUDU 在 APACHE FLINK”、案例 3：来自阿里云的“阿里云基于 FLINK CDC 的实时数据集成实践”、案例 4：来自 Apache Flink/Streampark Contributor 的“FLINK K8S OPERATOR AUTOSCALING”、案例 5：来自 Ververica 的“APACHE FLINK 中 SCALA API 的状态”、案例 6：来自小米的“小米 FLINK 实时计算平台的建设实践”。

从 2022 年 8 月 1 日到 2023 年 8 月 27 日，Flink 先后发布了 release-1.15.2 到 release-1.17.1 九个版本。

Google 探索数据显示，当前搜索最多的是 1.13 和 1.15 版本。

Apache Flink 继续快速发展，是 Apache 中最活跃的社区之一。截止到 2023 年 8 月 27 日，Flink 拥有 GitHub Star 21.6K、Fork 12.5k、1160 名代码贡献者；截止 2022 年 7 月 26 日 Flink 拥有 GitHub Star 19.1k、Fork 10.8k、1011 名代码贡献者。

2022 年 10 月，发布 Flink1.16，该版本在 Checkpoint、SQL、Connector 和其他领域都进行了改进，从而确保 Flink 在流计算领域持续领先。

2023 年 3 月，发布 Flink 1.17，该版本解决了一些棘手的 Streaming SQL 语义和正确性问题，优化了 Checkpoint 性能，完善了 watermark 对齐机制，扩展了 Streaming FileSink，升级了 Calcite 和 FRocksDB 到更新的版本。这些提升进一步巩固了 Flink 在流处理领域的领先地位。

从 Flink1.16 开始，官方不再为 Java 8 提供预编译版本的 Flink。FLink1.17 版本中虽然继续支持 Java 8,但官方建议尽快升级到 Java 11 或更高版本。Flink1.18 计划支持 Java 17（LTS）。

动态分析：

流式数据处理是当今大数据领域的趋势，当下数字化转型期的企业渴望更及时地洞察自己的数据，而曾经的“批处理”思维正迅速被流式处理所取代。越来越多的公司，无论大小，都在重新思考技术架构时把实时性作为第一考量，并开始用强大的开源引擎如 Flink，Spark，Kafka，Pulsar，StreamPark，Paimon 等构建自己的实时计算平台。

Flink 目前已经成为流处理领域的主角和事实标准，流批统一的数据处理概念在越来越多的公司中得到认可，并在越来越多的公司中成功实施。Flink 提出 Flink-Streaming Warehouse（Streamhouse）的下一个发展方向，进一步升级了流批融合的范围：真正做到了不仅统一计算还统一存储，从而实现统一实时分析。

广联达的业务平台部、技术中心、流程与数字化部、高校 BU、集团服务业务部、成本大数据产品线等 6 个平台或产线，目前采用 Flink 来作为流处理框架，Flink 版本从 1.13 到 1.17 都有。仅国标成本产品线采用 Storm 做自积累数据智能组价实时分析。

信息来源：

[1]GitHub
https://github.com/apache/flink

https://github.com/apache/spark
[2]apachecon
https://apachecon.com/acasia2023/zh/tracks/streaming.html
[3]Goolge 趋势
https://trends.google.com/trends/explore?date=2021-01-01%202022-06-18&q=%2Fg%2F11btzy2gtf

动态 2：具备极浅学习曲线、低性能成本和维护成本的自带流计算能力的云原生存算分离的流数据库 Rising Wave 崭露头角，让流处理惠及更多的用户。对于极致性能成本要求的实时流处理场景，建议广联达尝试引入 Rising Wave。

动态内容：

Rising Wave 是一个分布式云原生流数据库，自带流计算能力，又支持数据持久化存储，并允许用户对存储的数据进行高并发查询，这使得用户可以使用 Rising Wave 这一单一系统来替代传统“流处理框架+数据库”组合（如 Flink+Cassandra 组合），从而高效方便的支持实时应用程序。RisingWave 既可以用作流处理系统，也可以用作数据库系统。

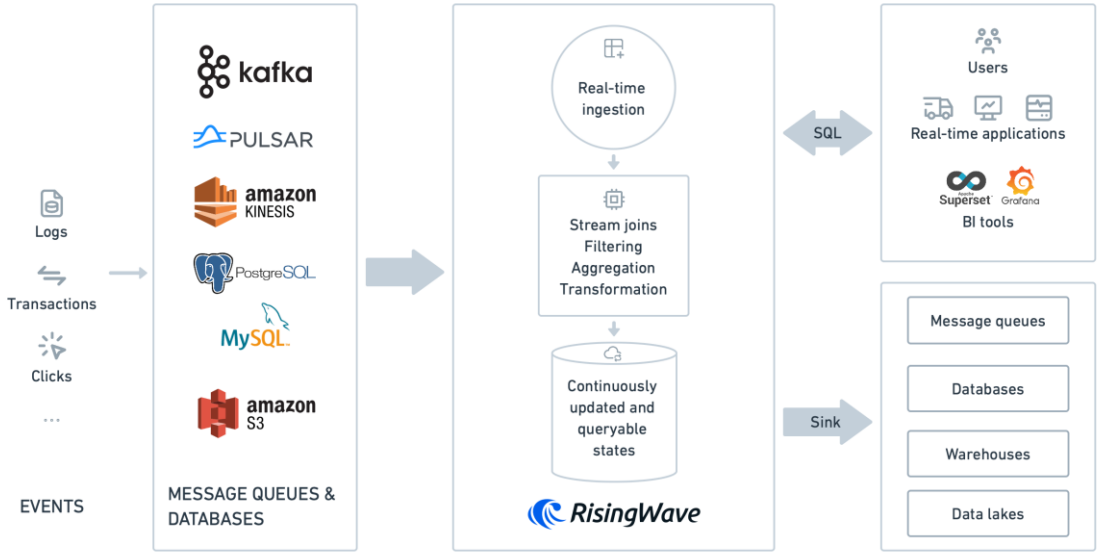

Rising Wave 支持和 Postgres 完全兼容的 SQL 协议，号称比 Flink 快 10 倍，并且更加经济实惠。

Rising Wave 采用 Rust 语言开发实现，采用存算分离架构，具有卓越的性能。根据标准的 Nexmark 基准测试，与 Apache Flink 相比，Rising Wave 在无状态计算方面可以获得 10-30%的性能提升；而在有状态计算方面，性能提升至多可达 660 倍。

DataFun Summit 2023 数据基础架构峰会的实时计算论坛的 6 场分享中，有 4 场跟 Flink 相关；1 场介绍云原生流数据库 Rising Wave。

Rising Wave2022 年 4 月 8 日正式在 GitHub 上以 Apache 2.0 协议开源，2023 年 7 月 12 日发布 1.0 正式版，目前在 GitHub 上拥有 4.8K 颗星标,134 名贡献者。还拥有近 2000 位微信中文社区群成员和 Slack 社区成员。Rising Wave 的研发团队已经为数十家企业部署到生产环境中，并且全球范围内可追踪的每日新增 Kubernetes 集群数已达到数百个。

动态分析：

RisingWave 是一种简单、经济高效、基于 SQL 的实时处理解决方案的不错的选择。RisingWave 设计易于使用且可快速部署，使其成为需要实时处理能力的快速增长企业的绝佳选择。

Flink 是一个更强大的编程框架，可以适应基于 JVM 的技术栈。Flink 允许用户编写复杂的程序，以便在机器集群上运行大规模的流处理，使其成为需要使用高级编程语言处理大量数据的用例的理想选择。

RisingWave 的目标并不在于取代现有 Flink 等计算框架，而在于用更简单更高效的方式让流处理普惠大众。正如批处理领域 Snowflake（SQL 数据库）与 Spark（大数据计算框架）所形成的互相促进的关系一样，RisingWave（SQL 数据库）也希望能与 Flink（大数据计算框架）一起推动流处理领域的发展。

Rising Wave 是作为分布式云原生流数据库，专注流处理场景，以简化流处理、降低开发运维门槛、提升性能为目标，后续发展值得期待。

广联达各部门广泛采用 Flink 来作为流处理框架。对于极致性能成本要求的实时流处理场景，建议尝试引入 Rising Wave。

信息来源：

[1]GitHub
https://github.com/risingwavelabs/risingwave
[2]infoq
https://xie.infoq.cn/article/2837b60512c5ad254949649d0
[3]Rising Wave官网
https://www.risingwave.com/

2.3.2查询分析框架

动态 1：Presto 和 SparkSQL 热度依然较高，社区活跃度高、更新频繁、支持的数据源种类多、使用者众多，成为查询分析引擎领域的首选。其他框架如 Impala、Druid 和 Kylin 日渐式微，不建议将它们作为新大数据应用的查询分析引擎。

动态内容：

从 Goole 全球趋势来看,SparkSQL 各方面的活跃度明显高于 Presto、Impala、Druid、Kylin，五者平均热度之比为 82:52:14:2:1,五者最近热度之比为 100:61:15:1:2，SparkSQL 和 Presto 热度保持在较高水平,Impala、Druid、Kylin 热度稳定地保持在较低水平；中国趋势上 SparkSQL、Presto、Impala、Druid、Kylin 五者的平均热度之比 51:43:8:4:8,五者热度变化起起伏伏交织在一起，SparkSQL、Presto 热度较高。

从 2022 年 8 月 1 日到 2023 年 8 月 27 日,Spark 先后发布了 v3.3.1 到 v3.3.3 六个版本。抽取 v3.4.1 版本和 v3.4.0 版本对比，共新增 89 个 commit，其中 Spark SQL 相关的 39 个，占比 43.8%，Spark SQL 在整个 Spark 的更新中占比较大。

Spark 继续快速发展，是 Apache 中最活跃的社区之一。截止到 2023 年 8 月 27 日，Spark 拥有 GitHub Star 36.2k，1961 名代码贡献者；去年 2022 年 7 月 30 日，Spark 拥有 GitHub Star 33.1k，1798 名代码贡献者。

从 2022 年 8 月 1 日到 2023 年 7 月 31 日，Presto 先后发布了 0.275 到 0.282 共 13 个版本。

截止 2023 年 7 月 31 日，Presto 拥有 GitHub Star 14.9k、653 名代码贡献者；截止 2022 年 7 月 31 日，Presto 拥有 GitHub Star 13.7k、587 名代码贡献者。

需要区分的是，Presto 以前有 PrestoDB 和 PrestoSQL 俩个分支。Presto 原本由 Facebook 运营,但 2019 年年初,Presto 团队的三位创始人离开了 Facebook。从此，Presto 项目被一分为二，由 Facebook 维护 PrestoDB，Martin、Dain、David 三位 Presto 项目最早的发起人维护 PrestoSQL，并于 2020 年 12 月 27 日将 PrestoSQL 更名为 Trino。

截止到 2023 年 8 月 27 日，Trino 拥有 GitHub Star 8.4k、679 名代码贡献者，从 2022 年 8 月 1 日到 2023 年 8 月 27 日，先后发布了 392 到 415 共 22 个版本。

2023 年 Trino 贡献者已超越 Presto。从 2022 年 9 月 4 日到 2023 年 8 月 27 日的 commit 数来看，Presto 在 10 到 50commits/week 的频率，Trino 在 40 到 180commits/week 的频率，Trino 更活跃。

总结分析：

Spark SQL 和 Presto 均是基于内存解析 SQL 生成执行计划，查询分析性能高，社区比较活跃、支持的数据源种类多、使用者众多，依然是查询分析引擎领域的首选。Trino 是 Presto 的另一个分支，GitHub Star 低于 Presto，但贡献者数量相当，代码提交更活跃。

广联达的业务平台部、房建 BIM、高校 BU 采用 Presto 作为联邦查询分析框架，主要应用于处理秒级查询的场景。广联达数据中台用 Kyuubi 替换 Linkis 后，因为 Kyuubi 原生不支持 Presto，将数据查询的底层框架从 Presto 换成了 Spark SQL。

信息来源：

[1] GitHub
https://github.com/apache/spark
https://github.com/prestodb/presto
https://github.com/trinodb/trino
https://github.com/trinodb/trino/graphs/commit-activity
https://github.com/prestodb/presto/graphs/commit-activity
[2]Spark SQL, Presto, Apache Impala, Apache Druid, Apache Kylin - 探索 - Google 趋势
https://trends.google.com/trends/explore?q=Spark%20SQL,%2Fg%2F11bywl5x_j,%2Fm%2F0whzky5,%2Fm%2F0_qlbpj,%2Fg%2F11cl1j0nn7
[3]Trino
https://trino.io/blog/2020/12/27/announcing-trino

2.3.3 图计算框架

动态 1：TinkerPop 依旧是目前应用最广泛开源图计算框架，生态庞大，相比其他图计算框架，保持了相对较高的热度；阿里开源的 GraphScope 发展相对较好；蚂蚁集团开源集存储、计算图数据一体的 TuGraph；头部厂商阿里云图计算服务更新缓慢，华为云图引擎服务更新频繁；图计算整体热度增长不大。随着未来图数据规模的持续增大，建议广联达采用开源图计算框架或者公有云图计算服务进行图数据的查询和分析，以满足大规模图数据的高性能查询和分析场景需求。

动态内容：

Apache TinkerPop 是一个适用于图数据库(OLTP)和图分析系统(OLAP)的图计算框架。TinkerPop 支持 Neo4j、ArangoDB、OrientDB、JanusGraph、HugeGraph、阿里 Graph Database、华为图引擎服务等多达 24 种流行图数据库和图分析系统的图计算。

相比其他图计算框架（Spark GraphX、Apache Giraph、Apache Hama），Apache TinkerPop 保持了较高的热度。

Spark GraphX 在 GitHub 上的 master 分支，最近更新时间为 1 年前；Apache Giraph 最新的 release 版本为 2014 年；Hama 对应 GitHub 仓库在 2020 年 10 月 26 日变为归档状态。TinkerPop 从 2022 年 8 月 1 日到 2023 年 7 月 31 日，先后发布了 3.5.5 到 3.6.4 共 5 版本，目前 GitHub Star 1.8K、170 名贡献者，但相比去年 7 月 30 日只新增了 0.2K 颗 Star、3 名贡献者。

GraphScope 是阿里巴巴达摩院智能计算实验室研发并于 2020 年 12 月开源的一站式图计算平台。依托于阿里海量数据和丰富场景，与达摩院的高水平研究，GraphScope 致力于针对实际生产场景中图计算的挑战，提供一站式高效的解决方案。

2023 年 7 月，国际权威图基准测评“LDBC SNB Interactive”（社交网络-交互查询）榜单更新中出现关键突破：阿里云开源的图计算引擎 GraphScope 登顶并打破榜单历史纪录，性能达此前纪录保持者 2.45 倍。在此次基准测评中，GraphScope 以超过 33,000 QPS 的吞吐量排名第一。

截止到 2023 年 7 月 31 日，GraphScope 拥有 GitHub Star 2.6K、57 名代码贡献者，从 2022 年 8 月 1 日到 2023 年 7 月 31 日，先后发布了 v0.16.0 到 v0.23.0 共 9 个版本；截止 2022 年 7 月 30 日 GraphScope 拥有 GitHub Star 1.8K、41 名代码贡献者。

高性能图数据库 TuGraph 由蚂蚁集团和清华大学共同研发，历经蚂蚁实际业务场景锤炼，在国际图数据库基准测试中获得性能第一。包含 TuGraph DB（图数据库引擎）、TuGraph Analytics（图计算引擎）、TuGraph Platform（一站式图平台）。目前分社区版和企业版，社区版是单机版，并且不包含 TuGraph Analytics 和 TuGraph Platform。

TuGraph 在 GitHub 上采用 Apache-2.0 license 开源，其中 tugraph-db 主要采用 C++实现，在 2022 年 9 月 1 日发布第 1 个版本 v3.3.0，当前最新版本为 8 月 11 日发布的 v3.6.0；tugraph-analytics 主要采用 Java 实现，2023 年 6 月 12 日发布第一个开源版本 release-0.1，当前最新版为 2023 年 8 月发布的 release-0.2。

2022 年 7 月阿里云正式发布图计算服务（Graph Compute），2022 年 8 月做了一次版本更新，2022 年 9 月在华东 1（杭州）正式开服。

华为云图引擎服务（Graph Engine Service，简称 GES），是国内首个（2018 年 8 月）商用的、拥有自主知识产权的国产分布式原生图引擎，是针对以“关系”为基础的“图”结构数据，进行查询、分析的服务。广泛应用于社交应用、企业关系分析、风控、推荐、反欺诈等具有丰富关系数据的场景。

2022 年 8 月 1 日到 2023 年 7 月 31 日，华为云 GES 更新频繁，先后发布了 15 次更新：持久化版导入和增删改查支持平行边；图编辑器新增路径探索功能；GES 产品类型增加持久化版；图编辑器新增 3D 展示；Cypher 支持算术运算；画布增加点/边的删除和编辑功能；新增动态图功能；cypher 支持 optional match 子句；图编辑器支持可视化查询;图编辑器支持打印 cypher 查询计划;新版开发指南 SDK，支持 AK/SK，Token，Password 三种认证方式；图导出 API 支持分页导出；子图计算支持 LPA、Louvain 算法；持久化版 Cypher 支持部分字符串和数值函数；快速响应算法运行时不再拒绝写请求。

2022 年 8 月 1 日到 2023 年 7 月 31 日，TinkerPop 和 Gremlin 的 Google 全球趋势每月上下波动不定，但整体趋势没太大变化。

动态分析：

相比于其他大数据计算框架，图计算框架热度偏低，但大数据时代图计算在处理海量关系数据方面的优势也越来越明显，图计算在个性化推荐、社交网络、知识图谱、金融风控、网络安全、IT 设备运维等场景上应用日趋广泛，图计算框架潜力较大。

TinkerPop 是目前应用最广泛的开源图计算框架，拥有庞大的生态系统，生态系统涵盖主流图数据库和图分析系统，并紧跟开源生态。

TuGraph 性能强劲，并且有蚂蚁集团的作为强大后盾，值得关注。

广联达数据中台采用图数据库 NebulaGraph 存储图数据，图查询用的是 NGbatis（NGbatis 是一个基于 NebulaGraph 和 spring-boot 的数据库 ORM 框架，其借鉴于 MyBatis 的使用习惯进行开发，包含了一些类似于 mybatis-plus 的单表操作，另外还有一些图特有的实体-关系基本操作。），目前还未使用到图计算框架。随着未来图数据规模的持续增大，建议广联达采用开源图计算框架或者公有云图计算服务进行图数据的查询和分析，以满足大规模图数据的高性能查询和分析场景需求。

信息来源：

[1]GitHub
https://github.com/apache/hama
https://github.com/apache/giraph/tags
https://github.com/apache/spark/tree/master/graphx
https://github.com/apache/tinkerpop
https://github.com/alibaba/GraphScope
https://github.com/TuGraph-family
https://github.com/nebula-contrib/ngbatis
[2]TinkerPop, Gremlin - 探索 - Google 趋势
https://trends.google.com/trends/explore?q=TinkerPop,%2Fm%2F0hhr8wc
[3]Aiyun
https://www.aliyun.com/product/bigdata/graphcompute?spm=5176.28055625.J_3207526240.12.e939154aJe2QFI&scm=20140722.S_function@@product@@1758560._.ID_function@@product@@1758560-RL_Graph%20Compute-LOC_bar-OR_ser-V_2-PO_1
[4] Huaweicloud
https://www.huaweicloud.com/product/ges.html
[5] TuGraph
https://tugraph.antgroup.com/
[6] InfoQ
https://www.infoq.cn/article/7zAblNXRAb2VZ9af85Mv

动态 2：传统 SQL 难以满足高效的数据深度挖掘需求，图几乎成为了不二之选；以 ChatGPT 为代表的大语言模型（LLM）迎来爆发式增长，得益于图抽象的语意表达能力和可解释性，图计算可以很好的解决 LLM 的回答及时性、准确性，以及复杂任务编排的问题。

动态内容：

推荐场景常会用到链路预测，即通过已知的网络结构，预测尚未发生连边的两个节点之前产生连接的可能性。比如对社交网络做关系分析时，共同邻居是一个重要的特征，它标记了两个不直接关联的点之间共同的好友关系。这个应用如果用传

统的关系数据库写查询，会十分复杂，事实上，很多业务场景确实是通过 SQL+一些 UDF 的方式搞定的。但由于复杂度的问题，要舍弃一些精度以及引入很多近似计算才能在一个很大规模的数据集上成功跑下来，但千亿规模的数据上需要近 10 个小时。

这种情况采用图建模的话，共同邻居的查找就十分直观，也很容易写。GraphScope 系统通过基于子图模型、增量化计算等技术，能高效的支撑千亿规模以上的图计算，并且由于图建模可以准确计算共同邻居，避免精度损失。这类之前用时 10 小时的计算任务，用 GraphScope 只需要约 10 分钟。

以前，相比于传统的关系型数据库以及 SQL，图数据库的使用所占的比重很小。但近年来，随着互联网应用的爆炸式增长和对用户需求的深度挖掘，大家开始认识到有些场景下，传统的 SQL 处理方式已经不能满足高效的需求。而图数据库，与其他的文档数据库、KV 数据库类似，为复杂数据分析提供了全新的维度。特别是在需求深入挖掘关联关系的场景下，图几乎成为了不二之选。这一趋势的重要性在 ISO SQL 标准的 2023 版本中得到了体现，其中，SQL/PGQ（Property Graph Query）被纳入，未来支持 SQL 的数据库中也将支持图的查询。

不仅在数据库中，图计算已经在大数据处理和分析中也开始展现其独特的价值和地位。根据 2022 年 8 月发布的 Gartner 报告，到 2025 年，图计算技术将在 80%的数据和分析创新中扮演核心角色。这与 2021 年的数据大相径庭，当时图计算在数据和分析创新中的占比仅为 10%。这样的飞速增长无疑证明了图计算在未来数据分析领域的至关重要性。

今年以来，以 ChatGPT 为代表的大语言模型（LLM）迎来爆发式增长，虽然 LLM “涌现”出的智能令人兴奋不已，但其训练方式和特有的自然语言交互模式，使得将 LLM 应用于生产依然面临诸多挑战，例如：在训练数据滞后的情况下，如何提升 LLM 回答的实时性？在大部分 LLM 都具有“幻觉”（Hallucination）的情况下，如何确保回答的准确性？虽然 LLM 具有智能，但其大语言模型的本质决定了 LLM 在特定领域能力的限制，例如数学计算、网页搜索等。同时，在处理复杂任务时，往往需要对任务进行拆解和编排，利用工具逐个解决，如何才能端到端完成复杂任务？得益于图抽象的语意表达能力和可解释性，图计算可以很好的解决上述业界正在面临的问题。

动态分析：

图计算技术基于图数据开展分析和计算，从中挖掘出有价值的信息、知识和规律，为事件溯源、因果关系分析，以及为实际业务应用提供支持。图计算已经在大数据处理和分析中展现出其独特的价值和地位。随着关联关系数据深入挖掘的需求增加，以及 LMM 的爆发式增长，图计算未来会有更大的发展。

信息来源：

[1]InfoQ
https://www.infoq.cn/article/7zAblNXRAb2VZ9af85Mv
[2]ISO
https://www.iso.org/standard/79473.html
[3]stardog
https://info.stardog.com/graph-market

2.3.4ML 计算框架

动态 1：Ray 作为新一代一站式云原生分布式的机器学习计算框架，继续保持高热度和活跃度；Ray 背后的研发公司 Anyscale 发布 Aviary，旨在帮助开发人员简化为其项目选择和集成最佳 LLM 的过程。

动态内容：

Ray 是一个基于内存共享的分布式计算框架，适用于细粒度的并行计算和异构计算，其提供了一个底层基础架构，用于管理分配机器学习模型训练工作的复杂任务，采用 Apache-2.0 许可。

截止到 2023 年 7 月底，Ray 在 GitHub 上有星标 26.7K、贡献者 849 名，从 2022 年 8 月 1 日到 2023 年 7 月 30 日，先后发布了 ray-2.0.0 到 ray-2.6.0 共 10 个版本。

Ray 2.0.0 版本发布了工具箱 Ray AIR 和 KubeRay；原生支持 100TB 以上数据的 shuffle；通过 Deployment Graph API 使图的构建、测试和部署更容易。

2.1.0 版本，Ray AIR 对图片数据做了更好的支持，并提供了读 TFRecord 的能力；Ray Server 增加了 gRPC 支持；RLib 引进 DT 算法，对 on_episode_created() 增加新的回调，支持对 SimpleQ 和 PG 的学习率调整策略；Ray Core 增加 OOM 预防，支持动态生成器作为任务返回值；仪表盘支持时间序列指标，支持导出配置文件在 Prometheus 或 Grafana 中使用，在 job 明细视图中支持新的进度条。

2.2.0 版本，Ray Jobs API 达到 GA 程度；Ray Dashboard 提供 CPU 帧图和内存使用率指标；默认开启 OOM 监控；支持动态块分解解决文件过大时占用过多内存的问题。

2.3.0 版本，流式后端可以试用，支持 tb 级的训练；重构仪表盘，按用户和工作流组织指标，而不是实体；Ray On Spark 可以试用。

2.4.0 版本，支持生成式 AI 和 LLM。Ray Data 默认支持流式执行，能用更小的内存消耗支持更大的数据集；实现了数据集的异步批量预处理；支持读取 SQL 数据库；引入对 WebDataset 的支持。Ray Server 支持多 app 和 REST API；增强了服务的日志和指标。

2.5.0 版本，主要是对 Ray 生态做了增强和改进。对于 LLM，支持分布式模型 checkpointing 和 Pytorch Lightning FSDP，支持流式响应和模型多路复用。Ray Data 默认开启严格模式，要求数据集有 schema；同时默认的批量格式适配 Numpy，批量接口具有更好的性能。RLib 支持多 gpu 训练， ray-project/rllib-contrib 包含了社区贡献的算法。增加轻量资源广播提升了核心模块的可靠性和伸缩性。

2.6.0 版本，Server 进行了更好的流式支持；支持通过报错告知用户选择云存储或者 NFS；引入新的流式集成；RLib 对多 gpu 的方案更简单和强大。

2023 年 5 月 31 日，Anyscale 宣布启动名为 Aviary 的新开源项目，专注于开发开源大型语言模型（LLM）的应用程序。

2022 年起，人们对构建基于 AIGC 的定制应用程序的兴趣正在爆炸式增长。Gartner 最近的研究发现，到 2026 年，75%新开发的企业应用程序将包含基于 AI（人工智能）或 ML（机器学习）的模型，大大高于 2023 年不到 5%的比例。Anyscale 指出，集成 LLM 功能带来了一些挑战，如管理多个模型、自定义模型和集成应用程序逻辑、升级模型和确保高可用性、根据需求扩大或缩小规模，以及最大限度地提高 GPU 利用率以降低成本。

为了应对这些挑战，Anyscale 提供 Aviary 作为一个完全开源、免费、基于云的 LLM 服务基础设施，旨在帮助开发人员为其基于 LLM 的应用程序选择和部署正确的技术和方法。Aviary 允许用户向开源 LLM 提交测试提示，包括 CarperAI、Dolly 2.0、Llama、Vicuna、StabilityAI 和亚马逊的 LightGPT。

使用 Aviary，应用程序开发人员可以快速测试、部署、管理和扩展一个或多个开箱即用的预配置开源 LLM，同时最大限度地提高 GPU 利用率并降低云成本。有了 Aviary，Anyscale 正在使 LLM 技术民主化，并将其交到任何需要它的应用程序开发商手中，无论他们是在小型初创公司还是大型企业工作。

Aviary 建立在 Ray Serve 的基础上，Anyscale 表示，Ray Serve 提供生产级功能，包括容错、动态模型部署和请求批处理。Aviary 是为多 LLM 编排而设计的，能够随着时间的推移对 A/B 模型进行连续测试。Aviary 支持跨 GPU 划分模型，并实现跨异构计算的模型管理和自动缩放，以推动成本优化。

从今年 6 月 1 日开始，在 GitHub 上 Aviary 先后发布了 v0.0.1 到 v0.1.1 共 5 个版本，有星标 543 颗、贡献者 12 位。

动态分析：

Ray 继续保持着高热度和活跃度，其背后的研发公司 Anyscale 走在 AI 前沿，针对 LMM 继续发布了开源应用 Aviary。Aviary 目前还非常新，可以持续关注。

信息来源：

[1]GitHub
https://github.com/ray-project/ray
https://github.com/ray-project/aviary
https://github.com/ray-project/ray/releases?page=2
https://github.com/ray-project/ray/releases?page=1
[2] Aviary
https://www.anyscale.com/blog/announcing-aviary-open-source-multi-llm-serving-solution

2.3.5 统一计算引擎

动态 1：流批计算从统一计算到统一存储，实现统一实时分析，流批统一的数据处理概念在越来越多的公司中得到认可，并在越来越多的公司中成功实施。Flink 持续加强批处理方面的能力，成为流批一体的最佳选择。

动态内容：

Apache Spark 是专为大规模数据处理而设计的流批通用的计算引擎。Spark 是 UC Berkeley AMP lab 所开源的类 Hadoop MapReduce 的通用并行框架，Spark 拥有 Hadoop MapReduce 所具有的优点；并且 Spark 的 Job 中间输出结果可以保存在

内存中，从而不再需要读写 HDFS，因此 Spark 能更好地适用于数据挖掘与机器学习等需要迭代计算的 MapReduce 的算法。

从 2022 年 8 月 1 日到 2023 年 8 月 27 日，Spark 先后发布了 v3.3.1 到 v3.3.3 的 6 个主要版本。抽取 v3.4.1 版本和 v3.4.0 版本对比，共新增 89 个 commit。

截止到 2023 年 8 月 27 日，Spark 拥有 GitHub Star 36.2k，1961 名代码贡献者；去年 2022 年 7 月 30 日，Spark 拥有 GitHub Star 33.1k，1798 名代码贡献者。

Apache Flink 是由 Apache 软件基金会开发的开源流处理框架，是一个用于对无界和有界数据流进行有状态计算的框架和分布式处理引擎。Flink 可运行在所有常见的集群环境上，在任何规模的数据上以内存速度进行计算。

从 2022 年 8 月 1 日到 2023 年 8 月 27 日，Flink 先后发布了 release-1.15.2 到 release-1.17.1 的 9 个版本。

- 1.16 版本在批处理方面，完成了易用性、稳定性、性能全方位的改进。1.16 是 Fink 批处理的里程碑式的版本，是走向成熟的重要一步。
- 1.17 版本支持了 SQL Client 的 gateway 模式，并且对批处理进行了性能优化。

2023 年 5 月 ACM SIGMOD 系统奖授予“Apache Flink”，颁奖词为“Apache Flink 极大地扩展了流数据处理的使用。”

动态分析：

Flink 目前已经成为流处理领域的主角和事实标准，流批统一的数据处理概念在越来越多的公司中得到认可，并在越来越多的公司中成功实施。Flink 提出 Flink-Streaming Warehouse（Streamhouse）的下一个发展方向，进一步升级了流批融合的范围：真正做到了不仅统一计算还统一存储，从而实现统一实时分析。近一年 Flink 批处理能力也在逐步增强。

Spark 更新速度变慢，近一年主要做 Spark SQL 方面的能力增强。从各大会议上收集的信息来看，Flink 正在蚕食 Spark 的流处理和批处理地盘，尤其在流处理领域，Spark 公开发布场景应用越来越少。

广联达的业务平台部、技术中心、流程与数字化部、高校 BU、集团服务业务部、国标成本产品线(仅 Spark)、成本大数据产品线（仅 Flink）等 7 个平台或产线，目前采用 Flink 和 Spark 来作为流或批和流批一体的计算引擎。

信息来源：

[1]GitHub
https://github.com/apache/flink
https://github.com/apache/spark
[2]ACM SIGMOD 2023 年奖项
https://sigmod.org/2023-sigmod-awards/
[3]ApacheCon
https://apachecon.com/acasia2023/zh/tracks.html
https://apachecon.com/acasia2023/zh/tracks/streaming.html
https://apachecon.com/acasia2023/zh/tracks/datalake.html
https://apachecon.com/acasia2023/zh/tracks/datastorage.html

2.3.6检索分析引擎

动态 1：Elasticsearch、Splunk 分别作为开源搜索引擎和商业搜索引擎的代表，在搜索引擎领域均占有一席之地，在全球范围内热度不相上下，但在国内，仍然是 Elasticsearch 一家独大，Splunk 与 Solr、OpenSearch 一样在国内属于小众框架。

动态内容：

Elasticsearch 是一个分布式、RESTful 风格、支持多租户、建立在 Apache Lucene 之上的搜索和数据分析引擎。

Elasticsearch 版本发布非常密集，每个月均会有新版本发布，从 2022 年 7 月 30 日到 2023 年 7 月 30 日，共发布大小版本 25 个，最新版本 v8.9.1。

Elasticsearch 于 2023 年 7 月发布 v8.9.0。Elasticsearch v8.9.0，新增的主要功能包括优化并发索引和搜索性能，支持多个查询添加到搜索框，KNN 搜索进行文本嵌入，资产跟踪功能。

截止 2023 年 7 月 30 日 Elasticsearch 拥有 GitHub Star 64.9k、Fork 23.5k、1854 名代码贡献者。最近 1 年 Elasticsearch 的社区始终保持很高的活跃度。

Splunk 是一个功能强大的机器数据分析平台，包括机器数据的收集、索引、搜索、监控、可视化和告警等。另一方面来说，Splunk 是一个时间序列索引器，因为 Splunk 索引数据的时候，是基于数据时间戳把数据拆分成事件。

Splunk 平均每 2 个月发布 1 个子版本，主版本一般 1 年左右更新 1 次，从 2022 年 7 月 30 日开始，截止 2023 年 7 月 30 日，共发布大小版本 10 个，最新版本 V9.1.0.2。

Splunk 于 2023 年 6 月发布 v9.1.0。新增的主要功能包括健康报告增强功能，提取操作支持 S3 目标分区、支持多个 S3 存储桶、优化联合搜索的结果、支持 KMS 加密、预览效果优化、验证 Splunk Web 中的源类型，集群管理器分配策略优化，重新设计主页界面，TLS 证书相关优化，Dashboard Studio 和仪表板的功能优化，联合搜索功能改进等。

Solr 是流行的、速度极快的、建立在 Apache Lucene 之上的开源企业搜索平台。自从 2022 年 5 月发布 9.0.0 版本后，更新速度较缓慢，截止 2023 年 7 月 30 日，共发布 5 个版本，目前最新的版本是 9.3.0。

9.3.0 版亮点包括由 Lucene 9.7 提供支持，提供适用于二进制版本和 docker 镜像的精简版本，支持高维向量的矢量搜索，提供安装分片的 API 供用户将索引从本地导入云端，改进实验性 API，连接查询优化等。

截止 2023 年 7 月 30 日 Solr 拥有 GitHub Star 807、Fork 515、342 名代码贡献者。

OpenSearch 是一个社区驱动的、获得 Apache 2.0 许可的开源搜索和分析套件，可以轻松获取、搜索、可视化和分析数据。

OpenSearch 版本发布较密集，每个月均会有新版本发布，从 2022 年 7 月 30 日开始，截止 2023 年 7 月 30 日，共发布大小版本 18 个，最新版本 v2.9.0。

截止 2023 年 7 月 30 日 OpenSearch 拥有 GitHub Star 7.4k、Fork 1.2K、227 名代码贡献者，最近两年 OpenSearch 的社区始终保持较高的活跃度。

从 Goole 全球趋势来看，Elasticsearch、Splunk 各方面的活跃度明显高于 Solr 和 OpenSearch，平均热度之比为 82:80:14:18,2023 年 7 月底的热度之比为 86:91:16:22，Elasticsearch 和 Splunk 近一年内保持较高热度；中国趋势上 Elasticsearch 热度完全碾压 Splunk、Solr 和 OpenSearch，一家独大，热度之比高达 83:8:3:6。

2023 年 7 月 Elasticsearch、Splunk、Solr 分别位列 DB-Engines 的搜索引擎排行榜第 1 名（分值 139.92）、第 2 名（分值 88.98）、第 3 名（分值 47.80）。

分析总结：

Elasticsearch 优势在国内不断扩大，受欢迎程度节节升高，商业软件 Splunk 在全球范围的热度与 Elasticsearch 不相上下，相较而言 Solr 和 OpenSearch 不具有热度优势，市场会被 Elasticsearch 和 Splunk 不断蚕食。

目前业务平台部、国标成本产品线、成本大数据产品线、房建 BIM 产品线、城市 BU、技术中心采用 Elasticsearch 作为海量数据的搜索和分析引擎，使用版本有 5.6.x、6.x.x、7.x.x。对于 7.x 以下的版本建议升级至 Elasticsearch 8.9.x 以上版本以便获取更安全、更快速、更智能的搜索体验。Solr 在国标成本产品线的计价自积累数据智能组价和工程数据化以及成本大数据产品线的成本数据中台有应用。

信息来源：

[1]Elasticsearch 官网
https://www.elastic.co/cn/elasticsearch/
https://www.elastic.co/guide/en/elasticsearch/reference/8.0/index.html
[2]Elasticsearch 社区
https://elasticsearch.cn/
https://github.com/elastic/elasticsearch/tags
https://github.com/elastic/elasticsearch/graphs/contributors/
[3]Solr 官网
https://solr.apache.org/
https://solr.apache.org/news.html
[4]Solr 社区
https://lists.apache.org/list.html?users@solr.apache.org
https://github.com/apache/solr
https://github.com/apache/solr/graphs/contributors
[5]OpenSearch 官网
https://opensearch.org/
[6]OpenSearch 社区
https://opensearch.org/blog
https://forum.opensearch.org/
https://github.com/opensearch-project/OpenSearch
[7]Elasticsearch, Solr, OpenSearch, Splunk - 探索 - Google 趋势
https://trends.google.com/trends/explore?q=%2Fm%2F0h64sgb,%2Fg%2F11r9vstxzc,%2Fm%2F02qd9s1,%2Fg%2F11c3wthr71
[8]db-engines 搜索引擎排名
https://db-engines.com/en/ranking/search+engine
[9] Splunk 官网
https://www.splunk.com/zh_cn/products.html

https://docs.splunk.com/Documentation/Splunk/9.1.0/ReleaseNotes/MeetSplunk
[10] Splunk 社区
https://www.splunk.com/en_us/community.html

2.4 集群资源管理[姜建卫]

动态 1：K8s 作为容器编排技术的领头羊，其霸主地位就像谷歌在搜索领域的地位一样，无可撼动，目前主流厂商仍然以 K8s 作为集群资源管理的首选。其引以为傲的灵活性是建立在复杂的使用流程之上，与之相对的，另一款称为 nomad 的容器编排技术，以轻量性和简单的操作作为噱头吸引用户，不过其在大数据方面的应用仍然十分稀少，无法与 K8s 抗衡。

动态内容：

Kubernetes，简称 K8s，是一个开源的，用于管理云平台中多个主机上的容器化的应用,K8s 的目标是让部署容器化的应用简单并且高效，K8s 提供了应用部署、规划、更新、维护的一种机制。

截止 2023 年 7 月 17 日 K8s 拥有 GitHub Star 100K、3468 名贡献者。2022 年 8 月至 2023 年 7 月 17 日，K8s 共发布 64 个中小版本，中型版本 3 个从 v1.25 到 v1.27，最新版本是 2023 年 6 月 15 日发布的 v1.27.3，K8s 社区非常活跃。

K8s v1.25 到 v1.27 逐步稳定或取得显著进展特征包括：（1）Pod 安全性准入在 v1.25 进入稳定阶段（2） 临时容器在 v1.25 进入稳定阶段；（3）核心 CSI 迁移在 v1.25 进入稳定阶段；（4）对 Linux cgroups v2 API 的支持在 v1.25 进入稳定阶段（5）v1.25 版本网络端口配置支持指定端口范围，网络策略（6）v1.26 容器镜像注册表的更改,优化了用户的下载体验（7）v1.26 动态资源分配已进入 alpha 阶段 （8）v1.27 版本支持 Pod 资源的原地纵向弹性伸缩

YARN（Yet Another Resource Negotiator）是一种新的 Hadoop 资源管理器，它是一个通用作业调度和集群资源管理的框架。Apache Hadoop YARN 是 Apache Hadoop 顶级项目的一个模块。

截止 2023 年 7 月 17 日 Hadoop 拥有 GitHub Star 13.7K、520 名贡献者；Hadoop 共发布 3 个小版本，目前最高版本是 2023 年 6 月发布的 3.3.6；同期的 Hadoop 社区活跃度下降。

从 Google 全球趋势来看，K8s 各方面的活跃度明显高于 Hadoop，二者平均热度之比为86:11,三者最近热度之比为84:8,K8s近一年内热度一直保持相对稳定，处于火热状态；中国趋势上二者平均热度之比为 88:12。

动态分析：

Hadoop YARN 技术发展已相对成熟，近两年没有大版本更新，进入稳定期。相较而言，K8s 的增长势头还没有任何减缓的趋势。按照设计，它可以管理任何类型的资源；这种高度灵活性使得即使容器化最终不再流行，K8s 仍然有继续存在的价值。

K8s 目前在广联达应用广泛，广联达的新产品均使用 K8s 作为容器化组件，老产品也纷纷迁入 K8s 集群下。K8s 未来应用面会越来越广，轻量化大数据场景下 K8s 是最好的选择。

信息来源：

[1]Kubernetes 官网
https://kubernetes.io/
https://kubernetes.io/blog/
[2]Kubernetes 社区
https://github.com/kubernetes/kubernetes
[3]YARN 官网
https://Hadoop.apache.org/
[4] Kubernetes, Apache Hadoop- 探索 - Google 趋势
https://trends.google.com/trends/explore?q=%2Fg%2F11b7lxp79d,%2Fm%2F0fdjtq

2.5 大数据中间件[刘松]

动态 1：实时即未来，流批一体、可视化开发的计算中间件兴起，进步一降低实时数仓的构建门槛

动态内容：

Dinky 是基于 Flink 的一个应用平台，目前最核心的功能，就是在 Flink 上扩展了主要基于 Flink SQL 的，连接 OLTP、OLAP 和数据湖等众多框架的一站式实时计算平台，致力于流批一体和湖仓一体的建设与实践，方便直接在其上进行开发、联调。2022 年 1 月，Dlink 更名为 Dinky，英译为“小巧而精致的”，最直观的表明了它的特征：轻量级但又具备复杂的大数据开发能力，标志着 Dinky 从 FlinkSQL

开发平台转变为实时计算平台。2022 年 3 月 Dinky 顺利入选 2022 年度 Gitee GVP 项目。2022 年 5 月 Dinky 加入中国信通院可信开源社区共同体预备成员。

StreamPark 原名 StreamX，是一个简单易用的流处理应用开发框架和操作管理平台。于 2019 年由个人组织 streamxhub 创建，并于 2021 年 4 月在 GitHub 上开源，2022 年 8 月改名为 StreamPark。

StreamPark 初衷是让流处理更简单，项目的初衷是——让流处理更简单,使用 StreamPark 开发流处理作业,可以极大降低学习成本和开发门槛,让开发者只用关心最核心的业务,StreamPark 规范了项目的配置,鼓励函数式编程,定义了最佳的编程方式,提供了一系列开箱即用的 Connectors,标准化了配置、开发、测试、部署、监控、运维的整个过程, 提供了 scala 和 java 两套 Api,并且提供了一个一站式的流处理作业开发管理平台,从流处理作业开发到上线全生命周期都做了支持,是一个一站式的流处理计算平台。2022 年 9 月顺利通过投票，正式成为全球最大的开源基金会 Apache 软件基金会(ASF)的孵化项目。

Apache Hop（Hop Orchestration Platform 的首字母缩写）是一种数据编排（data orchestration ）和数据工程平台（data engineering platform），旨在促进数据和元数据编制。Hop 可以让我们专注于问题的解决，而不受技术的阻碍。该项目起源于 Kettle，经过数年的重构，并于 2020 年 9 月进入 Apache 孵化器；2022 年 1 月正式成为 Apache 顶级项目。

Hop 允许数据专业人员以可视化的方式工作，使用元数据来描述应如何处理数据。可视化设计使数据开发人员能够专注于他们想要做的事情，而不是需要如何完成该任务。这种对手头任务的关注让 Hop 开发人员比编写代码时更有效率。Hop 的目标是成为数据集成的未来，我们只需要对手头上的任务进行一次设计，然后通过 Hop 在任何地方运行，比如 Hop 本地引擎、Spark、Flink、Google Dataflow 或 AWS EMR 等。

Hop 被设计的尽可能灵活：其核心是小巧但功能强大的 Hop 引擎。所有的功能都是通过插件添加的：默认的 Hop 安装带有大约 400 个插件。可以根据需要删除或添加第三方插件，以定制 Hop，使其完全符合我们的需要。Hop 设计用于任何场景，从物联网到海量数据、本地、云端、裸操作系统或容器和 kubernetes。

动态分析：

传统大数据时代，基于 flink、spark 的 hadoop 体系，开发门槛较高，随着大数据技术应用越来越广泛，数据开发计算的易用性问题逐渐突出，各大开源社区衍生出各类计算中间件产品，致力于降低大数据的应用门槛。

在实时即未来的今天，Dinky、streamSpark 致力于通过完善的中间件工具体系，带来低门槛的大数据实时计算使用体验，使数据应用开发者聚焦在自身业务逻辑的实现上，快速实现业务价值。

Apache Hop 在从小数据量计算、海量数据计算、多环境迁移、可视化开发等维度出发，通过可视化拖拉拽的方式进一步降低数据开发的使用门槛，同时通过 Beam 编程模型进一步隔离开发内容，做到一次数据开发，既可运行在本地线程环境中，也可以运行在 Spark、Flink 的大数据环境中，做到了资源消耗可小，可大，零成本切换，符合业务的逐步发展、数据量逐步增大的场景。

广联达数据中台建设之初，基于 Hadoop 大数据体系构建了完整的大数据能力，并产品化，在对外推广的过程中，客户侧反馈数据中台使用门槛及资源消耗过高，数据中台大数据团队从 2022 年底开始了大数据容器化、轻量化之路，并在 2023 年 4 月份全线上线推广，同时计划 2023 年实现数据的可视化开发。年中随着 GDE 业务的逐步开展，轻量化及低资源诉求越来越迫切，数据中台团队 2023 年 7 月份启动了计算资源轻量化（线程级）、可视化的建设之路，经过多维度对比，选择了 Apache Hop 作为轻量化组件方案，目前已经完成底层组件的整合，并通过过拉拽的方式验证了成本中台 300+任务流的落地，预计在 2023 年底全面完成数据计算轻量化及可视化。

信息来源：

[1]Dinky
http://www.dlink.top/
https://github.com/DataLinkDC/dinky
[2]streamPark
https://streampark.apache.org/zh-CN/docs/intro
[3]Apache Hop
https://www.modb.pro/db/623848
https://hop.incubator.apache.org/

动态 2：新型数仓逐步融合开源大数据计算中间件的能力

动态内容：

2022 年 02 月，Apache Kyuubi 入围中国科协 2021“科创中国”开源创新榜。2022 年 05 月，Apache Kyuubi 加入中国信息通信研究院可信开源社区共同体。2022 年 12 月，Apache Kyuubi 从 Apache 基金会顺利毕业成为顶级项目，项目已在国内外数百家企业成功落地应用。2022 年 09 月，Apache Kyuubi 获评中国信息通信研究院、中国通信标准化协会 2022 OSCAR 开源产业大会尖峰开源项目。2023 年 06 月，Apache Kyuubi 获中央网信办信息化发展局“2022 年中国开源创新大赛”二等奖。

Kyuubi 社区目前的进展方面，社区目前有 12 位 PPMC，以及 17 位 Committer，有 96+的 Contributor，dev 的订阅者已经超过 65 位，Kyuubi 社区最近两年举办了 4 次社区 Meetup，参加了 20+项活动，比如 ApacheCon 等。对于 Kyuubi 项目本身来说，已经发布了 8 个版本，每个版本由不同的 Release Manager 发布，1400+PR 被 Merge，900+Issue 被解决。

2022 年随着社区的发展和社区开发者的参与，Kyuubi 的基础定位也在发生改变，Kyuubi 的愿景从最初的 Serverless Spark 转变成了现在的 Serverless SQL on Lakehouse。Apache Kyuubi 可以为企业级数据湖探索提供标准化的接口，赋予用户调动整个数据湖生态的数据的能力，使得用户能够像处理普通数据一样处理大数据。它的主要方向是依托本身的架构设计，围绕各类主流计算框架，打造一个面向 Serverless SQL on Lakehouse 的服务

用户可以使用 Kyuubi、Spark、Hudi 构建纯 SQL 的数据湖，用于处理 ETL 或 OLAP 业务；当然，也可以使用 Kyuubi、Flink、Hudi 构建纯 SQL 的实时数据入仓入湖架构。所有业务处理都可以基于一个平台、一份数据、纯 SQL 实现完成，与 RDBMS 一样的用户体验。除此之外，Kyuubi 支持 LDAP 和 Kerberos 安全认证，支持多租户资源隔离，提供多种编程接口和访问形式包括 Hive Thrift Protocol(兼容 HiveServer2 语法，提供 JDBC 方式提交 SQL 的能力)、RESTful APIs(提供管理 engines、sessions、operations 功能和 REST 方式提交 SQL 的能力)

动态分析：

大数据计算中间件在充分融合大数据生态多元异构计算引擎的基础上，附加多租户管理、逻辑资源隔离、Serverless 容器化及弹性申缩的自治能力，以普通服务的角色对外暴露 Restful Api、SQL API 等，进一步降低传统工程化团队对大数据的使用门槛，加速大数据技术的应用平民化，同时向企业级数据湖探索平台演

进。新型 MPP 数据库在逐步扩展大数据生态的周边能力建设，期望达到一个 MPP 数据库搞定传统大数据体系下 90%的场景，降低大家对大数据技术的使用门槛。

广联达大数据团队在 2022 年开始融合 Kyuubi 替换原有 Linkis，同时扩展在多租户、资源隔离、高可用等方面的能力，基于存算分离架构拥抱云原生 k8s，且已经在生产环境及多个私有化环境上线基于 kyuubi 的数据中台轻量化大数据底座。现阶段数据中台正在积极搭建数据湖，kyuubi 在数据湖方面的探索值得关注。同时新型数据仓库例如 Starrocks、Doris、Databend 发展方向也需要持续关注，大数据未来的发展方向一定是期望通过一个数据库解决大数据领域 90%的问题。

信息来源：

[1]Linkis
https://github.com/apache/incubator-linkis
[2]Kyuubi
https://github.com/apache/incubator-kyuubi
https://kyuubi.apache.org/
[3]spark
https://github.com/apache/spark
https://spark.apache.org/
[4]flink
https://github.com/apache/flink
https://flink.apache.org/
[5]Doris
https://doris.apache.org/
https://github.com/apache/doris

2.6 数据集成技术[杨思羽]

2.6.1 数据集成商业工具/平台

动态 1：全球数据集成工具市场仍然以较高的速度在稳定增长。主流国外厂商的数据集成工具以小版本迭代为主，主要优化点在于一些新框架的支持和任务优化等。国内大厂在数据集成方面无重大更新。

动态内容：

2022 年 8 月 Gartner 发布的数据集成工具魔力象限图分析报告指出数据集成工具市场在 2021 年增长 11.8%，2021-2026 年的五年复合年增长率预计为 8.5%。

目前处于领先位置的数据集成商业工具厂家包括 Informatica、IBM、SAP、Oracle、Talend、Microsoft 等。

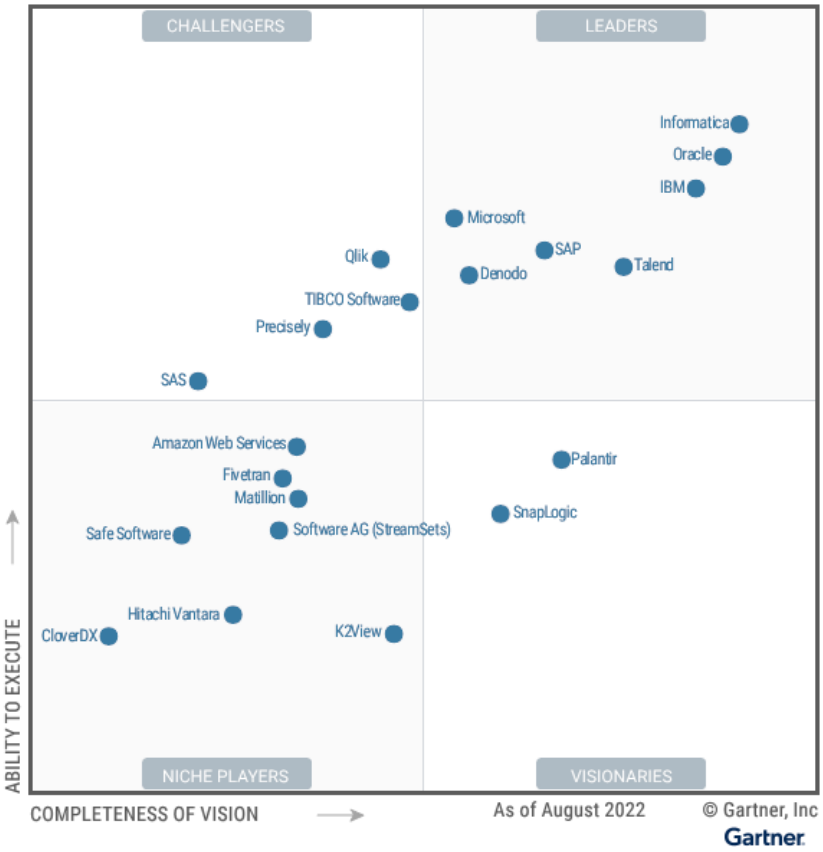

Informatica 公司于 2022 年 11 月发布 Informatica 10.5.3 版，2022 年 11 月发布 10.5.4 版。这两个小版本的更新主要改进了数据集成、数据质量、数据流、数据隐私管理、企业数据目录等模块的功能。

IBM Cloud Pak for Data（CPD）是 IBM 的数据管理平台解决方案，使用 Data Fabric 支持多云数据集成和管理。CPD 包括 DataStage（用于批量/批量集成）、IBM Cloud Pak for Integration（用于应用程序集成和 API 管理）、Watson Query（用于数据虚拟化） ）、IBM Data Replication（用于数据复制和同步）和 IBM Streams（用于流数据集成场景）等。2022 年 6 月发布的 4.5 版本包含了对现有数据隐私、数据虚拟化等功能的增强。2022 年 11 月发布 4.6 版本新加入了 AI Factsheets 模块(用与 AI 管理)和 Data Replication 模块。

2022 年 11 月 AWS 的数据集成工具 Glue 4.0 发版，最新的版本支持 Spark 3.3.0,并且包含了 Amazon EMR 中的特别优化，包括自适应查询、矢量化读取器以及优化的 shuffle 和分区合并。同时 Glue4.0 减少了任务启动延迟，以提高整体

作业完成时间和交互性，并且原生支持 Apache Hudi、Delta Lake 和 Apache Iceberg 的开源数据湖框架。

阿里云上的数据集成工具包括数据集成（Data Integration）和数据总线（DataHub）。2021 年 3 月后未见更新。

华为云的数据接入服务（Data Ingestion Service,简称 DIS）面向 IoT、互联网等实时数据，提供高效采集、传输、分发能力，支持多种 IoT 协议，提供丰富的接口，帮助客户快速构建实时数据应用。2021 年 5 月后未见更新。

动态分析

随着数据量以及数据集成需求的数量呈指数级增长，数据集成业务的领导者意识到他们需要自动化程度更高的增强数据集成产品，以在保证效率和质量的前提下减低人力成本。主流商业工具/平台都在利用图形、语义、知识图谱和 AI/ML 技术来提升数据集成设计、交付和维护的自动化。

数据集成的几个趋势中，对于集成工具对云和数据湖的支持，与 AI 的结合，以及实时数据集成值得关注。国内的主流产品对数据集成的趋势还没有做出应对。数广在推动公司数据资产入湖，对于上面的趋势需要进行感知和探索。

信息来源：

[1]Gartner: Magic Quadrant for Data Integration Tools
https://www.gartner.com/doc/reprints?id=1-27AC1P8K&ct=210825&st=sb?mkt_tok=ODY3LU1BTy02MzQAAAGEo63DUpMqkXkX83SC1Meqnd3O1aAJZftkjT_5cfs86T-UPZTHgZmSf-6ksdlZSSwvS5zvN31FK5sB3JU32KPOGkqBw3MqCTgVe8wsm1bqEJ8o9DEk7gA
[2]Informatica 10.5.2 new features
https://knowledge.informatica.com/s/article/informatica-1052-is-now-available?language=en_US
[3]IBM Cloud Pak for Data
https://www.ibm.com/products/cloud-pak-for-data
[4]Amazon AWS Glue Developer Guide
https://docs.aws.amazon.com/glue/latest/dg/what-is-glue.html
[5]Data Integration Trends to Watch in 2023
https://www.integrate.io/blog/data-integration-trends/

2.6.1 主流开源产品

动态 1：国外主流开源产品，Kafka 正在放弃 ZooKeeper，提升可维护性和性能，

Pentaho 以优化细节，改进性能和体验为主。

动态内容：

1. kafka

Kafka 是由 Apache 软件基金会开发的一个开源流处理平台，由 Scala 和 Java 编写。该项目的目标是为处理实时数据提供一个统一、高吞吐、低延迟的平台。

2023 年 6 月 Kafka 3.5.0 发布。3.5 中最引人注目的更新和更改集中在 Kafka Raft（KRaft）的实现及其生产适用性上。最大的消息是，随着 3.5 的发布，Zoo Keeper 被正式标记为 deprecated。用户仍然可以利用 ZooKeeper 来管理 Kafka，但是官方不推荐使用，并将在 4.0 中正式删除对 Zookeeper 的支持。

2. Kettle

Kettle 是一款国外开源的 ETL 工具，纯 Java 编写，可以在 Window、Linux、Unix 上运行，绿色无需安装，数据抽取高效稳定。Kettle 中文名称叫水壶，该项目的主程序员 MATT 希望把各种数据放到一个壶里，然后以一种指定的格式流出。Kettle 这个 ETL 工具集，它允许你管理来自不同数据库的数据，通过提供一个图形化的用户环境来描述你想做什么，而不是你想怎么做。

Kettle，现在已经更名为 PDI（Pentaho Data Integration）。

2023 年 8 月 Pentaho 发布 9.4 版本，提供了各种新功能和增强功能：用户体验改进，Pentaho Analyzer 可视化配置，业务分析服务性能改进，Mongo DB 插件改进等。

动态 2：国内开源产品动态，新开源了两款工具，BitSail 和 SeaTunnel，其中 SeaTunnel 以较快速度更新，优化引擎性能和使用效率。Datax 近期更新以完善插件为主。Flink 相关的，包括 Flink（主要是改善流和批处理的易用性、稳定性和性能），Flink CDC（性能优化和稳定性大改进以及跟进 Flink 新版本的支持），FlinkX（已经改名为 chunjun-纯钧，以完善 bug 为主），Dlink（改名为 Dinky，租户支持，完善 udf 支持，支持新版本 Flink 等）。

1. BitSail

BitSail 是字节跳动旗下引擎的数据集成引擎，于 2022 年 10 月 26 日正式开源，采用 Apache 2.0 开源许可。BitSail 支持多种异构数据源间的数据同步，并提供离线、实时、全量、增量场景下的全域数据集成解决方案，目前服务于字节

内部几乎所有业务线，包括抖音、今日头条等大家耳熟能详的应用，同时也支撑了火山引擎多个客户的数据集成需求。

2. InLong

Apache InLong（应龙）最初于 2019 年 11 月由腾讯大数据团队捐献到 Apache 孵化器，2022 年 6 月正式毕业成为 Apache 顶级项目。

InLong 是一站式的海量数据集成框架，提供自动、安全、可靠和高性能的数据传输能力，方便业务构建基于流式的数据分析、建模和应用。InLong 以腾讯大数据的 TDBank 系统为基础，依托近百万亿级别的数据接入和处理能力，整合了数据采集、汇聚、存储、分拣数据处理全流程，拥有简单易用、灵活扩展、稳定可靠等特性。

2023 年 1 月 Apache InLong（应龙）发布了 1.5.0 版本，该版本主要完成了新增 StarRocks、Hudi、Doris、Elasticsearch 等流向、优化 Dashboard 体验、重构 MQ 管理模型、新增脏数据处理、全链路 Apache Kafka 支持、TubeMQ C++/Python SDK 支持生产等。

2023 年 3 月发布了 1.6.0 版本，该版本主要完成了新增 Kudu 数据流向、完善 Redis 数据流向、增加 MQ 缓存集群 Selector 策略、优化 Audit ID 分配规则、新增数据节点链接性测试、优化 Sort Audit 对账基准时间、Audit 支持使用 Kafka 缓存审计数据等。

2023 年 5 月发布了 1.7.0 版本，该版本主要完成了支持直发数据到 Kafka、MySQL 整库迁移支持 schema 变更、MySQL 整库迁移支持 GH-OST 感知、增加 CSV/SQL/JSON/Excel 4 种批量导入模式、简化命令行工具创建数据流配置、重构 Dashboard 整体布局等。

2023 年 7 月发布了 1.8.0 版本，该版本主要完成了多租户管理、支持 Apache Flink 多版本、Dashboard 增加数据同步、支持数据预览、优化超长日志处理逻辑等。1.8.0 发布后，Apache InLong 围绕数据接入、数据同步和数据订阅的全场景数据集成布局基本完成，配合多租户管理、多集群管理、审批流管理、全链路审计/指标等。

3. DataX

DataX 是阿里云 DataWorks 数据集成的开源版本，在阿里巴巴集团内被广泛使用的离线数据同步工具/平台。DataX 实现了包括 MySQL、Oracle、SqlServer、Postgre、HDFS、Hive、ADS、HBase、TableStore(OTS)、MaxCompute(ODPS)、Hologres、DRDS 等各种异构数据源之间高效的数据同步功能。

2023 年 3 月，datax 发布新版本，精简代码，新增插件（adbmysqlwriter、databendwriter、selectdbwriter），优化插件、修复问题（sqlserver、hdfs、cassandra、kudu、oss），fastjson 升级到 fastjson2。

2023 年 6 月，新增插件（neo4jwriter、clickhousewriter），优化插件、修复问题（oceanbase、hdfs、databend、txtfile）。

2023 年 8 月，OTS 插件更新，databend 插件更新，Oceanbase 驱动修复。

4. Apache SeaTunnel

SeaTunnel 是一个非常易用、高性能、支持实时流式和离线批处理的海量数据集成平台，架构于 Apache Spark 和 Apache Flink 之上，支持海量数据的实时同步与转换。2023 年 6 月首个由国人主导的开源数据集成工具 Apache SeaTunnel 正式宣布从 Apache 软件基金会孵化器毕业成为顶级项目。

SeaTunnel 集成了多种能力，缩减 Spark、Flink 应用到生产环境的周期与复杂度；利用可插拔的插件体系支持超过 100 种数据源；引入管理与调度能力做到自动化的数据同步任务管理，在特定场景做端到端的优化提升数据同步的数据一致性；开放插件化与 API 集成能力帮助企业实现快速定制与集成。

5. Flink 相关

Flink CDC

2023 年 11 月发布了 2.3.0

新增 Db2 CDC 连接器，解锁读取 Db2 数据库，支持全量和增量一体化同步。

MongoDB CDC，Oracle CDC 两大连接器均接入了增量快照框架，从而提供了无锁读取，并发读取和断点续传的能力。

MySQL CDC 连接器在 2.3 版本里进行了诸多性能优化和稳定性大改进，极大提升了生产稳定性和性能。

Flink CDC 2.2 版本兼容了 Flink 1.13 和 Flink 1.14，Flink CDC 2.3 在此基础上继续兼容了 Flink 1.15 & 1.16 大版本，从而兼容了 Flink 的四个大版本。这意味着 CDC 的 SQLconnector 可以跑在不同的 Flink 集群上而无需任何修改，如果是 DataStream 用户也可以参考 SQL Connector 的打包方式，实现跨版本兼容。

OceanBase CDC 连接器支持将全部数据库类型对接到 Flink SQL，也就是说 OceanBase 所有类型的字段均支持同步。

2023 年 6 月发布了 2.4.0 版本

新增 Vitess CDC 连接器，支持 Vitess 增量数据同步。

PostgreSQL CDC，SQL Server CDC 两大连接器均接入了增量快照框架，从而提供了无锁读取，并发读取和断点续传的能力。

2.4 版本升级 Debezium 的依赖版本到 1.9.7.Final，引入了 Debezium 新版本的功能，优化和修复。

增量快照框架在 2.4 版本增加了自动关闭全量阶段结束后的空闲 Reader 功能，该功能非常实用，可以在生产环境节省资源。

MySQL CDC 连接器在 2.4 版本支持读取无主键表，同时支持新增表时原有实时同步链路不断流。

社区 2.4 版本兼容 Flink 1.13 ~ 1.17 五个 Flink 版本。CDC 的 SQL Connector 可以跑在不同的 Flink 集群上而无需任何修改，实现跨版本兼容。如果是 Datastream 作业，则需要根据不同的 Flink 版本引入不同版本的 flink-shaded-guava 依赖，DataStream 用户可以参考 SQL Connector 的打包方式管理正确的依赖。

MongoDB CDC 支持指定时间戳消费数据，支持 mongodb + srv 连接协议，并修复了若干问题。

OceanBase CDC 连接器支持 JDBC 参数设置，支持指定 Oracle 驱动，完善对 Oracle 数据类型的支持。

FlinkX

FlinkX 是一款基于 Flink 的分布式离线/实时数据同步插件，可实现多种异构数据源高效的数据同步，其由袋鼠云于 2016 年初步研发完成，目前有稳定的研发

团队持续维护，已在 Github 上开源（开源地址详见文章末尾），并维护该开源社区。目前已完成批流统一，离线计算与流计算的数据同步任务都可基于 FlinkX 实现。

FlinkX，已经改名为 chunjun（纯钧）

2022 年 11 月发布 1.12.7，完善了 oracle 在 sql 上进行类型修改；修复了一些 bug，比如将时间戳列转换为长错误的问题；支持 hadoop3.x 版本，支持 orc 等。2023 年 2 月日发布了 1.12.8，修复了 pgsql 查询元数据异常等一些异常。

Dlink，改名为 Dinky

Dlink 是一个基于 Apache Flink 开发的 FlinkSQL Studio，可以连接多个 Flink 集群实例，并在线开发、执行、提交 FlinkSQL 语句以及预览其运行结果，支持 Flink 官方所有语法并进行了些许增强。

Dlink 在 DataLink 中的定位是一个实时计算平台，将提供相关功能如开发调试、元数据、血缘分析、任务调度等功能。

2022 年 9 月发布 0.6.7，添加多租户的实现，一键上线和下线作业，添加全局变量管理，添加命名空间与密码的表单，登录时选择多租户，多租户前端业务管理实现，添加 github 工作流来检查代码风格、测试类和打包，添加 druid 连接池来解决 jdbc 多连接问题，新增用户授权角色的功能，修改 Flink 默认版本为 1.14 等。

2022 年 11 月发布 0.7.0，支持 Flink 1.16.0，新增 Java udf 打包，支持 Flink Session 模式自动加载 udf，支持 Flink Per-Job 模式自动加载 udf，支持 Flink Application 模式自动加载 udf，支持 Python udf 在线开发，支持 Scala udf 在线开发，支持自定义的 K8S Application 提交，新增 FlinkJar 文件上传等。

2023 年 8 月发布 0.7.4 版本，新增从 Flink SQL 分析自定义函数；在 Flink 1.16 中新增 SQLServer Connector；CDCSOURCE 支持 Doris 自动建表。

动态分析：

广联达私有化部署大数据平台广泛采用 Kafka，Flink，FlinkCDC，Datax 等框架，集团服务业务部采用 datax3.0，技术中台采用 flinkx，kafka，大数据平台采用 kafka，flink，flinkcdc 等。

下一步需要重点关注Flink,Kafka等产品的路线和最新进展,尤其是FlinkCDC相关。注意评估Kafka新版本对zookeeper放弃的影响。

信息来源：

[1] https://cloud.tencent.com/developer/article/1812233
[2] https://cloud.tencent.com/developer/article/1782225
[3] https://www.cnblogs.com/tgzhu/p/17130515.html
[4] https://juejin.cn/post/7048058543290712071
[5] https://github.com/apache/seatunnel
[6] https://github.com/apache/inlong
[7] https://github.com/bytedance/bitsail
[8] https://github.com/apache/flink
[9] https://github.com/ververica/flink-cdc-connectors/releases
[10] https://github.com/DTStack/chunjun
[11] https://github.com/DataLinkDC/DataLink

2.7 大数据开发[袁小芬]

大数据开发技术主要从开发语言和开发框架两个维度扫描，考虑到广联达各产线的大数据应用产品的开发语言以Java为主，并且广联达正在研发行业数据中台（一站式数据治理平台），所以，本次扫描主要关注Java语言的动态，以及头部云厂商在数据开发平台或数据治理平台的可视化工作台的发展趋势及动态。

2.7.1 开发语言

动态1：Java 11已经成为最主流的Java长期支持版本（LTS），Java 17使用率在一年之内增长迅速。Java 8之前版本已结束支持。JDK供应商竞争激烈，Amazon已超过Oracle成为使用率最高的JDK供应商。

动态内容：

New Relic公司发布了《2023年Java生态系统状况报告》，与2022年相比，在长期支持版本（LTS）中，Java 8的使用占比已经从2022年的46.65%减少到了32.99%；Java 11使用率较同期增长7.62%，达到56.06%；Java 17使用率较同期增长8.7%，达到9.07%。Java 17的速度增长超过了Java 11。此外，到2022年7月，对Java7的支持已经结束，目前Java 8以前版本的Java使用率已经不足1%。

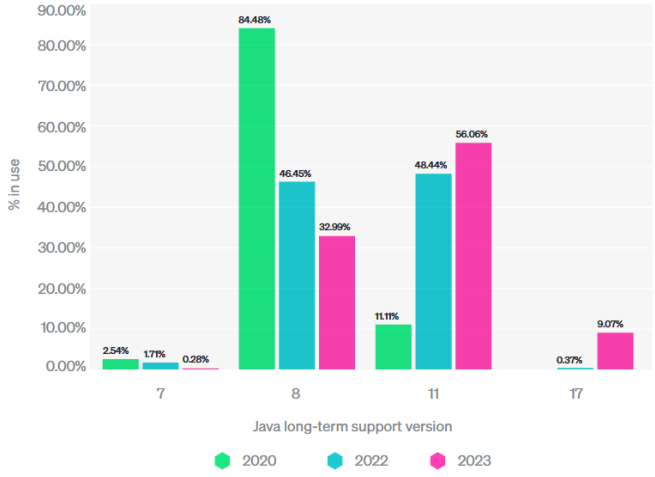

2023 年 LTS 版本 java 使用占比

根据 New Relic 公司发布的《2023 年 Java 生态系统状况报告》显示，Amazon 的使用率在 2023 年增长了 9.39%，达到了 31.35%；而 Oracle 在 2023 年的使用率减少了 5.73%，目前已不足 29%；Red Hat 的使用率增长了近一倍，仅次于 Eclipse Adoptium，位居第四。而 IcedTea 和 Ubuntu 基本已经放弃了 JDK 供应商市场。同时又出现了类似 Debian 和 SAP SE 等新兴的 JDK 供应商。

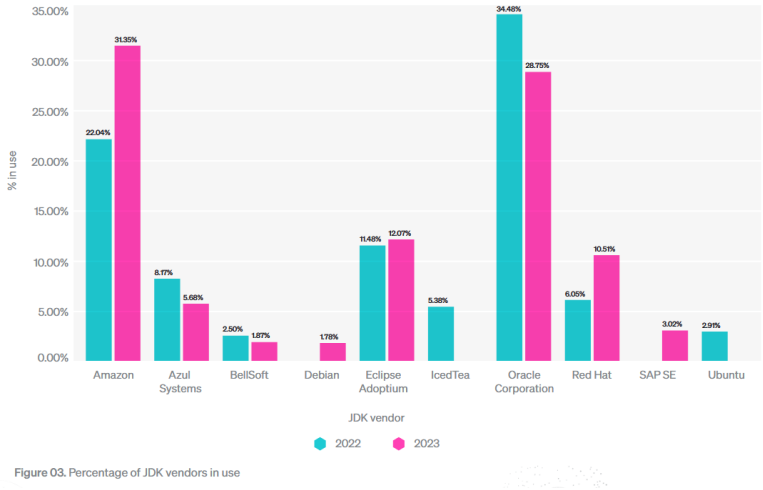

JDK 供应商使用占比

甲骨文表示将于 2023 年将 GraalVM Java 编译器加入 OpenJDK 中，以提高 OpenJDK 的性能，节奏与 OpenJDK 的发布节奏和流程保持一致。

2022 年 11 月 24 日，Springboot3.0 正式发布，要求 Java 最低版本 Java 17。

2022 年 06 月 27 日，Jenkins 发布 2.357 版本，兼容 Java 17 由原来的预览版过度到一般可用版（GA）

2023 年 07 月，在 Flink 1.18 的任务列表中出现 Support Java 17（LTS）任

务。从 Flink 1.16 开始，官方不再为 Java 8 提供预编译版本的 Flink；FLink 1.17 版本中虽然继续支持 Java 8，但官方建议尽快升级到 Java 11 或更高版本。

2023 年 06 月，Spark3.3.0 版本开始兼容 Java 17。Spark3.4.0 版本已经不再支持 Java 8u362 之前的版本。Spark3.4.0 版本开始不再支持 Python 3.7。

Java 8 支持自 Apache Kafka 3.0 起已被弃用，并将在 Apache Kafka4.0 中删除。当前 kafka 最新版本 3.5。

Elasticsearch 7.15.x 开始支持 Java 17；Elasicsearch 8 开始不再支持 Java 8 和 Java 11。

Cassandra 5.0 版本不再支持 Java 8。

动态分析：

从 New Relic 的报告内容上来看，Java 11 虽然已经连续两年占据使用率榜首，但 Java 17 使用率增长速度远远超出了 Java 11 推出时的状况。目前共有 9.07%的应用程序在使用 Java 17，但在 2022 年时还仅仅不到 1%，这意味着 Java 17 在一年内完成了 2300%的环比增长。另外，Java 生态中，各大主流的 Java 软件都陆续开始兼容 Java 17，例如：SpringBoot3.0，Spring6.0，Jenkins、Flink、Spark、Elasticsearch 等，也是 Java 17 使用率增长迅速重要原因。

供应商市场上，Amazon 增长迅速，已经超过 Oracle，成为使用率最高的 JDK 提供商，而 Oracle 的占比则继续下滑，已不足 30%。但 Oracle 近期还在不断优化 OpenJDK，引入 GraalVM 以提高 OpenJDK 的性能，是否会提高自身 OpenJDK 的使用率需要进一步关注，此外 RedHat 的使用率在一年内增长近一倍，未来有可能会成为新兴 JDK 提供商的代表。

信息来源：

[1] New Relic 发布 Java 生态运行报告
《new-relic-2023-state-of-the-java-ecosystem-2023-04-20.pdf》
https://finance.sina.com.cn/wm/2023-06-01/doc-imyvunyf2649603.shtml
[2] Java 17 预览版在 Jenkins2.339 以后版本中可用
https://www.jenkins.io/blog/2022/03/21/java17-preview-availability/
[3]Flink 1.18 版本计划支持 Java 17
https://issues.apache.org/jira/browse/FLINK-15736
[4]GraalVMJava 编译器将于 2023 年加入，与 OpenJDK 的发布节奏和流程保持一致
https://www.infoq.cn/article/XOzIWQtI1qUdtX7gOEj3
[5]Springboot3.0 正式发布
https://spring.io/blog/2022/05/24/preparing-for-spring-boot-3-0
[6]Jenkins 需要 Java 11 还是更高版本
https://www.jenkins.io/blog/2022/06/28/require-java-11/

[7]Spark3.3.0 开始兼容 Java 17
https://spark.apache.org/releases/spark-release-3-3-0.html
[8] TIOBE Index for July 2023
https://www.tiobe.com/tiobe-index/#2022
[9] 2023 年 Java 发展趋势
https://blog.csdn.net/qq_24785325/article/details/128755426
[10] Elasicsearch 支持一览表
https://www.elastic.co/cn/support/matrix#matrix_jvm

2.8 数据治理技术[申凯]

数据治理面临一系列挑战：1）开发与治理脱节 2）对数据的成本和价值缺少精细化的管理 3）忽视了开发过程中效率和质量的问题 4）不同平台之间缺少统一的管控”

应对以上挑战，主动元数据管理及 DataOps 技术体系已有落地实践。

2.8.1 元数据

动态 1：主动元数据管理已有商业产品落地实践，开源社区尚无类似产品。开源方面，Datahub、opendatadiscovery 等产品日趋完善，并支持主流大数据计算引擎的技术元数据实时获取。

动态内容：

“要实现数据驱动，组织必须先实现元数据驱动。”

主动元数据（Active Metadata）通过利用机器学习和知识图谱等底层人工智能技术，实现对数据采集、内容解析、使用分析等元数据的“主动”管理。作为元数据概念的延伸和扩展，主动元数据是对数据的使用者、相关数据管理活动、以及数据基础设施等方方面面情况的数据，支持持续分析数据的一致性和异常情况。

Aloudata（大应科技）是一家智能湖仓平台提供商和数据编织(Data Fabric)解决方案提供商，其产品深度实践 Data Fabric 架构，更多关于 Data Fabric 的行业洞察参考本报告章节 2.1：大数据软件架构技术。2023 年大应科技发布基于算子级血缘的主动数据治理平台 BigMeta。Aloudata BigMeta 可自动采集全链路元数据，并可对 SQL 进行高精度解析，无论再复杂的数据网络、再大的数据规模，BigMeta 都可基于任务脚本、执行日志等元数据自动构建算子级数据血缘、抽取字段加工口径，准确率达 99%以上。结合 BigMeta 的字段口径穿透、加工链路比对、重复资产识别、分类打标扩散等能力，数据团队可十倍提升数据资产盘点效率，彻

底摆脱纯人工、运动式分析字段口径、梳理上下游依赖等低价值繁琐工作，专注数据资产建设及数据价值创造。

开源的元数据管理平台产品

(1)Apache Atlas

Apache Atlas 是一款开源的数据治理和元数据管理工具。它支持对各种数据资源进行分类、标注和搜索，能够帮助用户更好地管理和利用数据。Apache Atlas 也提供了丰富的 REST API 和插件，可以与其他数据管理工具和系统进行集成。

(2)Datahub

Datahub 是领英（LinkedIn）开源的数据治理平台，提供了数据注册、血缘、安全、监控等功能，支持多种数据类型和数据源。Datahub 通过可视化的界面和 REST API，让用户更方便地管理和使用数据，帮助企业提高数据质量和效率。

(3)Open Lineage

Open Lineage 是一项由数据社区推动的开放性数据血缘标准和工具集，旨在解决数据血缘追溯和数据治理的问题。Open Lineage 提供了统一的数据血缘模型和 API，支持跨多个系统和环节的数据血缘追踪。它还提供了可扩展的插件和工具，可以与各种数据管理工具和系统进行集成。对元数据的获取提供了 Spark 及 Flink 的相应扩展，其它数据源支持不完善。由于目前只有 MARQUEZ 支持 Open Lineage 标准，并且界面交互做的较为简单不太适合生产，持续保持关注。

（4）Open Data Discovery

Open Data Discovery (ODD)是一个开源数据发现和可观察性平台。它旨在帮助数据驱动型企业通过使其更易于发现、可管理、可观察、可靠和安全来实现数据民主化。由于支持开放数据标准，ODD 使数据团队能够在各种数据工具之间进行更高效的数据交换。优点是界面美观，比较符合国人使用习惯，搭建环境简单试用了下，由于开发时间较短，很多功能不完善，社区回复较为及时，由于已经将重点放在 Datahub 上，持续保持关注。

动态分析：

目前 Apache Atlas 在流程与数字化部的生产环境能够支持使用 Spark 产生的元数据，但是由于社区活跃度较低，比如对 Flink 元数据的支持一直处于搁置状态以及技术栈复杂、交互界面不够友好等方面的考虑，已经准备弃用。DataHub 是流程与数字化部重点考虑的开源产品，通过了 POC 测试，并对当前支持的 spark 操作命令类型做了扩展。

元数据治理是数据治理的重要基础、企业实现数据驱动的必要条件。数据资产盘点、集群的降本增效（识别如：跨层引用、重复逻辑、僵尸表等）、湖仓一体架构的实现都离不开元数据。目前开源的元数据管理相关产品由于其背后团队技术栈的局限，很难大而全的支撑好广联达的数据链路场景，需要二次开发或基于其 API 定制。商用产品方面，主动元数据管理是一个值得关注的亮点。

信息来源：

[1]BigMeta-基于算子级血缘的主动数据治理平台
https://www.aloudata.com/products/big
[2]Datahub
https://datahubproject.io/
[3]Open Lineage
https://openlineage.io/
[4]Open Data Discovery
https://docs.opendatadiscovery.org

2.9 大数据运维[张祺君]

大数据运维动态扫描选择商业和开源两个维度,商业大数据运维系统选择全球 Top 大数据云厂商阿里云、华为云、腾讯云和 Cloudera 的商业产品,开源大数据运维系统选择了应用比较广泛的 Apache Ambari

动态 1:Ambari 开源运维平台在经历被移至 “阁楼”事件后即将发布新版 2.8.0,将集成 BigTop 开源 hadoop 组件，阿里云、腾讯云、华为云等头部厂商不断完善自有商业化运维平台

动态内容：

Apache Ambari 是一个基于 Web 的 Hadoop 集群的配置、管理和监控系统，是 5 个顶级 hadoop 管理工具之一，支持 HDFS、MapReduce、Hive、Pig、Hbase、Zookeper、Sqoop 和 Hcatalog 等的集中管理。

Ambari 经历过“阁楼”事件后与 BigTop 项目进行了合作，由 BigTop 提供 hadoop 发行组件，最近版本 2.8.0-rc1 发布日期为 2023 年 5 月 8 日。BigTop 在组件类型上抛弃了一些过时的组件，如 Pig、Sqoop、Storm 等；引入了一些新组件，如 Flink；在组件版本上，都比 HDP 的要新。

阿里云 E-MapReduce（简称 EMR），2022.10.31 支持将模型发布至 E-MapReduce Hive，并能生成相应的 ETL 框架代码，EMR Workflow 于 2023 年 6 月 29 日开始，面向所有用户开放公测。EMR Workflow 是一个全托管的工作流和任务调度服务，

100%兼容开源 Apache DolphinScheduler。它提供了易于使用的调度服务，您可以通过可视化的操作界面轻松地管理工作流和任务，高效构建数据仓库，并为生产任务的稳定运行提供保障。

腾讯云动态 2022-11-04 弹性 MapReduce - 容器版支持 RSS 集群（RSS：Remote Shuffle Service 提供开源的分布式 Shuffle 计算引擎）。RSS 能够帮助解决大数据量 Spark 作业的磁盘写满、网络不稳定和随机 IO 等运行稳定性问题，同时可以提升大数据量 Shuffle 的性能。2023-02-23，支持 EMR 基于 TKE 或 TKE Serverless 全容器部署产品形态。

华为云数据湖 MRS（MapReduce Service），2023 年 3 月支持包周期集群缩容，支持弹性伸缩到指定资源池。2023 年 4 月新发布 CDL 组件和 IoTDB 组件，Flink 升级到 1.15.0 版本，Hadoop 升级到 3.3.1 版本，Hudi 升级到 0.11.0 版本。

动态分析：

广联达私有化部署大数据平台广泛采用 HDP（集成 Ambari）：造价大数据平台采用 HDP3.1.5、TC 行为大数据分析平台采用 HDP3.1.4，数字广联达底层经营分析数据仓库采用 HDP3.1.5。

下一步需要重点关注 Ambari 产品路线和最新进展。建议测试和评估 Ambari+BigTop，在功能、性能和稳定性等指标满足要求的前提下逐步替换原 HDP 版本。

信息来源：

[1]ambari 官网
https://ambari.apache.org
[2] ambari 社区
https://github.com/apache/ambari
https://lists.apache.org/list.html?dev@ambari.apache.orgsss
[3] 阿里云
https://help.aliyun.com/document_detail/613490.html
[4]腾讯云
https://cloud.tencent.com
[5]华为云
https://www.huaweicloud.com

2.10大数据安全技术[高贵增]

大数据安全技术扫描聚焦的维度包括大数据安全趋势、大数据安全标准规范、

大数据安全技术或产品动态等。

2.10.1数据安全标准

动态 1：2022 年下半年至 2023 年多个数据安全相关法律、法规、标准发布。

动态内容：

2022 年 9 月 1 日起《数据出境安全评估办法》正式实施，旨在落实《网络安全法》、《数据安全法》、《个人信息保护法》的规定，规范数据出境活动，保护个人信息权益，维护国家安全和社会公共利益，促进数据跨境安全、自由流动，切实以安全保发展、以发展促安全。

2022 年 11 月中国电子信息行业联合会发布 T/CITIF 001—2022《数据合规管理体系 要求》团体标准。标准以数据政策为依据，以落实数据合规义务为目标，以构建数据合规管理体系为核心，提出兼顾组织体系、制度体系、运营体系和保障体系等方面的数据合规管理要求，为组织及其最高管理者、员工和第三方合作伙伴确立行为规范和边界。

2023 年 4 月，Gartner 发布《满足中国数据出境监管要求的三个最佳云安全实践》。

中国境外的云部署	*避免数据出境的解决方案*
IaaS和PaaS	中国本土CSP：在CSP的中国区域部署IaaS、PaaS 境外CSP： ■ 在独立的中国云中部署IaaS和PaaS，并关注可用的服务/功能 ■ 转换到中国合作伙伴CSP的IaaS和PaaS
SaaS	如果CSP设有中国POP，则切换到中国/POP（某些功能可能不开放） 检查CSP是否有中国POP的路线图，并根据相应时间表进行评估 本地部署使数据能够在本地处理，但控制层仍然在云端（部分CSP提供此选项）
远程数据访问	内部： ■ 审查数据访问政策 ■ 基于IP地址和位置的访问控制 外部： ■ 要求本地支持 ■ 基于IP地址和位置的访问控制

2023 年 5 月全国信息安全标准化技术委员会发布《网络安全标准实践指南—网络数据安全风险评估实施指引》，给出了网络数据安全风险评估的评估思路、工作流程和评估内容。

2023 年 6 月中关村网络安全产业联盟数据安全治理专业委员会编制的《数据安全治理白皮书 5.0》、《数据安全治理白皮书 5.0——行业数据安全治理实践集》发布。内容包括数据安全治理概念和理念、监管要求、技术体系、管理体系、行业实践、法律法规汇总、数据安全事件案例等，具备一定的参考价值。

动态分析：

伴随数据安全治理的深入，围绕“让数据使用有序而安全”的治理愿景与“满足数据安全保护、合规性、敏感数据管理”的治理目标，面对数据安全治理的新形势、新挑战，需要进一步完善“个人信息保护与合理利用”的需求覆盖，突出“全员协同治理”的重要性，强调面向行业特点的“场景化安全”，健全从评估、建设、运营到监督评价的闭环治理体系，持续推动数据开发利用与安全防护的一体两翼发展。

信息来源：

[1] 团体标准信息平台
https://www.ttbz.org.cn/StandardManage/Detail/70324
[2] 网信办
http://www.cac.gov.cn/2022-07/07/c_1658811536594644.htm
[3]信安标委
https://www.tc260.org.cn/front/postDetail.html?id=20230529155314
https://www.tc260.org.cn/upload/2023-05-29/1685346726882022691.pdf
[4]搜狐网
https://www.sohu.com/a/682995825_120708211

2.10.2 DataOps

动态 1：大数据技术标准推进委员会发布《DataOps 实践指南(1.0)》,Project Nessie 使企业能够通过在湖仓中控制一致的数据版本来改进 DataOps

动态内容：

DataOps：数据治理是一个发现问题、解决问题、沉淀问题的过程，因此在数据治理的各个环节中都要尽可能的做到闭环。基于 DataOps 的数据开发方法，是将数据看作是软件，用软件工程的方法去解决数据开发过程中的效率和质量问题，其包括可持续集成、可持续交付、可持续部署三块内容。

DataOps 相关开源产品

DataOps 的实现，需要集成的数据治理套件，如阿里的 DataWorks、华为的 DataArts Studio、广联达的 GBP、网易的 EasyData 等，目前没有开源产品可以完整实现，下文主要聚焦于数据的版本管理及数据质量相关开源产品的扫描。

（1）Nessie，像管理代码一样管理数据湖中的数据。

一个数据开发的 pipeline，常见的数据流是：数据源接入湖仓中->质量检查->流向下游（数据分层管理）->终端用户使用。我们很难在接入数据的同时做质量检查，因为这两个动作通常是由不同的技术组件实现的，另外如果质量检查有漏洞，异常数据将会继续向下游污染，想要清除异常数据其实是一个昂贵的操作。

假如当前写入的数据是写入基于最新数据创建的分支，只有这个分支的数据经过完整链路的验证后再合并或删除或修订，那么对于异常数据的处理将会变得简单高效，Nessie 提供了这种可能。

Project Nessie 是一个开源的数据版本控制项目，它为数据管道和数据湖(Iceberg)提供了与 Git 类似的版本控制和元数据管理功能。它旨在解决数据团队在数据开发和数据操作过程中遇到的一些挑战，如数据可追溯性、一致性和协作问题。

（2）Great Expectations，验证、记录和分析数据的领先工具

Great Expectations 是一种流行的开源数据质量管理工具，可帮助数据团队确保数据在整个数据管道中的准确性和一致性。它提供了一套灵活的工具和方法，使数据工程师、数据科学家和分析师能够定义、管理和监控数据质量指标。

Great Expectations 允许您在数据源、转换过程和分析环境中创建数据期望（Expectations），以验证数据是否符合预期的格式、范围、分布等要求。通过定义这些期望，您可以在数据处理过程中捕获潜在的数据质量问题，提前发现错误和异常。期望（Expectations）的定义，采用一种便于理解的 python 函数定义的方法，非常直观。

Great Expectations 可以与常见的数据处理工具和框架（如 Apache Spark、Pandas、SQLAlchemy 等）无缝集成，使其易于与现有的数据管道和工作流程集成。

Great Expectations 产生的数据质量结果可以传递给 Datahub,作为数据集元数据的一部分。目前社区十分活跃。

（3）Apache DolphinScheduler 数据质量模块

Apache DolphinScheduler 是一个工作流协调平台，在公司的应用较为广泛，其在 3.0 版本开始提供数据质量功能。其核心是基于 spark 封装的一个程序，通过用户在页面上配置的数据质量任务元数据作为参数传递给 spark 程序，完成数据质量的校验任务。数据治理的 pipeline 本身是基于 DolphinScheduler 的，则可以极大简化数据质量任务的开发。

动态分析：

在 2018 年 DataOps 正式被纳入 Gartner 的数据管理技术成熟度曲线当中。2022 年中国信通院正式牵头启动了 DataOps 的标准建设工作并发布《DataOps 成熟度框架》、2023 年发布《DataOps 实践指南（1.0）》，调研现有数据开发范式遇到的瓶颈，明确数据开发范式变革方向，一些大型企业已经开始进行 DataOps 能力模型评估。Nessie 原生支持 Iceberg，Great Expectations 可以无缝与 Spark 集成、DolphinScheduler 的数据质量模块也是一个封装好的 Spark 应用，以上三个项目能够较好与广联达现有数据产品技术栈融合。

信息来源：

[1] 网易数帆
《网易数据治理白皮书》
[2] CCSA TC601 大数据技术标准推进委员会
《DataOps 实践指南（1.0）》
[3] CCSA TC601 大数据技术标准推进委员会
《数据资产管理实践白皮书 6.0》
[4] DAMA 国际
《DAMA 数据管理知识体系指南(第二版)》
[5] Nessie 官网
https://projectnessie.org/
[6] Dremio talk
dataops-in-action-with-nessie-iceberg-and-great-expectations
[7] 大应科技公开演讲
EB 级数仓都在用的算子级血缘如何实现主动数据治理

2.10.3数据泄露趋势

动态 1：2023 年多份数据安全研究报告指出，数据泄露成本逐年升高，大量数据安全事件为经济驱动、内部人员导致。

动态内容：

Verizon 报告：95%数据泄露为钱而来，“高管”易成风险点。美国通信运营商威瑞森（Verizon）发布了 2023 数据泄露调查报告(DBIR)，报告显示，数据泄露已经成为全球数据安全风险的首要问题，其中 95%的数据泄露都是经济驱动，远高于 2019 年的 86%，特权账号或凭据的窃取和非法使用是数据泄露的关键攻击手段。Verizon 专家还认为，企业高级管理层由于经常被“网开一面”，又掌控更多权限，容易成为重大安全威胁。

根据 Ponemon 发布的《2022 年数据泄露成本报告》，2022 年全球数据泄露规

模和平均成本均创下历史新高，数据泄露事件的平均成本高达 435 万美元。AI 平台、DevSecOps 方法和使用事件响应(IR)团队是导致与数据泄露平均成本相比成本降低最多的三个因素。安全系统复杂性、组织在迁移至云的过程中发生云迁移以及合规失败等是与平均成本净增加最高相关的三个因素。

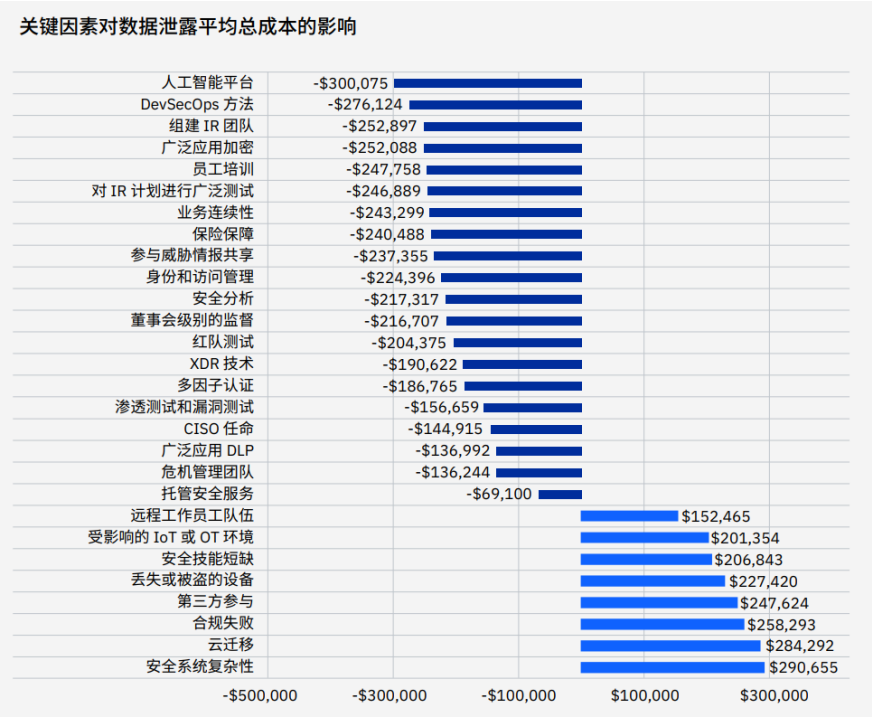

动态分析：

事实证明，大规模的数据泄露事件，往往都是由于一两个内部特权人员的一次恶意操作导致的，所以在数据安全建设方面优先加强对数据访问权限特别是对特权账号和特权行为的管控，是解决数据安全问题最快最有效的方式。

信息来源：

[1]知乎—数据泄露调查报告的要点
https://zhuanlan.zhihu.com/p/639502269?utm_id=0
[2]数据泄露成本报告
http://www.cyberandsecurity.cn/wp-content/uploads/2023/05/2022-%E5%B9%B4-%E6%95%B0%E6%8D%AE%E6%B3%84%E9%9C%B2%E6%88%90%E6%9C%AC%E6%8A%A5%E5%91%8A.pdf

2.10.4大数据平台安全

动态 1：2023 年多个主流大数据技术框架进行了更新，更新内容均涉及针对安全漏洞的修复，或以安全漏洞修复为主。2023 年公有云厂商数据安全产品有多个新

的功能更新。

动态内容：

本轮扫描包括了 Kfaka、Spark、Zookeeper、Hadoop、Hbase 等多个产品。具体情况如下：

产品	当前最新版本	发布时间	安全更新	地址
Kafka	V3.5.1	2023/07	自 0.9 版本起提供多项安全措施，最新版本修复多个安全漏洞，修复第三方依赖漏洞	https://kafka.apache.org/documentation/#security
Spark	V3.4.1	2023/07	2.X、3.X 等多个版本修复注入、XSS 等漏洞	https://spark.apache.org/security.html
ZooKeeper	V3.9.0	2023/08	修复多个第三方依赖漏洞，提供多个安全更新	https://zookeeper.apache.org/releases.html#release-strategy
Hadoop	release 4.0.0-beta-1	2023/08	修复多个第三方依赖漏洞，提供多个安全更新	https://issues.apache.org/jira/secure/ReleaseNote.jspa?version=12353351&styleName=Text&projectId=12310843
Hbase	3.0.0-alpha-4	2023	修复多个第三方依赖漏洞，提供多个安全更新	https://downloads.apache.org/hbase/3.0.0-alpha-4/RELEASENOTES.md

阿里云数据安全中心（Data Security Center）：为客户提供敏感数据自动识别、分级分类、大数据安全审计与数据脱敏等数据安全能力，形成一体化的云上全域数据防泄漏与安全解决方案，旨在帮助客户实现等保 2.0 二级有关“安全审计”与三级有关“个人信息保护”的合规要求的同时，并满足《数据安全法》中提出的有关要求。2022 年 11 月至 2023 年 4 月多次更新，提供了数据资产中心、数据标签标识、日志存储等多个功能。

动态分析：

随着《数据安全法》、《个人信息保护法》施行，各厂商依据相关要求加快了数据安全相关产品更新迭代频次，广联达应依据合规要求、社会责任等适当采用数据安全相关产品，依法合规、有效的保护公司和客户的数据资产。

信息来源：

[1] Apache
https://www。apache.org/
[2] 阿里云数据安全中心（敏感数据保护）

https://www.aliyun.com/product/security/sddp

3 大数据与相关技术的结合

本章扫描与大数据技术关联度大且与广联达数字建筑平台密切相关的 4 个技术方向的结合动态。第一个是关系最为密切的云计算技术，云计算是大数据技术的基础，大数据技术根植于云计算；第二个是 AI，大数据技术是 AI 技术发展的重要基础之一，为 AI 发展提供算力支撑；第三个是 IoT，大数据技术是 IoT 发展的重要基础技术之一，为 IoT 产生的海量数据提供强大的处理能力；第四个是 BIM，大数据技术与 BIM 技术结合的重要动态较少，本报告中不予表述。

3.1 大数据与云计算[姜建卫]

动态 1：头部云厂商在云原生的云数据仓库、云搜索服务、流式计算和数据治理细分领域不断发力，呈现多元化趋势；国内云厂商缩小与国外头部云厂商在大数据 Serverless 方面的差距，面向客户提供无服务器的数据库和数据分析服务，缩短用户开发大数据新应用周期，降低使用大数据技术的总体成本。

动态内容：

阿里云主要精力集中于持续增强已有产品能力：云原生大数据计算服务 MaxCompute、大数据开发治理平 DataWorks、实时计算 Flink、开源大数据平台 E-MapReduce、实时数仓 Hologres、检索分析服务 Elasticsearch。其中，云原生大数据计算服务 MaxCompute 发布更新共计 42 次，2023 年 3 月推出向量计算引擎 Proxima CE；大数据开发治理平 DataWorks 发布更新共计 35 次，2022 年 10 月智能数据建模支持新引擎 E-MapReduce Hive;实时计算 Flink 版发布更新共计 27 次，2022 年 10 月企业级引擎 VVR6.0.2 发布,2023 年 4 月首发 Apache Paimon 及 Flink Machine Learning 预览型功能;开源大数据平台 E-MapReduce 发布更新共计 24 次，2023 年 5 月 Serverless StarRocks 商业化发布；实时数仓 Hologres 发布更新共计 21 次，2023 年 2 月 Hologres 基于 Delta Lake 实现湖仓一体；检索分析服务 Elasticsearch 版发布更新共计 11 次，2022 年 12 月 Serverless 服务公测版发布。

华为云同样聚焦于持续增强已有产品能力——云数据仓库 GaussDB、数据治理中心 DataArts Studio、云搜索服务 CSS、数据湖探索 DLI 和 MRS。其中，云数据仓库 GaussDB 发布更新共计 38 次，2022 年 12 月 8.1.3.300 内核规模上线，作为

主推版本，2023 年 5 月 8.1.3.320 集群版本(推荐版)上线；数据治理中心 DataArts Studio 发布更新共计 26 次，2022 年 12 月新增支持 MRS ClickHouse 数据源，2022 年 6 月支持 MRS Hudi 整库迁移；云搜索服务 CSS 发布更新共计 18 次；数据湖探索 DLI 发布更新共计 12 次；MapReduce 服务 MRS 发布更新共计 7 次，2023 年 4 月上线 MRS 3.2.0-LTS.1 版本，新增 CDL、IoTDB 组件，ClickHouse、Flink、Hadoop 及 Hudi 组件内核升级。

腾讯云发布新产品大数据可视交互系统 RayData 和数据开发治理平台 WeData，并持续增强已有产品能力。RayData 是由腾讯云与光启元科技联合开发的大数据可视交互系统。基于独有的渲染技术，结合云计算、AI、IoT，将大规模多样化的数据融合呈现，实现云数据实时可视化、场景化以及交互的管理方式，从而节省管理成本，提升数据辅助决策的效率。数据开发治理平台 WeData（以下简称 WeData）是位于云端的一站式数据开发治理平台，融合了包含数据集成、数据开发、任务运维的全链路 DataOps 数据开发能力，以及数据地图、数据质量、数据安全等一系列数据治理和运营能力，帮助企业在数据构建和应用的过程中实现降本增效，数据价值最大化。Elasticsearch Service 发布更新共计 24 次，2023 年 2 月 Beats 支持 7.14 版本并发布发布 ES Serverless 版；数据湖计算 DLC 发布更新共计 11 次，2023 年 3 月 Spark 作业集群支持 SQL 任务；流计算 Oceanus 发布更新共计 11 次，2023 年 4 月 Oceanus 内核增强；弹性 MapReduce 发布更新共计 8 次，2023 年 2 月 StarRocks 支持 2.4 版本；云数据仓库 for Apache Doris 发布更新共计 7 次，2023 年 2 月内核 1.2 版本发布。

亚马逊云主要精力集中于持续增强已有产品能力。其中，Amazon QuickSight 发布更新共计 43 次，2022 年 11 月 Amazon QuickSight 开始支持与 Databricks 连接；Amazon EMR 发布更新共计 42 次，2022 年 10 月 Amazon EMR 版本 6.8 开始支持 Apache Flink 1.15.1，Apache Hudi 0.11.1 和 Apache Iceberg 0.14.0；AWS Glue 发布更新共计 42 次，2022 年 11 月 AWS Glue 4.0 发布；Amazon Redshift 发布更新共计 34 次，2022 年 11 月在 Amazon EMR 上发布适用于 Apache Spark 的 Amazon Redshift 集成；Amazon Kinesis 发布更新共计 23 次，2022 年 11 月适用于 Apache Flink 的 Amazon Kinesis Data Analytics 支持 Apache Flink 版本 1.15；Amazon Athena 发布更新共计 22 次，2022 年 11 月 Amazon Athena 开始支持 Apache Spark，2023 年 5 月 Amazon Athena 支持 Apache Hudi 0.12.2，2023 年

6月Amazon Athena for Apache Spark支持Apache Hudi、Apache Iceberg和Delta Lake;Amazon OpenSearch Service发布更新共计20次,2023年7月Amazon OpenSearch Service支持OpenSearch 版本2.7；Amazon Managed Streaming for Apache Kafka (MSK)发布更新共计16次，2023年5月Amazon MSK增加对Apache Kafka版本3.4.0的支持。

微软云主要精力集中于持续增强已有产品能力。其中，Azure流分析发布更新共计26次，2022年9月正式发布：流分析中的Azure Database for PostgreSQL输出；Azure机器学习发布更新共计17次，2023年5月构建正式版发布；Azure数据资源管理器发布更新共计17次，2023年6月正式发布：Azure Cosmos DB到Azure数据资源管理器Synapse链接；Azure Synapse Analytics发布更新共计11次,2022年11月正式发布:适用于SQL的Azure Synapse Link;Azure Databricks发布更新共计9次，2022年11月正式发布：Azure Databricks SQL Pro，2023年5月正式发布：适用于Azure Databricks的无服务器SQL。

谷歌云聚焦于持续增强已有产品能力。其中，BigQuery发布功能更新共计140次，2022年11月可以使用“LOAD DATA”语句将数据从Amazon S3和 Azure Blob Storage传输到BigQuery，2022年5月对象表正式发布，2023年6月BigQuery支持查询由开源引擎创建的Apache Iceberg表，2023年7月Spanner允许执行分析查询和数据导出，对所配置的Spanner实例上的现有工作负载几乎零影响；Looker发布功能更新共计36次，2023年4月当使用Databricks版本12.1或更高版本时，Looker支持Databricks连接的增量PDT；Cloud Composer发布功能更新共计32次，2023年7月Airflow 2.5.3在Cloud Composer镜像中可用；Cloud Data Fusion发布功能更新共计26次，2023年6月Cloud Data Fusion版本6.8.3发布;Dataproc发布功能更新共计25次,2023年1月添加了对 Dataproc Metastore与 Trino 集成的支持。

动态分析：

国内云厂商近一年大数据方面重点放在云原生的 Severless 技术组件、云原生MPP数据库、全托管搜索服务的发布和技术更新，加快拥抱Serverless架构，推广云原生MPP数据库和持续发力搜索服务。Severless方面,阿里推出StarRocks Severless 和 ElasticSearch Severless 版本，腾讯云发布 ElasticSearch Severless版本，国内云厂商缩小与国外头部云厂商的差距，面向客户提供无服务

器的数据库和数据分析服务，加快用户开发大数据新应用，降低使用大数据技术的总体成本。MPP 数据库方面，阿里云和腾讯云支持 StarRocks 的新版本，华为云发布 Doris 数据库服务。云搜索服务方面，阿里云、华为云和腾讯云加快更新完全托管云搜索服务,增强读写分离、存算分离、弹性伸缩、智能化运维等特性。

亚马逊云、微软云、谷歌云继续深耕云原生的细分领域大数据分析技术，提供更加强大开放的大数据集成、交互式分析、实时流数据处理等服务，持续增强 Serverless 服务的能力，面向更多的国家或地区的用户开放 Serverless 服务，相比于国内头部云厂商，国外头部云厂商 Serverless 技术和商业运作更精细、更成熟，为客户提供更加灵活的大数据技术服务。谷歌云重点放在 BigQuery 无服务器企业数据仓库能力提升方面，在 BigQuery 中内置机器学习/AI 和 BI 功能，实现大规模的数据分析。

云厂商提供的各种大数据 Serverless 服务，为构建大数据应用提供更多的选择，Serverless 服务让我们更聚焦于业务本身，具有总体成本优势，尤其在搜索服务、离线分析计算场景，建议优先选择公有云厂商提供的 Serverless 服务，降本增效。

Doris 和 StarRocks 成为云原生 MPP 数据库的新秀，腾讯、京东、美团、携程、滴滴等大厂采用 StarRocks 赋能 BI、实时数仓、用户行为分析等场景。广联达正在采用 StarRocks 构建实时数仓，遭遇诸多稳定性的问题。建议结合建筑行业大数据处理的场景特点，深入研究和分析 Doris 和 StarRocks 等 MPP 数据库的优劣势，做出更优的选择。

信息来源：

[1]阿里云-产品动态
https://www.aliyun.com/product/news?spm=5176.224200.J_9220772140.4.2d28586cBw6wrR
[2]华为云-产品新特性
https://www.huaweicloud.com/intl/zh-cn/productfeature
[3]腾讯云-产品动态
https://cloud.tencent.com/product/events
[4]亚马逊云-AWS 的新功能
https://aws.amazon.com/cn/new/?whats-new-content-all.sort-by=item.additionalFields.postDateTime&whats-new-content-all.sort-order=desc&awsf.whats-new-categories=*all
[5]微软云-Azure 更新
https://azure.microsoft.com/zh-cn/updates/

[6]谷歌云-更新说明
https://cloud.google.com/release-notes

3.2 大数据与 AI[张祺君]

大数据与 AI 动态扫描选择了主流大数据框架 Spark 和 Flink 中的机器学习库和近期开源社区比较活跃的新型分布式 AI 框架 Ray。

动态 1：基于大数据计算引擎的机器学习库趋于成熟，新型分布式 AI 框架 Ray 社区活跃度升高

动态内容：

Flink ML 是 Apache Flink 框架的机器学习组件，提供了算法接口以及基础类，以支持开发具有高易用性，高性能，低延迟的机器学习算法库。2023 年 05 月发布 Apache Flink ML 2.3.0 版本。

Alink 是基于 Flink 的机器学习算法平台，由阿里巴巴计算平台事业部 PAI 团队研发，同时支持批式/流式算法，提供丰富的算法库 帮助数据分析和应用开发人员能够从数据处理、特征工程、模型训练、预测，端到端地完成整个流程。2022 年 3 月发布 1.6.1 优化性能，修复 bug。

Spark MLlib 是 Spark 的机器学习库，由一些通用的学习算法和工具组成，包括分类、回归、聚类、协同过滤、降维等，同时还包括底层的优化原语和高层的管道 API。2023 年 6 月发布 Spark 3.4.1 包含最新版本 MLLib，Spark MLlib 比较稳定与之前版本几乎没有变化。

Ray 是 UC Berkeley RISELab 出品的机器学习分布式框架,它支持分布式数据处理、模型训练、调优、强化学习、模型服务等。Ray 程序可以在单台机器上运行，也可以无缝扩展到大型集群，支持在 Kubernetes、YARN 分布式运行。它支持多种人工智能算法框架，包含 Dask、MARS、Modin、Horovod、Hugging Face、Scikit-learn 等。近两年 Ray 版本发布频繁。2022 年 8 月发布了 2.0 版本，Ray 2.0 重点构建了整合 ML 生态的能力，提供了一套更易用的工具集给 ML 开发者（2023 年 7 月发布 Ray-2.6.1）。

Ray2.0 新特性如下：

1、整合 ML 生态 Ray AI Runtime：一个可扩展和统一的 ML 工具集通过 AIR，可以很方便地集成 Ray 原生的 ML 库和社区中常用的 ML 框架（如 Pytorch、Tensorflow 等）。用户只需要写少量的 python 代码，就可以很容地运行各种类型

的 ML 任务，而底层复杂的规模化协同计算由 Ray 来完成。

2、生产化能力：KubeRay 由字节、蚂蚁、微软等公司联合开发，可以帮助用户在 K8S 上很方便地部署基于 Ray 的作业和服务，可以完美替代之前的 Python Ray operator。KubeRay 在 2.0 版本中处于 Beta 发布阶段，是目前官方推荐的 Ray on K8S 最佳方式。

3、高可用能力：利用 KubeRay，可以很方便地部署一个 Ray Serve 集群。可以用“fail-over”模式部署 services，或者用“fully HA”模式部署 Ray cluster。在此模式下，任何的单点故障都不会影响 Ray 集群的可用性。

4、可观察性（Observability）工具：Ray 提供了一套全新的 API 帮助开发者查看 Ray 的运行状态，包括健康状态、实例、性能数据等。这套 API 目前处于 Alpha 阶段。

动态分析：

Spark/Flink 等传统大数据引擎机器学习功能趋于成熟，特性趋于稳定。新型分布式机器学习框架 Ray 社区活跃，尤其 Ray2.0 在整合 ML 生态情况下，提供的生产化能力、高可用能力和可观察性，简化 AI 平台的搭建，建议在实际项目中探索和验证其应用价值。

信息来源：

[1]Flink 官网
https://flink.apache.org/news/2022/01/07/release-ml-2.0.0.html
[2] Spark 官网
https://spark.apache.org/releases/spark-release-3-3-0.html
[3] ALink 网址
https://github.com/alibaba/Alink
[4] Ray 官网
https://docs.ray.io/en/latest/index.html

动态 2：Ray 背后的研发公司 Anyscale 发布 Aviary，旨在帮助开发人员简化为其项目选择和集成最佳 LLM 的过程

动态内容：

Aviary 建立在 Ray Serve 的基础上，Ray Serve 是该公司为包括 LLM 在内的人工智能应用程序提供服务和扩展的开源产品。Anyscale 表示，Ray Serve 提供生产级功能，包括容错、动态模型部署和请求批处理。Aviary 是为多 LLM 编排而设计的，能够随着时间的推移对 A/B 模型进行连续测试。该公司声称，该系统跨

GPU 划分模型，并实现跨异构计算的模型管理和自动缩放，以推动成本优化

Aviary 是一个 LLM 服务解决方案，可以轻松部署和管理各种开源 LLM。他提供一套开源 LLM，默认值开箱即用。支持托管在 Hugging Face Hub 或本地磁盘上的 Transformer 模型。在一个统一的框架内简化多个 LLM 的部署，在大多数情况下，将新 LLM 的添加简化为在几分钟内完成。提供独特的自动缩放支持，包括缩放到零，完全支持多 GPU 和多节点模型部署。提供高性能功能，如连续批处理、量化和流式传输。

从今年 6 月 1 日开始，在 GitHub 上 Aviary 先后发布了 v0.0.1、v0.0.2、v0.0.3、v0.1.0、v0.2.0 版本，有星标 609 颗、贡献者 16 位。

动态分析：

信息来源：

[1] Aviary 网址
https://github.com/ray-project/aviary

3.3 大数据与 IOT[刘光剑]

本小章重点扫描物联网大数据平台 Apache IoTDB 2022-2023 年范围内的产品或技术动态，考虑到广联达数据驱动业务创新，大数据能力与 IoT 能力整合，核心扫描的是 Apache IoTDB 在阿里 MaxCompute、华为云 MRS 的整合。

动态：2022 Apache IoTDB 物联网生态大会在线上圆满落幕。大会上发布 Apache IoTDB 的分布式 1.0 版本，并分享 Apache IoTDB 实现的数据管理技术与物联网场景实践案例，同时分享了 MaxCompute 基于 Apache IoTDB 构建的解决方案。

动态内容：

Lemming 是阿里云大数据平台 MaxCompute 基于 IoTDB 实现的物联网大数据计算解决方案，它主要包含三个模块。首先它具有 Apache IoTDB 的内核，它本身就是一个十分高效的 IoT 数据的存储和查询引擎。在这个基础上自研物化视图引擎和云边同步引擎，物化视图引擎负责完成边缘端数据计算的任务，云边同步引擎则负责实现数据从云同步到边的功能。

阿里云大数据平台 MaxCompute 基于 IoTDB 实现的 物联网大数据计算解决方案

华为云上线 MRS 3.2.0-LTS.1 版本，版本主要新增了 CDL、IoTDB 组件,无论华为云、阿里云，都在扩展与 IoTDB 对接的能力，代表 IoTDB 被生态的认可。

IoTDB 由清华大学发起的 100%开源项目，技术自主可控，属于 Apache 的顶级项目，有完善的文档和活跃的社区。IoTDB 是商业友好的，遵循 Apache 2.0 开源协议，它的本身生态也是十分丰富，可以无缝去集成其他主流的大数据系统，这意味着对于一个云产品来说，它在将来可以服务更广的用户，实现更广的需求解决方案。从技术上来看，它具有十分健壮的架构，它内置大规模并行处理框架，可以按需扩展。IoTDB 本身的性能也是十分优异的，它具有高数据的压缩率、低写入延迟和资源占用，十分适合边缘端物联网数据的处理。

动态分析：

广联达物联网平台基于 InfluxDB 时序数据库构建物联网持续聚合能力，基于开源自研集群模式，但是现在与大数据平台对接困难，需要数据再次迁移，建议将大数据生态较好的物联网数据库纳入选择范围。

Gartner 预测，到 2025 年，超过 50%的企业的关键数据将在数据中心以外或者云以外的地点创建或处理，这意味着任何的大数据解决方案不能再只限于云端。为了解决物联网时代数据分析需求，需要拓展自己的边界，将能力辐射到边缘端，以符合时代发展的需求。工业界的发展趋势也是从工业制造到工业“智”造，也就是说从单纯的工业生产变成智能化生产，这个转变过程也要依托于物联网大数据的技术能力才能实现。我们建筑行业，需要紧贴时代和市场的需求，拥抱变化，应对未来的挑战。

信息来源：

[1] Apache IoTDB 的分布式 1.0 版本发布
https://www.timecho.com/archives/2022-IoTDB-Summit-a-li-bai-jian-mai-xiang-wu-lian-wang-shi-dai-da-shu-ju-ji-suan-ping-ta
[2] 华为 MRS 组件更新 IoTDB

https://support.huaweicloud.com/wtsnew-mrs/index.html
[3] IoT DB 开源地址
https://www.oschina.net/p/iotdb?hmsr=aladdin1e1

4 大数据行业应用

4.1 数据标准[李会涛]

4.1.1 行业政策

工信部、住建部、科技部以及各个省市地区，在十四五新规划中陆续发布了多项 BIM 和数据相关的政策。新时期下，发展智能建造、推动工程项目全周期数字化应用，加快行业数字化转型、建立数据标准化基础成为未来一段时间的重要目标。这其中数据标准是众多政策的重要组成部分。

动态 1：国家政策层面积极推动数据标准相关工作

进入 2023 年，智能建造成为当前国家工程建设领域的重要国家战略，国家和地方陆续发布了多项政策，其中重点提到**智能建造、BIM 标准、装配式**等要素。

图 4-1 23 上半年二三维一体化的空间数据各地政策标准发布活跃度和关键词

动态 2：智能建造试点城市成为区域热点，工程行业数字化变革正在推广

2022 年 10 月住房城乡建设部发布了《关于公布智能建造试点城市的通知》。选取北京、天津、重庆等 24 个城市开展智能建造试点，积极探索建筑业转型发展的新路径，试点为期 3 年。近年来，我国建筑业生产规模不断扩大，国民经济支柱产业的地位持续稳固。但建筑业主要依赖资源要素投入、大规模投资拉动发展，工业化、信息化水平较低，生产方式粗放、劳动效率不高、能源资源消耗较大等问题较为突出。

试点城市名单如下：北京、天津、保定、河北雄安新区、沈阳、哈尔滨、苏州、南京、温州、嘉兴、台州、合肥、厦门、青岛、郑州、武汉、长沙、广州、深圳、

佛山、重庆、成都、西安、乌鲁木齐等 24 个城市开展智能建造试点。

试点目标包括三个方面：一是加快推进科技创新，提升建筑业发展质量和效益。二是打造智能建造产业集群，培育新产业新业态新模式。三是培育具有关键核心技术和系统解决方案能力的骨干建筑企业，增强建筑企业国际竞争力。

动态分析：

智能建造和建筑业新型工业化、数字化、绿色化转型、建筑业高质量发展是新时期建筑业的发展目标。广联达始终创业，勇挑行业发展的重任。

2022 年 9 月在广联达主导下，中关村数字建筑绿色发展联盟《数字化精益建造成熟度评价标准》启动会顺利召开，为行业首创的精益建造评价体系，建立了完善的评价模型和指标。是广联达提出的精益建造理念的最终诠释。

2022 年 12 月参与中国工程建设标准化协会的《智能建造与建筑工业化协同管理标准》编制工作，为行业智能建造发展提供了重要依据。

广联达积极主导或参与多项标准工作，成为行业标准领导者。

广联达 22-23 年主导或配合完成国家标准 7 件、行业标准 7 件、团体标准 54 件、地方标准 86 件、企业标准 10 件等多项标准。广联达定位数字建筑服务商，是行业数字化引领者，建议紧密关注政策标准新动态，配合政府做好顶层战略部署，积极参加相关政策调研、标准制修订等工作。更重要的是要与客户携手打造一批“智能建造”的标杆。

建议后续在工程建设行业的房建、基建领域积极参与各类标准编制和应用。重点关注行业智能建造、BIM 数据交换、BIM 全周期一体化等方面。重点参与国家标准、行业标准、重点城市和重点客户领域的有影响力标准工作。

信息来源：

[1]北京等 24 个城市将开展智能建造试点_滚动新闻_中国政府网建市函〔2022〕82 号
[2]广联达参与的住建部“智能建造发展水平评价指标体系研究“、“智能建造标准体系研究“课题顺利通过验收-公司新闻-广联达科技股份有限公司——数字建筑平台服务商，让每一个工程项目成功
[3]中关村数字建筑绿色发展联盟 《数字化精益建造成熟度评价标准》启动会暨第一次工作会成功召开_编制工作_精益_评价

4.1.2 行业通用数据标准

动态 1：清华大学发起的国标 BIM 通用数据标准标准（5 项系列标准）

2023 年 1 月由工信部信发司和质安司主管，由标准四院、信通院和清华大学发起，联合 30 多家单位。广联达作为第一参编单位，参编《信息技术 BIM 软件》系列 5 项国标。该标准是有全国信息技术标准化技术委员会发起的 BIM 国标系列的底层标准，将为我国 BIM 技术的底层研发和应用筑牢基础。

5 项标准名称	标准简要介绍
应用参考架构	本标准致力于制定适用于我国的 BIM 软件的应用参考架构，明确 BIM 软件的基本概念、功能定位、互通性要求、数据汇交要求，以协助 BIM 软件的需求定义、开发实现、互联互通，促进我国 BIM 软件行业形成完整的开发与应用环境。本标准也明确 BIM 软件与本系列各项标准以及其他相关标准的关系。
参数化模型（广联达主编）	本标准规定了在应用 BIM 技术的项目中，机电、建筑以及结构专业通用构件的几何形体的信息表达，以及描述该几何表达所需要的参数和定位坐标信息。对于机电、建筑以及结构专业非通用性的构件，本标准提供相应的参数描述方法以及局部坐标系定义方法来提供指导。
模型视图定义	本标准规定了模型视图定义的内容和表示方法，规定了协同工作过程中，通过模型视图定义方式完成模型数据交换的基本框架，描述了模型视图定义在数据交换过程中的应用方法和对软件工具的要求，并提供了一个轻量级的模型视图定义语言，以及有关此语言的概念、路径和规则。
网络模型	本标准适用于支持构建 BIM 的轻量化文件，也适用于支持开发相关应用软件，对符合本标准的网格模型文件进行读取、创建及修改等操作。
数据接口	本标准规定了在应用 BIM 技术的项目建设中，依据统一数据环境进行开放数据交换的基本原理，规范了统一数据环境的组成部分和核心功能，制定了对统一数据环境数据进行访问的标准接口与数据结构，支持跨系统

	级别的数据共享交换

动态 2：中国工程建设标准化协会立项《建筑信息模型工业基础类》系列 9 项标准 IFC 转译标准工作正式启动

2023 年 3 月 14 日，中国工程建设标准化协会在北京召开建筑信息模型工业基础类和建筑与土木工程基本语义 9 项系列标准启动会。系列标准由中国建筑标准设计研究院有限公司（简称标准院）、铁路 BIM 联盟、中交第二航务工程勘察设计院有限公司、中国建科所属中设数字技术有限公司、中国建筑第八工程局有限公司、西安建筑科技大学、北京市政路桥股份有限公司等 94 家单位共同编制，包括《建筑信息模型工业基础类：通用》、《建筑信息模型工业基础类：建筑》、《建筑信息模型工业基础类：铁路》、《建筑信息模型工业基础类：水运》、《建筑信息模型工业基础类：施工》、《建筑信息模型工业基础类：古建筑》6 项 BIM 基础类标准，《建筑与土木工程基本语义：通用》、《建筑与土木工程基本语义：建筑信息化》、《建筑与土木工程基本语义：碳排放与可持续发展》3 项机器可读标准。**广联达重点参与了【通用】【建筑】2 项标准。**

动态 3：基于国际 IFC 标准，国内多个省市地区 尝试本地化扩展定制

2022 年 5 月由清华大学联合前海管理局、广联达、万翼科技等单位共同编制发布了 SJG114-2022《深圳市建筑信息模型数据存储标准》。该标准是基于国际 IFC4，结合政府的 BIM 监管场景，扩展定制的深圳 IFC 数据标准和格式。**广联达作为软件公司第一参编单位编制了其中重要的《可视化章节》和格式软件平台验证工作。**

2023 年 8 月由丁烈云院士主导，由湖北省住建局主管，由华中科技大学联合多家单位共同组建了尖刀项目专项工作组，通过课题推动编制湖北的【IFC 标准】（即 HIFC）。目前本项工作正在进行中，预计 23 年年底完成 HIFC 的编制和 MVD 适配、示范等。

动态分析：

广联达积极参与国标、行标及 BIM 行业通用数据标准，是引领行业标准建设的又一重大里程碑。

广联达积极参与国标、行标的编制工作，发挥企业 ESG 的责任和行业影响力。广联达通过参加相关标准，推动行业高质量发展，形成对行业的引领，彰显行业领导者地位。为后续公司 BIM 相关的平台软件铺路，为营造 BIM 技术市场氛围，提升

产品的品牌溢价等方面，提供了强有力支撑。

信息来源：

[1]首页-全国标准信息公共服务平台（检索“信息技术 BIM 软件 ”关键词）
[2]http://zjj.sz.gov.cn/attachment/0/979/979105/9822299.pdf
[3]中标研业务函〔2023〕224 号协会标准《建筑信息模型工业基础类：通用》等 9 项标准编制组成立暨第一次工作会在京顺利召开_中国工程建设标准化协会

4.1.3 工程全生命周期数据标准落地应用

动态 1：新版《建筑工程人工材料设备机械数据标准》在陕建集团落地应用

2013 年,广联达主导的《建筑工程人工材料设备机械数据标准》国标已经发布近 10 年，行业应用广泛，也进入了修订周期。进入 2022 年，该标准结合业务进行了重大升级迭代，升级迭代后的标准在陕西建工集团有限公司客户中上线应用，取得了良好的效果。

动态 2：广联达建筑信息模型数据交换格式 GFC 标准迈向行业发展

由广联达和中国标准院联合发起，在中关村数字建筑绿色软件联盟正式立项的《建筑工程信息模型数据格式标准》即 GFC 数据标准，正式立项通过。2023 年 8 月，广联达联合 4 地的 12 家单位共同召开本标准的启动会议。该标准的编制及后续应用，标志着广联达数据标准 GFC 正式迈出了行业普及应用的第一步。

广联达 GFC 标准发布后，第一时间在工信部的建筑信息模型软件开发及产业化项目，湖北省科技厅“建筑全生命周期国产自主数字化管理平台研发”尖刀项目和湖北省住建局 BIM 云平台建设中推进落地。

动态分析：

国内建设行业，多年来一直无法打通设计、成本算量造价两个环节的数据流，成为行业数字化发展的“顽疾”之一。如何实现设计、算量、成本数据的无损传递、直观便捷的跨阶段协同，是数字设计下一阶段的发展重点。

广联达先后参与了 BIM 正向设计软件、工程施工工料机、全过程造价等多项数据标准编制，未来要打通多阶段基于 BIM 的“一模到底”应用。广联达通过房建+基建的设计算量一体化解决方案，围绕 GFC 通用数据交换标准，形成了行业上下游衔接的产业互联网平台体系架构和标准体系。基于此可实现行业基础资源标准化、平台和业务接口标准化、数字设计与智能建造的标准化评估认证等一系列关键

成果，以数据驱动设计岗位、企业项目、行业监管等信息要素的动态融合和资源高效应用。

信息来源：

[1]广联达《数字设计 2023》白皮书正式发布-公司新闻-广联达科技股份有限公司——数字建筑平台服务商，让每一个工程项目成功
[2]广联达基建设计算量施工一体化方案重磅亮相-公司新闻-广联达科技股份有限公司——数字建筑平台服务商，让每一个工程项目成功
[3]联盟动态 ｜ 8 月 24 日《建筑工程信息模型格式标准》编制组成立暨第一次编制工作会议圆满结束

4.2 数据中台[刘松]

动态 1：“数据二十条”出炉！数据要素开启产业化大时代

动态内容：

2022 年 12 月中共中央、国务院发布《关于构建数据基础制度更好发挥数据要素作用的意见》，从数据产权、流通交易、收益分配、安全治理四方面，提出 20 条政策举措。

《意见》指出，数据基础制度建设事关国家发展和安全大局，要探索有利于数据安全保护、有效利用、合规流通的产权制度和市场体系，完善数据要素市场体制机制，促进形成与数字生产力相适应的新型生产关系。坚持共享共用，释放价值红利。合理降低市场主体获取数据的门槛，强化反垄断和反不正当竞争，形成依法规范、共享红利的发展模式。建立保障权益、合规使用的数据产权制度；建立合规高效、场内外结合的数据要素流通和交易制度；建立体现效率、促进公平的数据要素收益分配制度；建立安全可控、弹性包容的数据要素治理制度等；初步搭建了我国数据基础制度体系；充分激活数据要素价值；赋能实体经济发展；激活市场主体活力；推动构建新发展格局；促进高质量发展。

同时，推动数据要素供给调整优化，提高数据要素供给数量和质量。建立数据可信流通体系，增强数据的可用、可信、可流通、可追溯水平。实现数据流通全过程动态管理，在合规流通使用中激活数据价值。

《意见》强调，统筹发展和安全，划定监管底线和红线。加强数据分类分级管理，形成政府监管与市场自律、法治与行业自治协同、国内与国际统筹的数据要素治理结构。

动态分析：

“数据二十条”的出台标志着数据治理领域正向数据要素时代演化，其中的逻辑就是数据在广泛的流通和互联，数据不光是在企业内部要流动，在不同企业之间也要流动起来，这种流动的需求是普遍的。数据要素时代数据治理的体系相较于之前也是不一样的，因为不光是一个企业内部数据治理的问题，还涉及到不同组织机构之间的数据治理问题。其中任何一个主体如果有安全、合规和治理的短板，那么数据就会流走，在数据要素时代，数据治理的挑战在于如何通过完善的流程、标准、制度、治理工具解决复杂场景下数据资产治理沉淀的问题，同时在产生高价值的数据资产的前提下，如何通过高度安全的制度、体系解决数据资产交易的问题。

长远来看，广联达的数据治理工具应该关注数据资产的沉淀能力，数据资产的交易安全等能力建设。

信息来源：

[1] “数据二十条”出炉！数据要素开启产业化大时代
https://finance.eastmoney.com/a/202212192592005078.html
[2]中共中央、国务院最新发布！“数据二十条”出炉！构建数据基础制度体系
https://fund.eastmoney.com/a/202212202592044251.html

动态 2：效率优先，DataWorks 全链路数据治理年度发布

动态内容：

大数据开发治理平台 DataWorks 基于阿里云 ODPS/EMR/CDP 等大数据引擎，为数据仓库/数据湖/湖仓一体等解决方案提供统一的全链路大数据开发治理平台。

在 2022 年 11 月云栖大会上，DataWorks 以“效率优先，回归工具为人服务的本质”为主题介绍了 DataWorks 端到端的全链路数据开发治理平台新能力。介绍从规范化、实时化、智能化的数据开发平台，低代码、可视化的数据分析与服务，主动式、持续式的全链路数据治理和开放、可扩展的企业级数据平台四个方面，分享了 DataWorks 的新特性。

今年的云栖大会上，也有众多客户展现了他们利用 DataWorks 及各类大数据引擎实现的数字化转型最佳实践。友邦人寿基于阿里云搭建金融数据中台，承接了 10 倍业务流量的高峰，让数据处理效率提升 20 倍，企业整体算力成本节省达数百万。“非洲之王”传音互联有力支撑集团互联网业务，数据治理效率提升 2-3 倍，为集团 95%以上的业务增长赋能，带领更多中国企业品牌走向全球新兴市场。哪吒汽车逐步完善数据治理与数据湖能力，依靠稳定可靠、性能卓越、弹性扩展的大数据平台，未来将支持超过 60 万+量汽车，数 PB 级别的数据分析。三七互娱以 DataOps

理念激活数据价值，建设自动化、敏捷、价值导向的数据体系，解决数据获取难、业务响应慢、数据场景单一等数据消费的痛点，利用数据驱动运营精细化。数据治理是一个庞大的话题，涉及的方面非常多。但是还是回到我们的主题，效率优先，回归工具为人服务的本质。今年 DataWorks 发布全链路数据治理的一些新功能，就是从人的视角出发，希望通过工具平台，让企业的开发人员减少低效的重复劳动，让数据人员的工作效率保持螺旋式的上升，全方位提升企业数据效率，为企业降本增效。

Aloudata（大应科技）是一家智能湖仓平台提供商和数据编织(Data Fabric)解决方案提供商，其产品深度实践 Data Fabric 架构，更多关于 Data Fabric 的行业洞察参考本报告章节 2.1：大数据软件架构技术。2023 年大应科技发布基于算子级血缘的主动数据治理平台 BigMeta。Aloudata BigMeta 可自动采集全链路元数据，并可对 SQL 进行高精度解析，无论再复杂的数据网络、再大的数据规模，BigMeta 都可基于任务脚本、执行日志等元数据自动构建算子级数据血缘、抽取字段加工口径，准确率达 99%以上。结合 BigMeta 的字段口径穿透、加工链路比对、重复资产识别、分类打标扩散等能力，数据团队可十倍提升数据资产盘点效率，彻底摆脱纯人工、运动式分析字段口径、梳理上下游依赖等低价值繁琐工作，专注数据资产建设及数据价值创造。

动态分析：

对于数据治理行业未来的判断，目前可以明显看到的几个数据治理趋势有：

1．政策法规不断完善

国家发布了各类培育统一的数据要素市场指导建议与法律法规，未来数据产权制度、流动交易制度、收益分配制度、安全治理制度等将不断完善，指导数据治理平台在各个方面不断补充平台能力。

2．开发治理一体化

先开发后治理，肯定会逐步退出历史舞台，所以后续所有治理工作应该事先融入开发的过程，而不是“先污染后治理”，生产运维、生产治理要实现一体化管理。

3．自动化数据治理

刚才我们提到的数据治理涉及多个模块，多个操作，如果未来我们将模块与模块之间、功能与功能之间、操作与操作之间，实现流程的自动化，例如：元数据自动发现、自动采集、自动打标、自动归类等，同时对应匹配一些智能化的数据治理策略或者模板，将会极大提高我们数据治理的效率。

信息来源：

[1] 效率优先，DataWorks 全链路数据治理年度发布
https://developer.aliyun.com/article/1151960?spm=5176.14066233.J_5954153390.1.74079325YA7Yvx
[2] 网易数帆发布开发治理一体化 Dataeasy7.0
https://baijiahao.baidu.com/s?id=1754799683561363201&wfr=spider&for=pc
[3] 华为开发治理一体化产品 DataArts Studio
https://www.huaweicloud.com/product/dayu.html
[4]BigMeta-基于算子级血缘的主动数据治理平台
https://www.aloudata.com/products/big

4.3 CDE[刘光剑]

本小章重点扫描 Bentley、Autodesk 等厂商 2022-2023 年基于 CDE 的产品更新，通过 CDE 在产品中更新迭代，为广联达的在 BIM 协同设计、GDE 建设提供参考。

CDE 是一种“理念”，不是技术方案，支撑 CDE 可以有多种方案，主要服务于协作和共享场景，为各参与方提供实时、真实、全面的单一数据源，协作产生价值。CDE 改变了数据交互的方式，由网络型改为中心型，统一交互标准，减少了交互类型，便于管理，CDE 正在向更加智能化、开放、安全、易于使用发展，同时也在应用于其他领域。

动态 1：Bentley OpenRoads/OpenRail For China 中国版本发布 2 季度版本

Bentley CDE 为最成熟的 CDE 产品，因为 ProjectWise 的发展一定程度共享了一部分 CDE 的理论体系，其所覆盖的可管理的文档类型和阶段相对全面，OpenRoads/OpenRail For China 中国版本，是由 ProjectWise 和工作空间共同组成的协同环境 CDE，为 Bentley 构建适合中国基础设施项目的专业级信息模型创建和开发平台，道路工程项目专业级产品，2023 Q2 季度 SDK 正式发布。使用统一的工程数据表达和存储，跨专业、跨阶段传递时无障碍，原生支持与 iTwin 数字孪生数据持续同步。

Autodesk Docs 是一种通用数据环境,是 Autodesk 在 CDE 能力上核心组件，可集中处理以下产品之间的项目信息：Autodesk Construction Cloud（ACC）平台产品、Autodesk Build、Autodesk BIM Collaborate/Collaborate Pro 和 Autodesk Takeoff。这些产品中的“文件”工具包含的文件和更新与 Autodesk Docs 中的“文件”工具相同。

2022 年 11 月至 23 年 5 月，Autodesk® Docs 共发布 4 个版本，更新近 30+功能点，核心聚焦在文档在协作过程中的命名、审批、权限、通知等能力的优化,没有更新迭代突出能力。目前 AutoDesk 的 CDE 更新方式已经趋于稳定，近 2 年没有突破式的更新。

在 BIM 出现后，国内一直有 CDE 意识形态的产品存在，“BIM 协同平台”、“项目协同管理平台”等，这些平台类产品在某程度上都包含了对文档、图形、数据的管控，CDE 在国内的意识形态还没有统一，在国外代表产品中，CDE 重点聚焦在文件的协同管理，通过分析欧特克、本特利 2 个代表厂商在近一年 CDE 能力更新，没有超出这个范围，在数据方面关注点仍然为数据协同，这方面也跟国外建筑行业的应用重点相关

动态分析：

将 CDE 能力划分文件协同、数据协同、业务数据融通协同三个层面,广联达构建 GDE 能力，聚焦在数据协同和业务融通协同，符合国内和广联达业务现状，在建筑业务平台能力基础上，将建筑全过程、全要素、全参与方数据汇聚在统一环境，通过数据要素->数据框架->XBS->数据图谱的业务设计和 BIM 语义等技术，实现各业务数据快速关联，业务融合互通，直接提升广联达业务一体化能力和数据智能能力。

信息来源：

[1]OpenRoads 官网
https://openroads.com.cn

[2]Autodesk Docs 官网
https://help.autodesk.com/view/DOCS/CHS/?guid=About_Autodesk_Docs

4.4 IOT[刘光剑]

本小章重点扫描阿里、腾讯等云服务厂商 2022-2023 年的物联网相关的产品、解决方案动态，结合头部厂商动态，为广联达在产品方向，解决方案落地上带来参考。

动态 1：腾讯云重磅推出 WeBuild 建筑云解决方案，聚焦建筑建造、地产物业、城市与片区更新等三大地产子行业

2022 年腾讯全球数字生态大会智慧建筑与不动产专场上，腾讯云重磅推出三大智慧建筑与不动产行业解决方案，聚焦建筑建造、地产物业、城市与片区更新等三大地产子行业。

在建筑建造领域，腾讯云以“连接 3 亿产业从业人员”以及“先进的数字孪生和技术平台”为核心竞争力，推出了 WeBuild 建筑云解决方案。依托建企 IDC、专区托管云、行业供应链/电商-区块链、建企信息数据安全等产品技术，WeBuild 建筑云打造了建筑业“新基座”，并在此之上搭建融合 BIM/CIM 的数字孪生平台、基于企微的建企协同平台、基于 AIOT 的智能建造平台、基于大数据的建企数智中台等四大能力平台，助力建筑业全要素数字化提升，推进行业向工业化、绿色化、智能化转型升级。

信息来源：

[1]腾讯 WeBuild 解决方案官网
https://cloud.tencent.com/solution/webldlink
[2]腾讯发布 WeBuild 建筑云解决方案
https://baijiahao.baidu.com/s?id=1750986058496319694&wfr=spider&for=pc

动态 2： 阿里云打通物联网平台与 DataWorks,实现 DataWorks 中进行物联网数据分析

2023 年 3 月阿里云-物联网平台发布新功能，支持通过 DataWorks 的数据源配置，将设备上报的数据或经过物联网平台数据处理后的数据流转 DataWorks 中，打通到阿里云大数据产品的数据链路。自定义存储表支持设置分区字段，从单表支持 3000 万行数据提升为单个分区可以支持 3000 万行数据，大幅提升单表的数据存储容量限制和读写性能。优化了数据解析和热数据存储两个功能的控制台交互体验，降低数据服务的使用门槛。

物联网平台的数据服务可以将预处理的数据流转到阿里云数据总线，再结合阿里云实时计算、离线计算等大数据分析工具，为企业提供数据可视化、数据分析服务，帮助企业管理者与运营人员更好地管理自身业务。

信息来源：

[1]阿里云-物联网平台 - 数据服务升级和体验优化
https://www.aliyun.com/product/news/detail?spm=5176.12418106.J_7503465570.10.75f25d35HQBeqp&id=23212
[2]阿里云-物联网平台创新案例分享
https://developer.aliyun.com/article/1224734?spm=a2c6h.14164896.0.0.733e73dcKYjsTW

动态分析：

在十四五规划的背景下，头部云服务厂商，在对外提供能力时，从整体上会推出多平台能力的联合解决方案，支撑行业的数字化、智慧化、绿色化的转型方案，单一能力已不能满足需求。

广联达基于建筑业务平台，结合平台多技术能力，面向行业开放平台技术、业务、数据、连接和生态能力，全面提升企业数字协同、智能驱动和产业互联水平，实现点线面体的系统性数字化转型。

4.5 BIM[刘光剑]

本小章重点扫描联想、火山引擎等厂商 2022-2023 年基于 BIM+大数据方案实现智慧城市方案。

动态 1：联想方案服务业务集团宣布推出国内首个绿色智慧城市解决方案，该方案以新 IT 和绿色能源为主线，建设数字底座，以新型能源结构为保障的绿色智慧城市

联想首推绿色智城解决方案，在 2023 年 6 月《互联网周刊》公布的《2022-2023 智慧服务 TOP50》中跻身前九，聚焦绿色智慧生活（智慧民生）、绿色智慧政务（数字政务、公共安全、城市数字基础公共设施）、绿色智慧园区（智能制造、智慧园区、智慧能源、智慧金融）、绿色基础设施（智慧教育、智慧医疗）四大关键场景，提出了“一个平台”和“两个架构”的思路。

“一个平台”即城市级数字孪生平台，是用数字孪生技术开发的城市运营管理中台，即以推动城市空间、城市部件、城市运行动态的数字化为目的，将建筑信息模型（BIM）、地理信息系统（GIS）和物联网（IoT）等多项技术统一集成的开放式城市信息模型（CIM）平台

动态 2：iBUILDING 美的楼宇数字化平台和火山引擎公有云的融合对接

近日，火山引擎与美的楼宇科技达成合作，双方将对上海抖音集团新江湾城办公园区进行智慧化改造，此次接受改造的园区面积达 28 万㎡，旨在将其打造成为全球智慧园区标杆项目。以合作园区为样板，双方将不断打磨和提升产品能力，探索智慧园区数字化产品市场共研、共赢之路。此次合作，将实现 iBUILDING 美的楼宇数字化平台和火山引擎公有云的融合对接，实现云平台间、不同设备层面的数据连接。

动态分析：

十四五”数字经济发展规划正式下发，为各类产业园区智慧化建设提供了“技术变革之机”。而数字化转型，不仅局限于产业园区的数字化管理，更是要打造数字经济产业生态空间。

信息来源：

[1]联想推出绿色智城解决方案
https://521dj.com/37123.html
[2]火山引擎与美的楼宇科技达成合作
https://www.sohu.com/a/586267902_121123910

4.6 数据智能[杨思羽]

动态 1：BI 软件在数据分析过程中集成机器学习能力，用于商业预测和建议；数据库集成 AI 分析功能，可以为数据驱动的智能应用提供一体化的数据服务。

2022 年 Qlik cloud 上发布 Qlik AutoML 模块，能自动识别历史数据中的关键驱动因素，并选择最佳算法生成机器学习模型，方便的集成到分析过程中提供预测、

关键因素分析和建议。也可以集成 Amazon Sagemaker，Azure ML 等第三方平台上准备好的模型。2021 年 Tableau 集成了 Salesforce 的 Einstein Discovery 模块，无需编写任何代码即可创建可信的机器学习预测模型，在 Tableau 工作流中提供预测和建议。2022 年 9 月发布的永洪 BI V10.0，在深度分析领域继续进行深耕，新增了回归、移动平均、高斯混合聚类、孤立森林等算子，同时新增了后台运行支持，子节点支持等功能，提升了深度而分析模块的易用性。

2022 年 7 月，阿里云云原生数据库 PolarDB 新增 PolarDB forAI 功能。PolarDB for AI 是基于的一个数据库内的分布式机器学习组件。其基于云原生的体系架构，通过 SQL 语句的方式提供了支持机器学习的一系列 MLOps，包括：创建模型、训练模型、查看模型状态、查看模型列表和模型推理等能力；同时 PolarDB for AI 提供了一系列内置的机器学习和人工智能算法，包括：分类算法、回归算法和聚类算法等。基于 MLOps 和内置的模型，PolarDB for AI 为数据驱动的智能应用提供了高效、可靠、方便的数据智能能力，打破了数据库和业务应用之间的系统墙，提供了基于数据库数据智能的一站式服务。

DB-engines 评选的 2022 年度数据库第一名 Snowflake，于 2023 年 6 月推出 Snowpark ML 的预览版。Snowpark ML 是一套 Python 工具，包括 SDK 和底层基础架构，用于在 Snowflake 中构建和部署机器学习模型。该预览版包括基于 scikit-learn、xgboost 和 lightgbm 等流行机器学习库的预处理和建模类。同时，Snowflake 还发布三款由机器学习算法驱动的新分析工具：预测，异常检测，贡献度浏览。这三种功能可对时间序列数据进行机器学习模型训练，以确定指定指标随时间的变化情况以及相对于其他特征的变化情况，并且会根据数据中检测到的趋势提供见解和预测。

2023 年 6 月 Google Cloud 的 Spanner 数据库服务发布 Spanner Vertex AI 集成功能，可通过 GoogleSQL 接口访问托管在 Vertex AI 上的分类器和回归机器学习模型。这有助于将机器学习预测服务功能与使用 DQL/DML 查询执行的常规 Cloud Spanner 数据访问操作无缝集成。

动态分析：

在过去几年，数据驱动的智能应用已经逐渐从基于简单的数据分析和统计转型为基于机器学习和深度学习的特征和模型应用。信通院发布的《2022 年大数据白皮书》指出数据应用正快速从感知、诊断向研判智能决策延伸，自动决策将成为

数据应用的主要形态。为了应对智能化的趋势，数据链路上的各个环节，包括数据库、BI 软件，都在增加支撑数据智能分析和应用的相关功能，从而提供一体化的数据智能解决方案。

目前广联达在数据智能应用层面，还处于比较基础的数据分析和统计，以感知和诊断企业运作为主，在通过机器学习和深度学习挖掘数据潜在价值方面，发力不多；此外，目前的数据分析也以人工为主，并无数据智能分析的探索，在技术前沿方面落后较多。广联达可以适当投入资源，进行探索，形成一定的技术积累，为未来的深度数字化和智能化积蓄力量。

信息来源：

[1]Qlik AutoML
https://help.qlik.com/zh-CN/cloud-services/Subsystems/Hub/Content/Sense_Hub/AutoML/home-automl.htm
[2]永洪BI
https://www.yonghongtech.com/help/Z-Suite/10.1/ch
[3]PolarDB for AI
https://help.aliyun.com/document_detail/439225.html?spm=a2c4g.439727.0.0.70dc6c58vtdha6
[4]Snowflake ML
https://docs.snowflake.com/developer-guide/snowpark-ml/index
[5]Google Spanner
https://cloud.google.com/spanner/docs/ml?hl=en

4.7 智慧城市[莫覃华]

动态 1：智慧城市对大数据的需求主要集中在空间大数据分析和支持城市孪生的数据融合上，在异构的时空数据分析上，受限于传统数据库对时空大数据原生处理能力的不足，开始出现融合数据库。

城市数据可以按照内容特征分为三个主要类别：空间数据（包括 BIM 和 GIS 数据）、时序数据（即设备实时数据）以及结构化数据（也就是业务数据）。在传统的空间数据库中，我们常常使用 PostGIS 作为典型代表，该数据库能够有效地存储和分析二维 GIS 数据。然而，随着智慧城市建模技术的发展，三维模型在城市规划中的应用日益普遍。因此，为了满足对二三维空间数据进行更全面的分析和展示的需求，二三维一体化的空间数据库应运而生。随着城市管理的精细化进行，单纯的空间数据展示已经无法满足需求。如今，对于城市数据管理的要求已经演变为将时

空数据与业务数据进行整合和融合的场景。这种融合将有助于提升城市数据的综合分析和决策能力，为城市管理者提供更全面、更准确的信息基础，以支持城市规划和决策制定的需要。因此，城市数据平台在满足空间数据分析和展示的同时，也需要具备处理和整合时序数据以及结构化数据的能力，行业内各厂商都在探索支持异构数据分析的融合数据库。

1. 阿里 Ganos 全空间数据库

阿里云自研 Ganos 时空引擎（以下简称 Ganos）提供一系列的数据类型、函数和存储过程，用于在云原生关系型分布式数据库 PolarDB 中对空间/时空数据进行高效的存储、索引、查询和分析计算。

2023 年 7 月发布 Ganos V5.7 版本，GeomGrid SQL 新增 GeoSOT 三维网格码功能。

2023 年 5 月发布 Ganos V5.6 版本，支持 Geometry3D 数据的三维矢量切片；

2023 年 4 月发布 Ganos V5.5 版本，增强 ST_MosaicFrom 函数，支持并行操作；增强 ST_MosaicFrom 函数，支持不同分辨率/投影影像镶嵌。

2023 年 3 月发布 Ganos V5.4 版本，新增 ST_ClusterDBSCAN 函数，支持在经纬度坐标下计算 DBScan 聚类;新增 ST_CurveRecognize 函数,识别轨迹中的弯道、转弯半径。

2023 年 1 月发布 Ganos V5.3 版本，PostGIS 插件兼容性升级到 3.3.2；新增 ST_Angle 函数，支持将轨迹的每一个转角的角度作为数组输出。新增 ST_CurvatureRadius 函数，支持将轨迹的每一个转角的转动半径作为数组输出。

2022 年 11 月 Ganos V5.0 实现了孪生全空间数据库的重磅升级，解决了全空间位置大数据使用流程复杂、使用门槛高、应用效率低等问题，为应对 XG(5G/6G)、数字孪生与物联网快速发展，构建云上空天地网立体化、全空间数据管理提供了核心基础能力。

2. 星环分布式时空数据库（Transwarp Spacture）

支持大规模矢量数据、时空轨迹数据的存储与计算，具有完备的数据查询、分析和挖掘能力，可用于时空查询分析、时空模式挖掘、时空轨迹聚类等时空轨迹数据分析场景，广泛应用于疫情防控、交通物流、城市管理、位置服务等场景。

3. YMatrix 超融合数据库

YMatrix 是四维纵横（YMatrix）基于 PostgreSQL/Greenplum 经典系开源数

据库开发的超融合数据库产品。除游刃有余应用于时序场景，它还同时支持在线事务处理（OLTP）、在线分析处理（OLAP）等经典场景。

2023 年 3 月发布 YMatrix 5.0.0 GA 版本。采用全新数据库架构，新增向量化执行引擎和平滑扩容功能，采用 Runtime Filter 查询性能优化技术，新增编码链压缩算法。

4. 超图 Yukon（禹贡）二三维一体化时空数据库扩展

Yukon（禹贡）是超图公司开源的空间数据库扩展，基于 openGauss 数据库扩展地理空间数据的存储和管理能力，提供专业的 GIS（Geographic Information System）功能，赋能传统关系型数据库。

2022 年 6 月发布 Yukon 2.0 版本。新增矢量金字塔模块，支持图数据存储能力，实现图与空间一体化存储，新增路由(pgrouting)、点云(pointcloud)模块，新增轨迹(mobilitydb)、拓扑(postgis_topology)模块，新增新增聚合函数 st_makeline、st_collect、st_asmvt、st_polygonize。

动态分析：

随着城市 BU 业务的深入发展，城市 BU 的产品已经从简单的数据展示逐渐演进为融合分析的方式。在过去，BIM、二维 GIS、三维 GIS、物联网（IoT）和业务数据都分散在各个独立的系统中，并且数据也是独立管理。然而，这种烟囱式的数据管理模式已经无法满足当前对精细化管理的需求。因此，城市全域数据的一体化融合分析已经成为新一代智慧城市的标配。

2023 年，城市 BU 也正推进建立二三维一体化的空间数据库。这一举措的目的是实现 BIM+GIS 数据的统一管理，从而实现空间数据的融合。同时，通过采用异构引擎的方式，城市信息管理（CIM）数据中台实现了空间数据、时序数据和业务数据的二次融合，最终形成 CIM 对象。这样的一次次融合分析，将为城市业务部门提供更加全面、准确的数据支持，促进精细化管理的实施。

信息来源：

[1]阿里 Ganos 全空间数据库
https://developer.aliyun.com/group/Ganos
https://developer.aliyun.com/article/1095485
https://www.alibabacloud.com/help/zh/apsaradb-for-rds/latest/release-notes-for-ganos
[2]星环分布式时空数据库
https://www.transwarp.cn/subproduct/spacture

[3]YMatrix 超融合数据库
https://www.ymatrix.cn/
[4] Yukon（禹贡）
https://www.ymatrix.cn/

4.8 数字孪生[杨思羽]

动态 1：大数据技术广泛应用在数字孪生领域的数据底座建设和时空计算服务

动态内容：

数字孪生领域中大数据技术主要应用于数据底座的建设，包括数据采集、数据存储、数据融合、时空计算等。信通院发布的 2022 年《数字孪生城市白皮书》指出城市大数据平台和城域物联感知平台一起为数字孪生底座平台提供海量的动静态运行数据，是数字孪生城市数据融合的源泉，是孪生底座构建的关键基础。

2022 年 11 月，bentley 发布 iTwin Experience、iTwin Capture 和 iTwin IoT，扩展其数字孪生产品 iTwin Platform 的功能。其中 iTwin IoT，用于收集和分析传感器数据，用户能够无缝纳入传感器和状况监测设备创建的物联网(IoT)数据；iTwin Capture，用于采集、分析和分享来自于无人机视频、数码相机、扫描仪等设备的实景数据，数字孪生模型都可以相应地从实景建模开始，而不需要 BIM 模型。

《城市数字孪生标准化白皮书 2022》指出时空计算实现对海量城市时空大数据的查询、分析和解析，对于充分释放时空大数据的价值，支撑时间、空间特性挖掘与体现具有重要意义,是支撑众多城市数字孪生应用场景的重要能力。京东的时空数据引擎 JUST 基于 Apache Hadoop 和 Apache Spark 框架，为海量时空数据的存储、管理、挖掘、可视化分析、服务提供一体化解决方案，并用于支撑京东数字城市、物流大脑等数字孪生应用的解决方案。

2022 年 9 月 26 日，腾讯联合埃森哲发布《全真互联白皮书》，全面呈现这一面向未来的技术体系和应用场景。全真互联以全真体验、无限连接、自由协同、数实融合为主要发展特征。人们能够对真实世界沉浸式感知和体验，产生无限连接的可能性，突破物理时间和空间限制自由协作，数字技术和实体经济也将充分融合发展。孪生/视频将包括音视频、数字孪生、3D 引擎及空间计算等技术体系，能够全细节还原或超写实呈现真实世界，让数字世界和真实世界相互连接、映射与耦合。比如，城市管理者可以通过数字孪生系统实时掌握城市现状、趋势，发现变化过程中的关系、规律，支撑管理决策。腾讯目前在音视频、数字孪生、3D 引擎、实时

渲染、边缘计算、安全、区块链等领域已经做好了技术储备，并建立了核心优势。

动态分析：

大数据起源于数据的指数级增长，而数字孪生则是为了满足物理空间与虚拟空间之间的互联互通。大数据与数字孪生产生的大背景是相同的，即新一代信息技术的应用和普及。

大量结构化，半结构化和非结构化数据可以通过大数据分析识别行为特征和模式，洞察行为趋势、帮助用户做出决策；数字孪生在产品全生命周期的应用中，每一阶段都需要物理实体与虚拟模型的持续互动和虚拟模型的迭代优化，而这一过程的媒介就是各种各样的数据。在实际应用中，数字孪生与大数据对制造业产生的有益效果是高度重叠的，如提高生产、管理效率，预测产品、设备的故障风险及寿命预测等。

要达成数字孪生的目标，物理实体方面需要引入更先进的传感器技术，从而能全面而实时的采集所需的数据；需要搭建更先进的物联网，从而为孪生数据的实时、可靠、高效传输提供帮助；也需要打造更先进的数据管理体系，从而能高效的汇聚和整合数据；还需要引入更先进的机器学习和 AI 算法，从而提升模型的智能化水平，不要仅限于传统的物理、几何或规则建模。

目前广联达的在数字孪生方面的探索，侧重在数字孪生的构建，而数字孪生的数据管理体系，以及匹配的机器学习和 AI 算法方面，进展较慢。建议广联达加大相关技术的调研和探索。

信息来源：

[1]http://www.studyofnet.com/315643744.html
[2]https://blog.csdn.net/jane9872/article/details/130041561

5 大数据与广联达

5.1 大数据平台建设[刘松]

大数据技术在广联达得到了广泛的应用，目前为多个业务线进行赋能。集团的数据治理系统经历了接近三年的建设，在离线和实时领域都有了更位丰富的能力，随着能力的拓展，数据治理系统的业务覆盖也在有条不紊的拓展，具体详见表 5-1。

表 5-1 数据治理系统覆盖业务一揽表

业务线	客户	大数据业务	云基础	部署模式
成本大数据产品线	陕西建工 中南设计院 华西集团	成本测算数据实时集成与分析	客户 IDC	私有云
	公有云租户	成本测算数据实时集成与分析	华为云	公有云
工程交易产品线	深圳公共资源	政务大数据平台	客户 IDC	私有云
企业管理产品线	二十冶集团 二十二冶集团 中建七局 北京建工集团	大数据治理平台	客户 IDC	私有云
行业服务客户群	盐城市住建局	盐城市智慧住建综合管理平台	客户 IDC	私有云
系统客户群	中建电子	大数据治理平台	客户 IDC	私有云
集团服务业务部	内部	数据服务新干线	阿里云	公有云

广联达在治理系统建设的过程中，大数据团队进行了多种类型的大数据技术探索，并自研新版大数据底座 SWAN，解决了旧版架构的资源消耗大、扩展新引擎成本高、架构复杂的一系列问题。治理系统在过去的一年发布了多个产品模块：低门槛实时开发工具、表维度数据质量管理、数据治理 OpenAPI 开放、作业迁移工具等，在降低用户使用门槛，满足更多治理场景，以及成果规模化方面都有了更好的能力支撑。

随着市场对精细化管理需求的不断加强，基于数据决策的诉求愈发的强烈，用户对数据的关注度也越来越高，广联达在大数据侧正在进行不断的整合，并引入 AI 算法技术，探索数据与数据，指标与指标间的关系。数据在关系整合后才具有业务指导价值，再依托综合决策、企业 BI 等分析平台，为用户的实际业务进行赋能。

广联达大数据团队在技术探索方向不断前行，近 1 年来，相继引入了 kyuubi 作为底层引擎与上层应用的链接，采用 k8s 做资源的管理。面对实时计算场景，引入了 FlinkCDC，Dlink，DBZ 等多项技术，并在开源基础上持续迭代优化，在更低的资源消耗下支持业务的实时场景。未来还会在 AI 算法领域发力，形成大数据+AI

的智能工具链为业务赋能。

5.2 GDE 平台建设[刘松]

CDE 起源于 1990 年，帮助企业在工程和设计领域实现数字化转型，提高效率、降低成本、改善决策、提高安全性和遵守法规。

1. CDE 服务于协作和共享场景，为各参与方提供实时、真实、全面的单一数据源，协作产生价值。

2. CDE 改变了数据交互的方式，由网络型改为中心型，统一交互标准，减少了交互类型，便于管理。

3. CDE 正在向更加智能化、开放、安全、易于使用发展，同时也在应用于其他领域。

4. CDE 是一种“理念”，不是技术方案，支撑 CDE 可以有多种方案。

广联达 GDE（Glodon Data Environment）是广联达推出的支撑 CDE 理念的平台解决方案。GDE 能力建设方面，索本求源，结合系统化数字化转型战略；博采众长，吸取国外 CDE 建设经验；从业务本质出发，解决业务痛点问题，挖掘业务潜在价值，取得了阶段性的成果。

1. **GDE 战略承接：**GDE 承接数字化三元素“数据+连接+算法”

2. **GDE 业务事理：**GDE 基于要素、框架、图谱构建一体化的数据网络事理

3．GDE 数据架构：构建以 BIM 为中心，以项目为载体的互联互通的数据环境

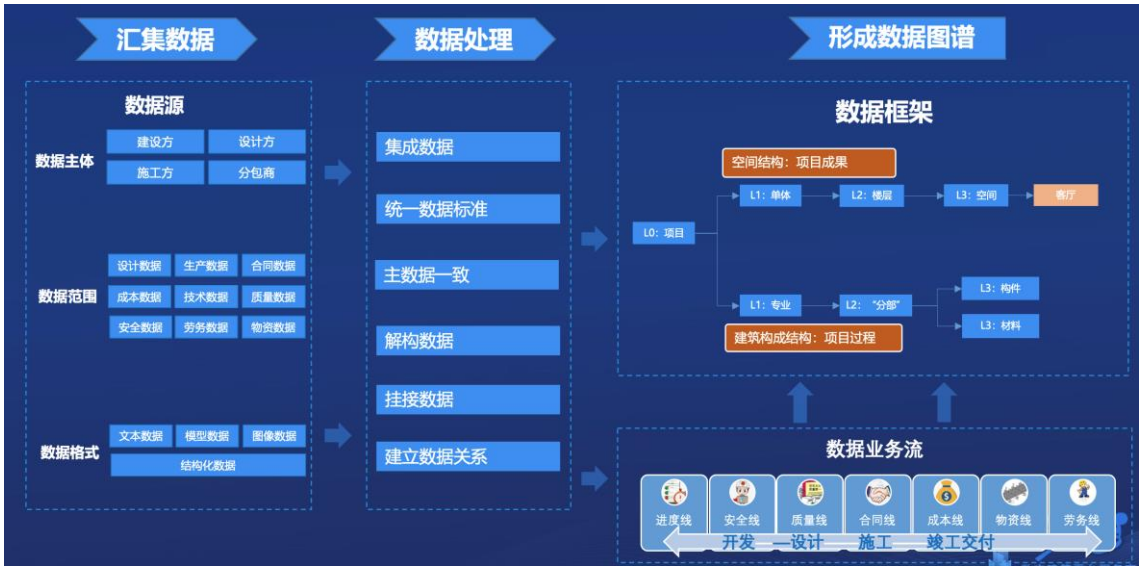

4．GDE 工具能力

广联达在 GDE 工具能力建设方面，结合多年沉淀的大数据技术，根据数据+连接+算法的思想，构建了全栈的数据连接、融合、协同能力。

在数据连接方面，基于多年沉淀的大数据实时数仓（Flink CDC、Debezium）+数据湖技术（paimon），实现了广联达业务全域（工程线、经济线、综合线等）的数据入湖；在数据融通方面，基于多年积累的行业数据要素库，以及业务框架，通过 NLP 算法实现无缝数据连接，配合主数据产品实现的主数据骨干网络，实现了全域的数据融通；在数据协同方面，基于 Starrocks，NebluaGraph 的实时和连接能力，实现了多方业务数据的协同。

5．GDE 应用场景

通过 GDE 基于数据要素的数据解构，实现计划与质量数据的拉通。

施工成本一体化的实现，是各个企业关注的核心领域：合同，成本，支出等经营数据对数据结果的准确性、数据的及时性、数据完整性和数据的可对比性都具有很高的要求，传统人工填报，人工录入，人工统计和汇总的作业模式已经很难满足现有企业和项目的对于过程的精细化管控和提升经营效益的需要。

通过 GDE 对于施工成本一体化，对于工程量数据、成本数据，合同数据，变更洽商等数据标准化处理，并通过提取其中的项目特征要素。成本科目要素、变更等商务要素、按照专业、分部、构件、楼层等要素组成的数据框架进行解构和联通。因为这些业务数据的组成要素是稳定不变的，以一套完善的数据框架体系为载体进行数据连接，实现全数据的联通，就可以支撑施工成本一体化在成本测控等场景的应用，让企业和项目的目标下达更合理、过程更高效、高精运转。

6．GDE 未来业务全景
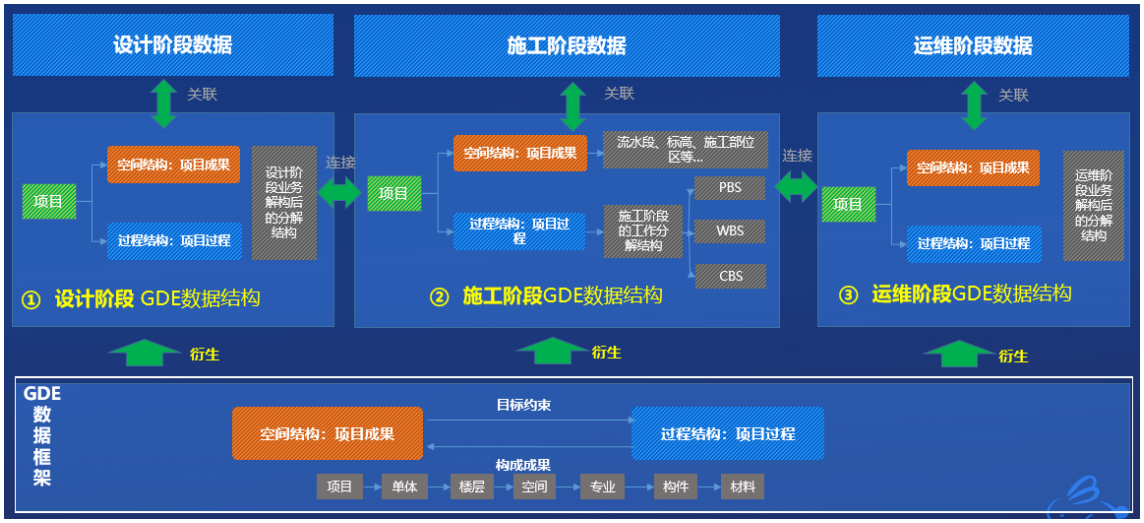
GDE 数据框架基于系统、模块的数据底座，连接业务全过程。